





Architecture Micro-services avec Spring Cloud

David THIBAU - 2023

david.thibau@gmail.com



Agenda

Introduction

- Architecture Micro-services
- Services techniques : frameworks vs infra
- L'offre Spring-Cloud

Discovery et Config

- Service Eureka
- Spring Cloud Config

Support pour les clients

- Répartition de charge
- Le pattern Circuit breaker
- Clients déclaratifs avec Feign
- API Gateway
- Spring Cloud Contract

Monitoring

- Monitoring Circuit Breaker
- Tracing avec Spring Sleuth
- Centralisation des logs ELK

Messaging

- Rappels Messaging
- Ex : Saga Pattern
- Spring Cloud Stream : Concepts et introduction
- Spring Cloud Data Flow

Sécurité

- Introduction
- Rappels oAuth2/OpenID
- Spring Security et oAuth2

Déploiement

- Alternatives
- Support pour les conteneurs
- Spring Cloud et Kubernetes



Introduction

Architectures micro-services

Services techniques : frameworks vs infra L'offre Spring Cloud



Introduction

Le terme « *micro-services* » décrit un nouveau pattern architectural visant à améliorer la rapidité et l'efficacité du développement et de la gestion de logiciel

C'est le même objectif que les méthodes agiles ou les approches *DevOps* : « Déployer plus souvent »



Architecture

L'architecture implique la décomposition des applications en très petit services

- faiblement couplés
- ayant une seule responsabilité
- Développés par des équipes full-stack indépendantes.

Le but étant de livrer et maintenir des systèmes complexes avec la rapidité et la qualité demandées par le business digital actuel

On l'a appelée également SOA 2.0 ou SOA For Hipsters

Caractéristiques

Design piloté par le métier : La décomposition fonctionnelle est pilotée par le métier (voir *Evans's DDD approach*)

Principe de la responsabilité unique : Chaque service est responsable d'une seule fonctionnalité et la fait bien !

Une interface explicitement publiée: Un producteur de service publie une interface qui peut être consommée

DURS (Deploy, Update, Replace, Scale) indépendants : Chaque service peut être indépendamment déployé, mis à jour, remplacé, scalé

Communication légère : REST sur HTTP, STOMP sur WebSocket,



Scaling indépendant : Seuls les services les plus sollicités sont scalés => Économie de ressources

Mise à jour indépendantes : Les changements locaux à un service peuvent se faire sans coordination avec les autres équipes => Agilité de déploiement

Maintenance facilitée : Le code d'un micro-service est limité à une seule fonctionnalité

=> Corrections, évolutions plus rapide

Hétérogénéité des langages : Utilisation des langages les plus appropriés pour une fonctionnalité donnée

Isolation des fautes : Un dysfonctionnement peut être plus facilement localiser et isoler.

Communication inter-équipe renforcée : Full-stack team

=> Favorise le CD des applications complexes



Réplication: Un micro-service doit être scalable facilement, cela a des impacts sur le design (stateless, etc...)

Découverte automatique : Les services sont typiquement distribués dans l'environnement d'exécution, le scaling peut être automatisé. Les points d'accès aux services doivent alors s'enregistrer dans un annuaire afin d'être localisés automatiquement

Monitoring : Les points de surveillances sont distribués. Les traces et les métriques doivent être agrégés en un point central


Résilience : Plus de services peuvent être en erreur. L'application doit pouvoir résister aux erreurs.

DevOps : L'intégration et le déploiement continu sont indispensables pour le succès.




Inconvénients et difficultés


- Trouver la bonne décomposition est difficile.
 Une mauvaise décomposition peut entraîner des couplages entre les micro-services
- Le côté distribué fait que le système complet est plus difficile à tester, déployer
- Le déploiement de fonctionnalités qui touche plusieurs services est plus délicat
- La migration d'une application monolithique existante vers les micro-services n'est pas simple



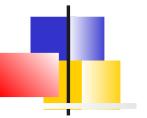
Architecture monolithique Hexagonale




Une architecture micro-service



Organisation DevOps





Problèmes à résoudre et design patterns

Décomposition en services, Patterns :

- DDD ou sous-domaines
- Fonctionnalités métier

<u>Communication entre service</u>, Aspects et patterns:

- Style (RPC, Asynchrone, etc.)
- Découverte des services, (Self-registry pattern, ...)
- Fiabilité : Circuit Breaker Pattern
- Messagerie transactionnelle
- APIs

<u>Distribution des données</u>, Aspects

- Gestion des transactions : Transactions distribuées ?
- Requêtes avec jointures ?

Patterns et problèmes à résoudre

<u>Déploiement des services</u>, Patterns :

- Hôtes uniques avec différents processus
- Un container par service, Déploiements immuables, Orchestration de Containers
- Serverless

Observabilité afin de fournir des insights applicatifs :

 Health check API, Agrégation des traces, Tracing distribué, Détection d'exceptions, Métriques applicatifs, Audit

<u>Tests automatisés</u>:

Service en isolation, Tests des contrats (APIs)

<u>Patterns transverses</u>:

– Externalisation des configurations, Pipelines CD, ...

Sécurité:

Jetons d'accès, oAuth, ...



- I. Outil de scm : Unique source de vérité
- II. Dépendances: Déclare et isoler les dépendances
- III. Configuration : Configuration séparée du code, stockée dans l'environnement
- IV. Services d'appui (backend) : Considère les services d'appui comme des ressources attachées,
- V. Build, release, run : Permet la coexistence de différentes releases en production
- **VI. Processes** : Exécute l'application comme un ou plusieurs processus stateless. Déploiement immuable
- **VII. Port binding** : Application est autonome (pas de déploiement sur un serveur). Elle expose juste un port TCP
- VIII. Concurrence : Montée en charge grâce au modèle de processus
- IX. Disposability: Renforce la robustesse avec des démarrages et arrêts rapides
- X. Dev/prod parity : Garder les environnements de développement, de pré-production et de production aussi similaires que possible
- **XI. Logs**: Traiter les traces comme un flux d'événements
- XII. Processus d'Admin : Considérer les tâches d'administration comme un processus parmi d'autres



Introduction

Architectures micro-services

Services techniques:
frameworks vs infrastructure
L'offre Spring Cloud



Services Transverses

De nombreux services transverses peuvent être fournis par un framework ou une infrastructure


- Service de discovery permettant à un micro-service de s'enregistrer et de localiser ses micro-services dépendants
- Service de centralisation de configuration facilitant la configuration et l'administration des micro-services
- Services d'authentification offrant une fonctionnalité de SSO parmi l'ensemble des micro-services, de génération et de relais de jeton
- Service de monitoring agrégeant les métriques de surveillance en un point central
- Support pour la répartition de charge, le fail-over, la résilience aux fautes

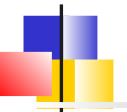


Services techniques vs Infra


Qui fournit les services techniques?

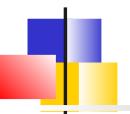
- Dans les premières architectures, c'est le software => framework Netflix
- Actuellement, de nombreux services techniques migrent vers l'infrastructure :
 - Discovery, Config, Répartition de charge offert nativement par Kubernetes
 - Résilience, Sécurité, Monitoring : Service mesh de type Istio





Capability Mapping





Introduction

Architectures micro-services
Services techniques:
frameworks vs infrastructure
L'offre Spring Cloud

Offre Spring Cloud

Spring Cloud a pour vocation de faciliter l'implémentation des patterns des architectures distribuées

Spring Cloud nécessite Spring Boot

Les solutions Spring Cloud s'exécutent dans différentes environnements distribués :

- Local au développeur
- Réseau d'entreprise (Bare Metal ou autres)
- Plateformes gérés (Kubernetes, Amazon Web Services, Cloud Foundry, Heroku Paas

Applications visées

Les applications visées sont de type SAAS software-as-a-service basées sur les technologies WEB et des méthodologies de développement DevOps

Les objectifs sont :

- Utiliser des formats déclaratifs pour l'automatisation de la mise en place.
 Cela pour minimiser les temps et les coûts pour intégrer de nouveaux développeurs au projet
- Avoir un contrat clair avec le système d'exploitation sous-jacent afin d'offrir le maximum de portabilité : La JVM
- Être adapté au déploiement sur les plate-formes de cloud afin d'éviter le besoin de serveurs et d'administration système
- Minimiser les divergence entre le développement et la production =>
 déploiement continu et agilité maximale
- Qui puisse se scaler sans de gros impacts sur les outils, l'architecture ou les pratiques de développement

Offre Spring Cloud

Sprint Cloud basé sur Spring Boot fournit un framework de développement de micro-services qui :

- Apporte des abstractions des micro-services techniques nécessaires : Permettant d'adapter rapidement son code à une implémentation spécifique
- Du support pour les clients REST incluant la répartition de charge et la résilience
- Du support pour l'intégration des micro-services aux middleware de messagerie
- Bénéficie de l'environnement Spring Boot et de l'écosystème Spring (Testabilité, Spring MVC / REST, Spring Data (SQL ou NoSQL), ...

Starter de projet Spring Cloud

Les fichiers de dépendances des projets SpringCloud font intervenir 2 versions :

- La version Spring Boot
- La release Spring Cloud

```
<parent>
 <groupId>org.springframework.boot
 <artifactId>spring-boot-starter-parent</artifactId>
 <version>1.5.10.RELEASE
 <relativePath/> <!-- lookup parent from repository -->
</parent>
<dependencyManagement>
 <dependencies>
   <dependency>
     <groupId>org.springframework.cloud
     <artifactId>spring-cloud-dependencies</artifactId>
     <version>Edgware.RELEASE</version>
     <type>pom</type>
     <scope>import</scope>
   </dependency>
 </dependencies>
</dependencyManagement>
```



Spring Boot / Spring Cloud

La plupart des fonctionnalités sont offertes par Spring Boot et l'auto-configuration

Les fonctionnalités supplémentaires de Spring Cloud sont offertes via 2 librairies :

- Spring Cloud Context: Utilitaires et services spécifiques pour le chargement de l'ApplicationContext d'une application Spring Cloud (bootstrap, cryptage, rafraîchissement, endpoints)
- Spring Cloud Commons est un ensemble de classes et d'abstraction utilisées dans les différentes implémentations des services techniques (Par exemple : Spring Cloud Netflix vs. Spring Cloud Consul).



Contexte de bootstrap

Ue application Spring Cloud créée un contexte Spring de "bootstrap" à partir du fichier bootstrap.yml.

Ce contexte est responsable de charger les propriétés de configuration à partir de ressources externes

Typiquement, un serveur de configuration distant.




Contexte bootstrap et contexte local

Les deux contextes (bootstrap et local) contribuent au contexte applicatif final de l'application

- Les propriétés de bootstrap (distant) ont la priorité la plus haute et ne peuvent donc pas être surchargées par une configuration locale.
- En général, le fichier de configuration local bootstrap.yml ne contient que l'identification de l'application et la localisation du service externe de configuration.

Exemple: bootstrap.yml

```
spring:
   application:
    name: members-service
   cloud:
    config:
        uri: http://config:8888
        fail-fast: true
        password: ${CONFIG_SERVICE_PASSWORD}
        username: user
```



Spring Cloud Commons

Abstractions et implémentations

Discovery (Client et serveur) : Eureka, Consul, Zookeeper

LoadBalancer: Ribbon, SpringRestTemplate, Reactive Web Client

Circuit Breaker: Resilence4J, Sentinel, Spring Retry, Hystrix

Routing: Gateway, Zuul



Spring et les Patterns Microservices

<u>Communication entre service</u>, Aspects et patterns:

- Spring Cloud OpenFeign
- Spring Cloud Discovery
- Spring Cloud CircuitBreaker
- Spring Cloud Gateway

Distribution des données, Aspects

- Spring Cloud Messaging (Saga Pattern)
- Spring Cloud Kafka Stream (KTable)

Spring et les Patterns Microservices (2)

Déploiement des services, Patterns :

- Spring Boot Plugin : spring-boot:build-image
- Spring Cloud Kubernetes
- Spring Native (ServerLess)

Observabilité afin de fournir des insights applicatifs :

- Actuator
- Sleuth, Zipkin

<u>Tests automatisés</u>:

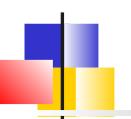
Spring Cloud Contract

<u>Patterns transverses</u>:

Spring Cloud Config

<u>Sécurité</u>:

Spring Security 5,




Serveur de Discovery et Configuration

Service de Discovery Spring Cloud Config



Types d'implémentation du service discovery



Predecessor → Successor

Alternative A → · · · → Alternative B



Self registration : Une instance de service s'enregistre au démarrage

auprès du service de discovery

Exemple: Eureka

Client-side discovery: Un service client récupère la liste des services

disponibles auprès du service de discovery et équilibre la charge

Exemple: Eureka, Consul

3rd party registration: Les instances de services sont

automatiquement enregistrés via un agent tiers

Exemple : Consul, Kubernetes

Server-side discovery: Un client effectue une requête vers un routeur

responsable de la découverte de service.

Exemple: Kubernetes



@EnableDiscoveryClient

L'annotation @EnableDiscoveryClient recherche des implémentations de l'interface DiscoveryClient :

- Spring Cloud Netflix Eureka,
- Spring Cloud Consul Discovery
- Spring Cloud Zookeeper Discovery.
- Spring Cloud Kubernetes Discovery

L'application s'enregistre alors auprès d'un serveur de discovery distant.



Service Discovery Eureka

La société Netflix a mis a disposition de la communauté Open Source *Eureka* un service de découverte pour les microservices

Eureka offre:

- Une API Rest, et une page Web
- Simple et rapide
- Peut fonctionner en cluster (1 par data centre)



Fonctionnement

Quand un client s'enregistre avec *Eureka*, il fournit des méta-données comme le hôte, le port, l'indicateur de santé, la page d'accueil

Eureka reçoit périodiquement des messages (heartbeat) de chaque instance des services.

Si il ne reçoit pas de messages au bout d'un timeout configurable, l'instance est supprimée du registre.

Mise en place du serveur Eureka

L'application Eureka Server doit déclarer le starter

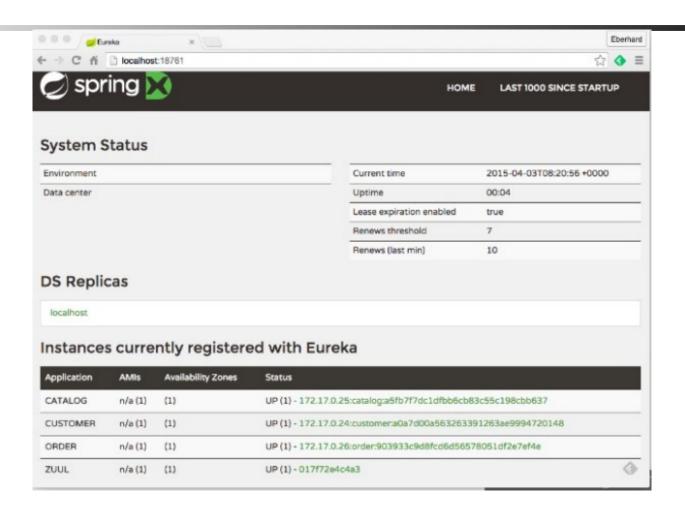
spring-cloud-starter-eureka-server

```
@SpringBootApplication
@EnableEurekaServer
public class AnnuaireApplication {

public static void main(String[] args) {
   SpringApplication.run(AnnuaireApplication.class, args);
   }
}
```



Page Eureka





Client Eureka

Pour s'enregistrer sur un service Eureka, un client doit simplement déclarer le starter¹ spring-cloud-starter-netflix-eureka-client

L'enregistrement a alors 2 conséquences :

- Le serveur surveille périodiquement le statut du service
- Le client interroge régulièrement le serveur pour localiser les autres services



Utilisation du client Eureka

La principale API de *EurekaClient* est de localiser une instance d'un service :

```
@Autowired
private DiscoveryClient discoveryClient;

public String serviceUrl() {
    InstanceInfo instance =
    discoveryClient.getNextServerFromEureka("STORES", false);
    return instance.getHomePageUrl();
}
```




Configuration

Pour localiser le serveur Eureka

eureka.client.serviceUrl.defaultZone

Les valeurs par défaut pour l'enregistrement du nom de l'application, de l'hôte virtuel et du port sont :

- \${spring.application.name}
- \${spring.application.name}
- \${server.port}



Page de statut et indicateur de santé

La page d'accueil d'*Eureka* propose des liens vers différentes ressources du service enregistré.

Par défaut ce sont les liens /actuator mais cela peut être changé

eureka:

```
instance:
```

statusPageUrlPath: \${management.context-path}/info

healthCheckUrlPath: \${management.context-path}/health

homePageUrl: https://\${eureka.hostname}/



Méta-données additionnelles

Des méta-données additionnelles peuvent être ajoutées dans

eureka.instance.metadataMap

Elles sont alors accessibles des clients distants qui peuvent en faire bon usage

Ces méta-données spécifiques sont utilisées par les solutions de Cloud supportées : Cloudfoundry, AWS par exemple

Exemple

```
spring:
  application:
     name: members-service # Service registers under this name
eureka:
  client:
    serviceUrl:
      defaultZone: http://annuaire:1111/eureka/
  instance:
    LeaseRenewalIntervalInSeconds: 5 # 5s au lieu de 30s (dev)
    MetadataMap :
      instanceId=${spring.apllication.name}:$random.value}
```



Heartbeat

Les services envoient un heartbeat toutes les 30 secondes.

=> Un service n'est pas disponible pour la découverte par un autre client tant que l'instance, le serveur et le client n'ont pas tous les mêmes données dans leur cache local (cela peut donc prendre 3 pulsations)

La valeur des 30s peut être modifiée via la configuration : eureka.instance.leaseRenewalIntervalInSeconds

Cependant, il n'est pas recommandé de le modifier en production



Configurations serveur

Par défaut, chaque serveur Eureka est également un client et nécessite au moins un serveur pair pour s'enregistrer.

- => 2 configurations typiques :
 - Standalone : Désactiver l'enregistrement du seul serveur Eureka
 - Peer : déclarer au minimum un serveur peer pour chaque instance du serveur Eureka


- 1

Configuration standalone

La configuration *standalone* est utile lorsque l'on ne démarre qu'un seul service Eureka

```
eureka:
  instance:
  hostname: localhost

client:
  register-with-eureka: false
  fetch-registry: false
  serviceUrl:
    defaultZone: http://${eureka.instance.hostname}:${server.port}/eureka/
```



Configuration en paire

```
spring:
  profiles: peer1
eureka:
  instance:
    hostname: peer1
  client:
    serviceUrl:
      defaultZone: http://peer2/eureka/
spring:
  profiles: peer2
eureka:
  instance:
    hostname: peer2
  client:
    serviceUrl:
      defaultZone: http://peer1/eureka/
```




Zones

Si les clients Eureka sont dans des zones différentes, il est préférable qu'ils accèdent au serveur Eureka le + proche.

Il faut alors indiquer dans quelle zone se trouve le client

eureka.instance.metadataMap.zone = zone1
eureka.client.preferSameZoneEureka = true



Serveur de Discovery et Configuration

Service de Discovery, l'exemple Eureka Spring Cloud Config



Configuration centralisée

spring-cloud-config offre une alternative pour mettre en place une gestion centralisée de toutes les configurations des micro-services.

- Les mises à jour peuvent être dynamiques
- Le serveur peut être associé à un dépôt Git
 - => Gestion de branches, des releases



Serveur de configuration

Le serveur de configuration est une application Spring Boot annotée par @EnableConfigServer

La stratégie par défaut pour localiser les sources des propriétés est de cloner un dépôt git (spring.cloud.config.server.git.uri)

Le serveur offre différents endpoints permettant de récupérer les valeurs de configuration :

```
/{application}/{profile}[/{label}]
/{application}-{profile}.yml
...
```



Résolution des valeurs de configuration

Les valeurs de configurations retournées par les endpoints dépendent de 3 paramètres :

- {application} qui correspond à la propriété "spring.application.name" du côté du client
- {profile} qui correspond à "spring.profiles.active" du côté du client
- {label} qui correspond à une révision ou tag du côté du serveur

Mise en place

```
@SpringBootApplication
@EnableConfigServer
public class ConfigServer {
  public static void main(String[] args) {
    SpringApplication.run(ConfigServer.class, args);
Propriétés principales (application.properties)
server.port: 8888
spring.cloud.config.server.git.uri: file://${user.home}/config-repo
Dépendance
<dependency>
  <groupId>org.springframework.cloud
  <artifactId>spring-cloud-config-server</artifactId>
</dependency>
```



L'implémentation par défaut pour stocker les valeurs de configuration est un dépôt Git spécifié par :

spring.cloud.config.server.git.uri

Le répertoire de clonage est spécifié par : spring.cloud.config.server.git.basedir

Le paramètre {label} est alors associé à une référence git (id de commit, branche ou tag)



Sécurité

Pour utiliser l'authentification basique HTTP, il suffit de préciser les propriétés :

- spring.cloud.config.server.git.username
- spring.cloud.config.server.git.password

Pour utiliser ssh, le plus simple est d'installer une clé publique sur le serveur



Backend de fichiers

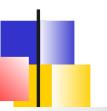
Le serveur peut également charger les configurations à partir du classpath ou du système de fichiers

Il faut alors

- activer le profil *native*
- et d'indiquer la propriété
 spring.cloud.config.server.native.searchLocations
 qui spécifie l'emplacement racine
 - soit à partir du classpath classpath:/config
 - Soit à partir du système de fichiers file:./config

Exemple Classpath

```
@SpringBootApplication
@EnableConfigServer
public class ConfigApplication {
  public static void main(String[] args) {
    SpringApplication.run(ConfigApplication.class, args);
spring:
  cloud:
    config:
      server:
        native:
          search-locations: classpath:/shared
  profiles:
    active: native
```



Arborescence serveur

Le répertoire racine sur le seveur contient alors :

- application.yml : Valeurs de configuration partagées par tous les micro-services
- Des fichiers <application-name>.yml
 Valeurs de configuration pour le microservice <application-name>
- <application-name>--profil>.yml : Des fichiers spécifiques à un profil¹.



Endpoints proposés

Une fois démarré le serveur propose les endpoints suivants :

- /application/default : Les propriétés partagées pars tous les micro-services
- -/{application-name}/default : Les propriétés d'un service donné dans le profil par défaut
- -/{application-name}/profil : Les propriétés d'un service donné dans un profil donné.

Usage client

Les clients dépendent de : spring-cloud-config-client

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-config</artifactId>
</dependency>
```

Ils définissent l'adresse du serveur de configuration (par défaut localhost:8888) via la propriété :

spring.cloud.config.uri: http://myconfigserver.com

Configurations optionnelles

Si l'on veut interdire le démarrage en cas de non contact du serveur de configuration :

spring.cloud.config.failFast=true

Si on veut autoriser plusieurs tentatives de connexions :

- spring-retry et spring-boot-starter-aop dans le classpath
- puis les propriétés spring.cloud.config.retry.*

L'emplacement par défaut des configurations (/{name}/{profile}/{label}) peut être surchargé par spring.cloud.config.*

Propriétés des micro-services

Les propriétés de configuration des microservices sont donc présents à 2 endroits :

- bootstrap.yml : Présent en local, il ne contient en général que :
 - spring.application.name
 - La configuration du serveur de config
- Fichiers sur le serveur de config :
 - propriétés communes des micro-services,
 - propriétés spécifiques application
 - spécifique profil

Changement dynamique d'environnement

Si la configuration est modifiée (fichier de config modifié ou *push git*), celle-ci peut être répercutée dynamiquement sur les clients du serveur de config

Lors d'une modification, un événement de type EnvironmentChangeEvent est généré

- Il contient la liste des clés de configuration qui ont changées.
- Les clients ne détectent pas automatiquement les changements.
 On peut alors utiliser :
 - Spring Cloud Bus pour pousser les événements automatiquement vers les services
 - Actuator et une requête POST pour demander le rafraîchissement d'un micro-service



Le endpoint *refresh* d'actuator doit être activée.

Une requête POST sur /actuator/refresh permet de à certains beans Spring de recharcher leur configuration.

 Les beans applicatifs voulant se recharger doivent être annotés par @RefreshScope



Support pour les clients

Répartition de charge

Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract



Introduction

- Les micro-services pouvant être répliqués, la charge doit être répartie sur les différentes répliques.
- 2 patterns sont possibles pour la répartition de charge :
 - Client-Side : Le client connaît le emplacements des répliques et peut ainsi répartir la charge
 - Server-side : Le client s'adresse à un point unique : le load balancer qui lui connaît l'emplacement des répliques



Client-side et Discovery-Client

Avec l'API *DiscoveryClient* de SpringCloud, la répartition client-side est naturelle.

Elle peut être implémentéeE

- En utilisant l'API DiscoveryClient
- En utilisant l'abstraction spring-cloudloadbalancer de SC Commons



Implémentation via DiscoveryClient

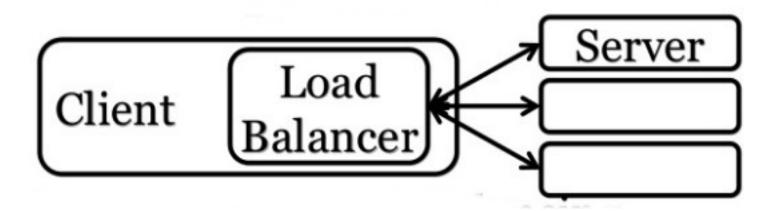
```
@Autowired
DiscoveryClient discoveryClient;
List<ServiceInstance> instances =
  discoveryClient.getInstances("another-service");
Instance instance = _chooseOneInstance(instances);
String url = "http://"+instance.getHost()
  +":"+instance.getPort();
restTemplate.rootUri(url);
```

Spring Cloud LoadBalancer

Spring Cloud fournit sa propre abstraction et implémentation d'équilibreur de charge côté client.

Le client Rest découvre les instances disponibles typiquement à partir du service de discovery.

- Il utilise le bean DiscoveryClient disponible dans le classpath
- Il peut également utiliser une librairie de cache





Dépendances

```
<dependency>
    <groupId>org.springframework.cloud</groupId>
    <artifactId>spring-cloud-starter-loadbalancer</artifactId>
</dependency>
< !-- Plus discovery client, par exemple -->
<dependency>
<groupId>org.springframework.cloud</groupId>
<artifactId>spring-cloud-starter-netflix-eureka-client</artifactId></dependency>
```



@LoadBalanced

Dans un contexte non-réactif, il suffit d'annoter un bean de type RestTemplate avec @LoadBalanced pour bénéficier de l'implémentation sous-jacente de l'interface de Spring Cloud Commons.

```
@Configuration
public class ClientConfiguration {

@Autowired
RestTemplateBuilder builder;

@Bean
@LoadBalanced
RestTemplate restTemplate() {
  return builder.rootUri(serviceName).build();
}}
```

Usage

```
@Log4j2
@Service
class RestClientService {
    @Autowired
    RestTemplate restTemplate

Greeting call(String url) {
    return restTemplate.getForObject("/greetings", Greeting.class);
    }
}
```



@LoadBalanced Pile réactive

Dans un contexte réactive la même annotation @LoadBalanced est utilisée

- L'annotation se place sur une méthode fournissant un WebClient.Builder.
- Le builder permet de construire un WebClient
- Le WebClient est utilisé pour effectuer les requêtes Rest



Exemple

```
@Bean
    @LoadBalanced
    WebClient.Builder builder() {
        return WebClient.builder();
    @Bean
    WebClient webClient(WebClient.Builder builder) {
        return builder.build();
    }
// Utilisation du bean
Flux<Greeting> call(String url) {
    return
  webClient.get().uri(url).retrieve().bodyToFlux(Greeting.class);
```

Usage

```
@Log4j2
@Component
class ConfiguredWebClientRunner {

   ConfiguredWebClientRunner(WebClient http) {
    call(http, "http://api/greetings").subscribe(
    greeting -> log.info("configured: " + greeting.toString()));
   }
}
```



Support pour les clients

Répartition de charge Pattern Disjoncteur Clients déclaratifs avec Feign Gateway et routing Consumer Driven Contract

Contexte du pattern

Lorsqu'un service en appelle un autre de manière synchrone, il est toujours possible que l'autre service ne soit pas disponible ou présente une latence si élevée qu'il est essentiellement inutilisable. Des ressources précieuses telles que des threads peuvent être consommées dans l'appelant en attendant que l'autre service réponde. Cela pourrait conduire à l'épuisement des ressources, ce qui rendrait le service appelant incapable de traiter d'autres demandes. La défaillance d'un service peut potentiellement se répercuter sur d'autres services dans l'application.1

Solution

Un client doit invoquer un service distant via un proxy qui fonctionne de la même manière qu'un disjoncteur électrique.

- Lorsque le nombre de défaillances consécutives dépasse un seuil, le disjoncteur se déclenche et, pendant la durée d'un délai d'expiration, toutes les tentatives d'appel du service distant échouent immédiatement.
- Une fois le délai expiré, le disjoncteur autorise le passage d'un nombre limité de demandes de test. Si ces demandes aboutissent, le disjoncteur reprend son fonctionnement normal. Sinon, en cas d'échec, le délai d'expiration recommence.

Spring Cloud Breaker Pattern

Spring Cloud Breaker fournit une abstraction et donc une API cohérente à utiliser pour les librairies implémentant le pattern circuit breaker. Il supporte :

- Netfix Hystrix
- Resilience4J
- Sentinel
- Spring Retry



Pour utiliser le pattern dans son application, Spring Cloud injecte un CircuitBreakerFactory en fonction des starters trouvés dans le classpath.

Sa méthode *create()* permet de définir une classe *CircuitBreaker* dont la méthode *run()* prend 2 lambda en arguments :

- Le code à exécuter dans l'autre thread
- Optionnellement, un code de fallback

-

Exemple

```
@Service
public static class DemoControllerService {
private RestTemplate rest;
private CircuitBreakerFactory cbFactory;
public DemoControllerService(RestTemplate rest, CircuitBreakerFactory cbFactory) {
this.rest = rest;
this.cbFactory = cbFactory;
public String slow() {
return cbFactory.create("slow").run(() -> rest.getForObject("/slow",
  String.class), throwable -> "fallback");
```

Patterns Resilience4J

Retry : Répéter les exécutions échouées

De nombreux fautes sont transitoires et peuvent s'auto-corriger après un court délai.

Circuit Breaker : blocages temporaires des défaillances possibles Lorsqu'un système éprouve de sérieuses difficultés, il est préférable d'échouer rapidement que d'attendre les clients.

Rate limiter: Limiter les exécutions

Limitez le taux des requêtes

Time Limiter: Limiter le temps d'exécution des requêtes Au-delà d'un certain intervalle d'attente, un résultat positif est peu probable

Bulkhead: Limiter les exécutions concurrentes

Les l'essources sont isolées dans des pools de sorte que si l'une échoue, les autres continuent de fonctionner.

Cache: Mémoriser un résultat réussi Une partie des demandes peut être similaire.

Fallback: Fournir un résultat alternatif pour les échecs Les choses échoueront toujours - planifiez ce que vous ferez lorsque cela se produira.



Support pour les clients

Répartition de charge Pattern Disjoncteur Clients déclaratifs avec Feign Gateway et routing Consumer Driven Contract



Introduction

Feign est un client de service REST déclaratif, facilitant le développement.

Pour utiliser *Feign*, juste créer une interface et l'annoter!

Il offre un support pour des annotations pluggable, les annotations JAX-RS, des dés/encodeurs pluggable



Mise en place

```
spring-cloud-starter-feign
```

```
@SpringBootApplication
@EnableEurekaClient
@EnableFeignClients
public class Application {
    public static void main(String[] args) {
        SpringApplication.run(Application.class, args);
    }
}
```

Client

```
// « stores » : client nommé correspondant au service
// Eureka
@FeignClient("stores")
public interface StoreClient {
    @RequestMapping(method = RequestMethod.GET, value = "/stores")
    List<Store> getStores();

    @RequestMapping(method = RequestMethod.POST, value =
    "/stores/{storeId}", consumes = "application/json")
    Store update(@PathVariable("storeId") Long storeId, Store store);
}
```



Si *Spring Cloud CircuitBreake*r est dans le classpath et


spring.cloud.openfeign.circuitbreaker.enabled=true, les appels sont encapsulés dans un circuit breaker

Le nom du circuit-breaker est alors : <feignClientClassName>#<calledMethod>(<parameterTypes>)

Pour configurer la commande de fallback il faut renseigner, l'attribut *fallback* en indiquant un bean implémentant l'interface

Exemple avec Feign et fallback

```
@FeignClient(name = "hello", fallback = ClientFallback.class)
protected interface Client {
    @RequestMapping(method = RequestMethod.GET, value = "/hello")
    Hello iFailSometimes();
@Service
class ClientFallback implements Client {
    @Override
    public Hello iFailSometimes() {
        return new Hello("fallback");
```



Support pour les clients

Répartition de charge Pattern Disjoncteur Clients déclaratifs avec Feign **Gateway et routing** Consumer Driven Contract



Introduction

Le pattern *API Gateway* permet à un client nécessitant plusieurs services de back-end de ne s'adresser qu'à **un seul** service.

La gateway route alors les requêtes vers les back-end implémentant les services demandés

En plus des fonctionnalités de routing, la gateway peut intégrer des services transverses à toute l'architecture micro-service : authentification, CORS, filtrage d'entêtes HTTP, ...

Spring Cloud Gateway

- Spring Cloud Gateway, construit sur un modèle réactif, a pour vocation de fournir toutes les fonctionnalités d'une Gateway :
 - Routage en fonction de n'importe quel attribut de requête.
 - Les filtres spécifiques aux routes.
 - Intégration de CircuitBreaker
 - Intégration de DiscoveryClient
 - Possibilité de limiter la cadence des requêtes
 - URL rewriting

Exemple gateway

```
@Bean
public RouteLocator myRoutes(RouteLocatorBuilder builder) {
    return builder.routes()
// Routing + ajout d'entête
        .route(p -> p
            .path("/get")
            .filters(f -> f.addRequestHeader("Hello", "World"))
            .uri("http://httpbin.org:80"))
// Utilisation de Hystrix
        .route(p -> p)
            .host("*.hystrix.com")
            .filters(f -> f.hystrix(config -> config
                 .setName("mycmd")
                 .setFallbackUri("forward:/fallback")))
            .uri("http://httpbin.org:80"))
        .build();
}
```



Intégration avec DiscoveryClient

Pour créer des routes vis à vis des services enregistrés dans le serveur de discovery :

spring.cloud.gateway.discovery.locator.enabled=true

Par défaut, des routes sont définies pour chaque service enregistrés

Les URLs /serviceId/** sont routées vers le service en enlevant le préfixe

Définition explicite des routes


En général, on ne veut pas exposer tous les micro-services à l'extérieur ; il faut donc configurer les routes explicitement.

Ex avec *DiscoveryClient*:

```
spring:
    cloud:
    gateway:
        locator:
        enabled : false
    routes:
        - id: route-order
            uri: lb://ORDERSERVICE
        predicates:
        - Path= /order/**
        filters:
        - RewritePath=/order/?(?<remaining>.*), /$\{remaining}
```

Exemple CircuitBreaker

```
Dans le classpath :
  spring-cloud-starter-circuitbreaker-reactor-resilience4j
Config:
spring:
  cloud:
    gateway:
      routes:
      - id: circuitbreaker_route
        uri: https://example.org
        filters:
        - name: CircuitBreaker
          args:
            name: myCircuitBreaker
            fallbackUri: forward:/inCaseOfFailureUseThis
        - RewritePath=/consumingSE, /backingSE
```



actuator

Pour avoir un endpoint actuator :

management.endpoint.gateway.enabled=true # default value management.endpoints.web.exposure.include=gateway

Ensuite, les configurations de routes sont accessibles à l'URL /actuator/gateway/routes



Support pour les clients

Répartition de charge Pattern Disjoncteur Clients déclaratifs avec Feign Gateway et routing Consumer Driven Contract



Spring Cloud Contract

Spring Cloud Contract est un projet qui permet d'adopter une approche Consumer Driven Contract

A partir d'une spécification d'interaction entre un producteur/serveur et consommateur/client, cela permet

- De générer des tests d'acceptation côté producteur
- De créer des mocks serveur pour le client

DSL

Spring Cloud Contract et son projet projet principal Verifier fournit un DSL (Groovy ou .yaml) qui permet de spécifier le contrat

Le contrat permet alors de produire :

- Les tests d'acceptations complets côté serveurs (Spock ou JUnit)
- Les définitions de stub JSON à utiliser par WireMock lors des tests d'intégration sur le code client.
 Le code de test doit toujours être écrit à la main mais les données de test sont produites.

SCC permet également les tests de routing de message lors de l'utilisation de Spring Cloud Stream

Exemple Groovy

```
import org.springframework.cloud.contract.spec.Contract
Contract.make {
    description "should return even when number input is even"
    request {
        method GET()
        url("/validate/prime-number") {
            queryParameters {
                parameter("number", "2")
    response {
        body("Even")
        status 200
```



Tests générés côté producteur

```
public class ContractVerifierTest extends BaseTestClass {
@Test
public void validate_shouldReturnEvenWhenRequestParamIsEven() throws Exception {
    // given:
    MockMvcRequestSpecification request = given();
    // when:
    ResponseOptions response = given().spec(request)
      .queryParam("number", "2")
      .get("/validate/prime-number");
    // then:
    assertThat(response.statusCode()).isEqualTo(200);
    // and:
    String responseBody = response.getBody().asString();
    assertThat(responseBody).isEqualTo("Even");
```

Plugin Maven

Spring Cloud Contract met à disposition un plugin Maven qui offre 2 principaux objectifs :

- generateTests : Génère les classes de test validant la spécification
- generateStubs : Génère un artefact contenant la spécification ...
 qui pourra servir pour générer le MockServer

Tests Consommateur

```
@RunWith(SpringRunner.class)
@SpringBootTest(webEnvironment = SpringBootTest.WebEnvironment.MOCK)
@AutoConfigureMockMvc
@AutoConfigureJsonTesters
@AutoConfigureStubRunner(
  stubsMode = StubRunnerProperties.StubsMode.LOCAL,
  ids = "com.baeldung.spring.cloud:spring-cloud-contract-producer:+:stubs:8090")
public class BasicMathControllerIntegrationTest {
    @Autowired
    private MockMvc mockMvc;
    @Test
    public void given_WhenPassEvenNumberInQueryParam_ThenReturnEven()
      throws Exception {
        mockMvc.perform(MockMvcRequestBuilders.get("/calculate?number=2")
          .contentType(MediaType.APPLICATION_JSON))
          .andExpect(status().is0k())
          .andExpect(content().string("Even"));
```



Monitoring

Metriques CircuitBreaker

Tracing avec *Spring Cloud Sleuth*Centralisation des traces



Introduction

Pour autoriser la collecte de métrique de Resilence4J, il faut les starters :

org.springframework.boot:spring-boot-starter-actuator
io.github.resilience4j:resilience4j-micrometer

Les métriques sont typiquement envoyés via *Micrometer* sur des systèmes comme *InfluxDB* ou *Prometheus* puis visualisés avec des outils de visualisation tels que *Grafana*



Métriques exportés

resilience4j.circuitbreaker.state : L'état du circuit

resilience4j.circuitbreaker.failure.rate : La cadence d'erreur

resilience4j.circuitbreaker.slow.call.rate: La cadence d'appels lents

resilience4j.circuitbreaker.calls : Nombre total d'appels réussis, échoués ou ignorés

resilience4.circuitbreaker.not.permitted.calls : Le nombre total d'appels non autorisés



Envoi vers promotheus

Pour offrir le endpoint nécessaire à prometheus, il suffit d'ajouter la dépendance :

io.micrometer:micrometer-registry-prometheus

Et d'activer le endpoint actuator prometheus



Monitoring

Metriques CircuitBreaker Tracing avec Spring Cloud Sleuth Centralisation des logs



Introduction

Spring Cloud Sleuth permet d'ajouter dans les messages de logs des *ids* permettant de tracer un séquence d'appels de méthodes correspondant à une requête HTTP, le démarrage d'un job, une thread ...

 Il s'intègre sans effort avec Logback et SLF4J et utilise la librairie de tracing Brave .

Dans le cadre d'une architecture micro-services, Sleuth sert à tracer le cheminement d'une requête à travers tous les micro-services qu'elle a invoqué.



Vocabulaire

Sleuth définit 2 notions :

- Traces identifiant une requête unique ou le démarrage d'un job. Toutes les différentes étapes de traitement partageront le même traceld.
- Spans, identifie une étape de traitement. Une trace peut donc être composée de plusieurs spans. Sleuth ajoute un spanId pour chaque étape de traitement

En utilisant ces lds on peut facilement isoler les traces relatives à une requête particulière.

Mise en place

```
Dépendance:
    org.springframework.cloud:spring-cloud-starter-sleuth

Impact sur les traces de l'appli:

2017-01-10 22:36:38.254 INFO

[SpringApplicationName, 4e30f7340b3fb631, 4e30f7340b3fb631, false] 12516
--- [nio-8080-exec-1] c.b.spring.session.SleuthController: Hello Sleuth

2017-01-10 22:51:48.664 INFO

[SpringApplicationName, 4e30f7340b3fb631, 4e30f7340b3fb631, false] 12516
--- [nio-8080-exec-1] c.baeldung.spring.session.SleuthService: Doing some work

[nom application, traceld, spanId, export]
- Nom application: Propriété spring.application.name.
```

- <u>Traceld</u> : id affecté à une requête, un job.
- <u>SpanId</u>: Identifie une unité de travail. Pour la première étape *TraceId=SpanId*.
- Export : Booléen qui indique si cette trace a été exporté vers un agrégateur comme Zipkin.

Ajout manuel de spans

Il est possible de manuellement créer des nouveaux spans dans une application.

```
@Autowired
private Tracer tracer;
// ...
public void doSomeWorkNewSpan() throws InterruptedException {
    logger.info("I'm in the original span");

    Span newSpan = tracer.newTrace().name("newSpan").start();
    try (SpanInScope ws = tracer.withSpanInScope(newSpan.start())) {
        Thread.sleep(1000L);
        logger.info("I'm in the new span doing some cool work that needs its own span");
    } finally {
        newSpan.finish();
    }
    logger.info("I'm in the original span");
}
```

Ajout manuel de spans (2)

Les traces deviennent.

```
2017-01-11 21:07:54.924
 INFO [SpringApplicationName, 9cdebbffe8bbbade, 9cdebbffe8bbbade, false] 12516
  --- [nio-8080-exec-6] c.b.spring.session.SleuthController
                                                                  : New Span
2017-01-11 21:07:54.924
 INFO [SpringApplicationName, 9cdebbffe8bbbade, 9cdebbffe8bbbade, false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService
 I'm in the original span
2017-01-11 21:07:55.924
 INFO [SpringApplicationName, 9cdebbffe8bbbade, 1e706f252a0ee9c2, false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService
 I'm in the new span doing some cool work that needs its own span
2017-01-11 21:07:55.924
 INFO [SpringApplicationName, 9cdebbffe8bbbade, 9cdebbffe8bbbade, false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService
 I'm in the original span
```



Zipkin est un projet open-source qui permet de recevoir et visualiser des traces.

Il est disponible:

- Sous forme de jar
- Ou d'image docker openzipkin/zipkin




Architecture

Chaque micro-service exporte ses spans vers le serveur *Zipkin*

Le serveur les stocke et propose une interface permettant de consulter les traces

Interface Zipkin





Configuration des services

Dans un contexte SpringCloud, chaque service doit ajouter la dépendance : org.springframework.cloud:spring-cloud-starter-zipkin

Et doit déclarer dans sa configuration l'URL Zipkin

```
spring:
  zipkin:
  base-url: http://zipkin:9411/
  sleuth:
    sampler:
    probability: 1
```



Monitoring

Metriques CircuitBreaker Tracing avec Spring Cloud Sleuth Centralisation des logs



Gestion des logs

Une préconisation pour le développement des microservices est qu'il ne ne se préoccupe jamais du routage ou du stockage de son flux de sortie.

=> Ne doit pas tenter d'écrire ou de gérer des fichiers journaux.

Au lieu de cela, chaque micro-service écrit son flux d'événements sur stdout.

En production, chaque flux est capturé par l'environnement d'exécution, assemblé avec tous les autres flux de la stack et acheminé vers une ou plusieurs destinations finales pour visualisation et archivage à long terme.

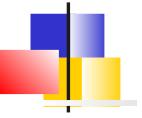
Elastic Stack

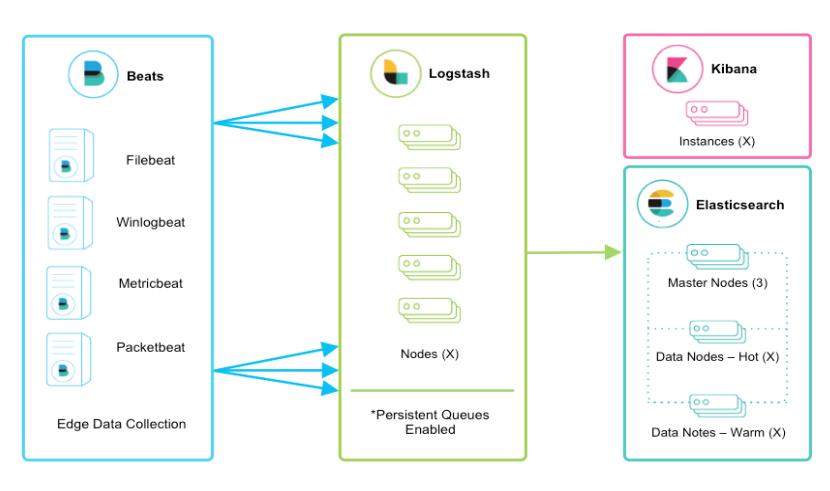
Une des solutions les plus courantes pour centraliser, visualiser et analyser les traces est la solution ElasticStack

Cette pile est constituée de :

- Beats: convoyeurs de données installés avec les applications SpringBoot
- Logstash : Micro-service chargé de normaliser les différentes traces et de les soumettre à un ElasticSearch
- ElasticSearch : Micro-service permettant d'indexer les traces et offrant des fonctionnalités de recherche et d'agrégation
- Kibana: Application front-end offrant une UI pour l'analyse

Architecture en cluster







Messaging

Communication asynchrone

Exemple: Saga Pattern Spring Cloud Stream Spring Cloud Data Flow



Introduction

Les communications asynchrones entre les micro-services apportent plusieurs avantages :

- Découplage du producteur et consommateur de message
- Scaling et montée en charge
- Implémentation de patterns de micro-services
 Saga^{1,} Event-sourcing Pattern²

Des difficultés :

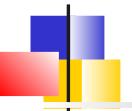
- Gestion de l'asynchronisme
- Mise en place et exploitation d'un message broker
- 1. https://microservices.io/patterns/data/saga.html
- 2. http://microservices.io/patterns/data/event-sourcing.html




Messaging Pattern

Messaging Pattern¹: Un client invoque un service en utilisant une messagerie asynchrone

- Le pattern messaging fait souvent intervenir un message broker
- Un client effectue une requête en postant un message asynchrone
- Optionnellement, il s'attend à recevoir une réponse



Architecture



Message

Un message est constitué d'entêtes (ensemble de clés-valeurs) et d'un corps de message

On distingue 3 types de messages :

- Document : Un message générique ne contenant que des données Le récepteur décide comment l'interpréter
- Commande : Un message spécifiant l'action à invoquer et ses paramètres d'entrée
- Événement : Un message indiquant que quelque chose vient de se passer. Souvent un événement métier



Canaux de messages

2 types de canaux :

 Point-to-point : Le canal délivre le message à un des consommateurs lisant le canal.

Ex: Envoie d'un message commande

 PubAndSub : Le canal délivre le message à tous les consommateurs attachés (les abonnés)



Styles d'interaction

Tous les styles d'interactions sont supportés :

- Requête/Réponse synchrone.
 Le client attend la réponse
- Requête/Réponse asynchrone
 Le client est notifié lorsque la réponse arrive
- One way notification
 Le client n'attent pas de réponse
- Publish and Subscribe :
 Le producteur n'attend pas de réponse
- Publish et réponse asynchrones
 Le producteur est notifié lorsque les réponses arrivent



Spécification de l'API

La spécification consiste à définir

- Les noms des canaux
- Les types de messages et leur format.
 (Typiquement JSON)

Par contre à la différence de REST et OpenAPI pas de standard



Message Broker

Un message broker est un intermédiaire par lequel tous les mesages transitent

- L'émetteur n'a pas besoin de connaître l'emplacement réseau du récepteur
- Le message broker bufferise les messages

Implémentations courantes :

- ActiveMQ
- RabbitMQ
- Kafka
- AWS Kinesis



Facteurs de choix (1°

Langages de programmation supportés C'est mieux si il en supporte plusieurs

Standard de messaging supportés AMQP, STOMP ou propriétaire

Ordre des messages

Le message broker préserve t il l'ordre d'émission des messages

Garanties de livraison

At-most-Once, At-Least-Once ou Exactly-Once

Persistance

Les messages survivent-ils au crash?



Facteurs de choix (2)

<u>Durabilité</u>

Si un consommateur se reconnecte au broker, récupère t il les messages qui ont été envoyés entre temps

Scalabilité

Le broker est-il scalable ?

Latence

Quel est le délai entre l'émission et la réception ?

Consommation concurrente

Le message broker permet-il que les messages d'un canaux soient entre des récepteurs répliqués



Offre Spring

Starter messaging pur:

RabbitMQ, ActiveMQ, Kafka, ActiveMQ
 Artemis, Solace PubSub

Pipeline de traitement d'évènements :

Kafka Stream

Architecture micro-services event-driven

- Spring Cloud Stream
- Spring Data Flow



Messaging

Communication asynchrone

Exemple: Saga Pattern

Spring Cloud Stream

Spring Cloud Data Flow



Exemple: Gestion des transactions avec Saga


<u>Problème</u>: Comment implémenter des transactions qui englobent plusieurs services, i.e des opérations qui mettent à jour des données dispersées dans plusieurs services

<u>Solution</u>: Une **saga**, séquence de transactions locales basée sur des messages. Cette séquence présente les propriétés ACD (Atomicité, Cohérence, Durabilité) mais la propriété d'isolation n'est pas respectée¹.

1. En conséquence, l'application doit utiliser des contre-mesures (opération de compensation) pour empêcher ou réduire l'impact des anomalies de concurrence.



Exemple





Structure des transactions

Une saga consiste en une séquences de 3 types de transactions :

- Transaction compensable : peuvent potentiellement être annulées à l'aide d'une transaction compensatoire
- Transaction pivot : Si elle est validée, la saga s'exécutera jusqu'à la fin.
 Une transaction pivot peut être une transaction qui n'est ni compensable, ni réessayable. Cela peut s'agir de la dernière transaction compensable ou de la première transaction réessayable
- Transaction réessayable : Elles suivent la transaction pivot transaction et sont assurés de réussir



Exemple

Etape	Service	Transaction	Tr. de compensation
S			
1	Order Service	createOrder()	rejectOrder()
2	Consumer Service	verifyConsumerDetail()	-
3	KitchenService	createTicket()	rejectTicket()
4	AccouningService	authorizeCreditCard()	
5	RestaurantService	ackRestaurantOrder()	
6	OrderService	approveOrder()	

- 1,2,3 : Sont des transactions compensables
- 2 : Une opération de lecture n'a pas besoin de compensation
- 4 : Transaction pivot. Si elle réussit, createOrder doit aller jusqu'à la fin
- 5,6 : Transaction réessayable, jusqu'à ce qu'elles réussissent




Implémentation


Il existe 2 façons de coordonner une saga:

- chorégraphie les participants à la saga échangent des événements
- orchestration un orchestrateur centralisé utilise une messagerie asynchrone pour piloter les participants




Chorégraphie





Orchestration






Exemple spring-kafka

Envoi de message

```
@Value("${app.my-channel}")
String PAYMENT REQUEST CHANNEL;
@Autowired
KafkaTemplate<Long, DomainEvent> kafkaOrderTemplate;
public Order doService(Domain model) {
  DomainEvent event = new DomainEvent(model);
  kafkaOrderTemplate.send(ORDER STATUS CHANNEL, event);
Réception de message :
@KafkaListener(topics = "#{'${app.my-channel}'}", id = "oneHandler")
public void handleEvent(DomainEvent domainEvent) {
```



Messaging

Communication asynchrone Exemple : Saga Pattern Spring Cloud Stream Spring Cloud Data Flow



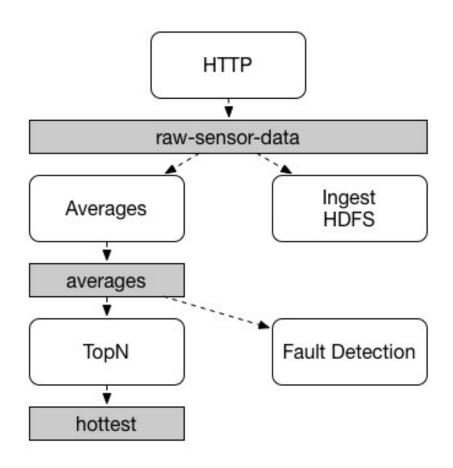
Introduction

Spring Cloud Stream est le framework pour construire des applications microservice pilotées par des flux de messages.

- Utilise Spring Boot et Spring Integration pour la connectivité avec les messages brokers
- Repose sur les concepts de
 - topic persistant (publish/subscribe),
 - groupe de consommateurs
 - et de partitions



Exemple d'architecture





Utilisation

Starter: spring-cloud-stream

- Une ou plusieurs interfaces déclarant les canaux d'entrée et/ou de sortie
- @EnableBinding pour auto-configurer la connectivité des canaux avec le système de messagerie sous-jacent
- @StreamListener sur les méthodes voulant réagir à un flux
- Utilisation de l'API MessageChannel pour envoyer des messages

Exemple

```
@SpringBootApplication
@EnableBinding(Sink.class)
public class VoteRecordingSinkApplication {
  public static void main(String[] args) {
    SpringApplication.run(VoteRecordingSinkApplication.class, args);
  @StreamListener(Sink.INPUT)
  public void processVote(Vote vote) {
      votingService.recordVote(vote);
public interface Sink {
  String INPUT = "input";
  @Input(Sink.INPUT)
  SubscribableChannel input();
```



Concepts principaux


Les applications Cloud Stream se basent sur la présence d'un middleware neutre

Elles communiquent avec l'extérieur à travers des canaux (channels) d'entrée /sortie

Les canaux sont associés à des systèmes de messagerie (Kafka, RabbitMQ, ...) à travers des **binders spécifiques** à l'implémentation



Architecture





Publish & Subscribe

La communication entre applications suit un modèle *publish-subscribe*, les données sont alors diffusées à travers des topics partagés

La notion de **groupe de consommateurs** permet la scalabilité

Un message n'est reçu que par un seul membre du groupe

Par défaut, les topics sont durables.

Ce qui garantit la livraison des messages mêmes si les consommateurs sont arrêtés au moment de l'émission



Partitionnement

Spring Cloud Stream supporte le partitionnement des messages

Cela garantit que les messages identifiés par une caractéristique commune seront traités par la même instance de consommateur (Modèle stateful)



- @EnableBinding configure la connectivité
- **@Input** et **@Output** dans des interfaces définissent les canaux d'entrée.

Spring fournit 3 interfaces. *Source :* 1 seul canal de sortie, *Sink* 1 seul canal d'entrée et *Processor* les 2 types de canaux

Les implémentations de ces interfaces ou directement les canaux peuvent être **injectées** permettant l'envoi de message par exemple

Les annotations de Spring Integration ou @StreamListener (plus simple) peuvent être utilisées pour traiter les messages

Également du support pour des API reactive, ou l'agrégation d'application (plus de messagerie)



Messaging

Saga Pattern Spring Cloud Stream Spring Cloud Data Flow



Introduction

Domaine d'usage : Traitement de données par flux et traitement par lots basé sur des Microservices pour Cloud Foundry et Kubernetes.

Spring Cloud Data Flow fournit des outils permettant de créer des pipelines des traitement de données par lots.

 Les pipelines sont constitués d'applications Spring Boot, construites à l'aide de Spring Cloud Stream ou Spring Cloud Task.

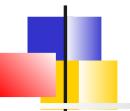
Cas d'utilisation : ETL, import/export, traitement en continu d'évènements, analyse prédictive, ...



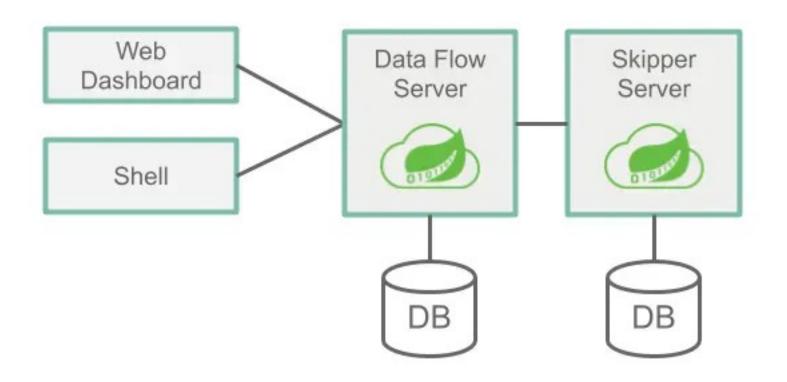
Architecture

L'architecture de l'offre est composée de 2 composants :

- Data Flow Serveur : Contient la bibliothèque des micro-services de base et les pipelines de traitement
- Skipper Serveur : S'occupe des déploiements dans les environnements Cloud à partir de repository d'artefact



Architecture





DataFlow Serveur

- Parse, valide, aide à l'édition et stocke les définitions de flux et de travaux batch exprimées via un DSL
- Stocke les artefacts .jar ou images docker
- Définit les propriétés de configuration des artefacts (flux d'entrées/sorties flux, propriétés de déploiements telles que le nombre initial d'instances, les besoins en mémoire et le partitionnement des données).
- Démarre les déploiements de travaux batch et délègue la planification des travaux
- Délégation du déploiement de flux à Skipper.
- Offre une historique d'exécution et un audit

Skipper serveur

Déploiement de flux sur une ou plusieurs plates-formes.

Mise à niveau et restauration du flux sur une ou plusieurs plates-formes à l'aide d'une stratégie de mise à jour blue/green basée sur une machine d'état.

Stockage de l'historique du fichier manifeste de chaque flux (qui représente la description finale des applications déployées).



Sécurité

Introduction

Rappels *oAuth2/OpenID*Spring Security et *oAuth2*



Introduction

Plusieurs approches pour sécuriser une architecture micro-services :

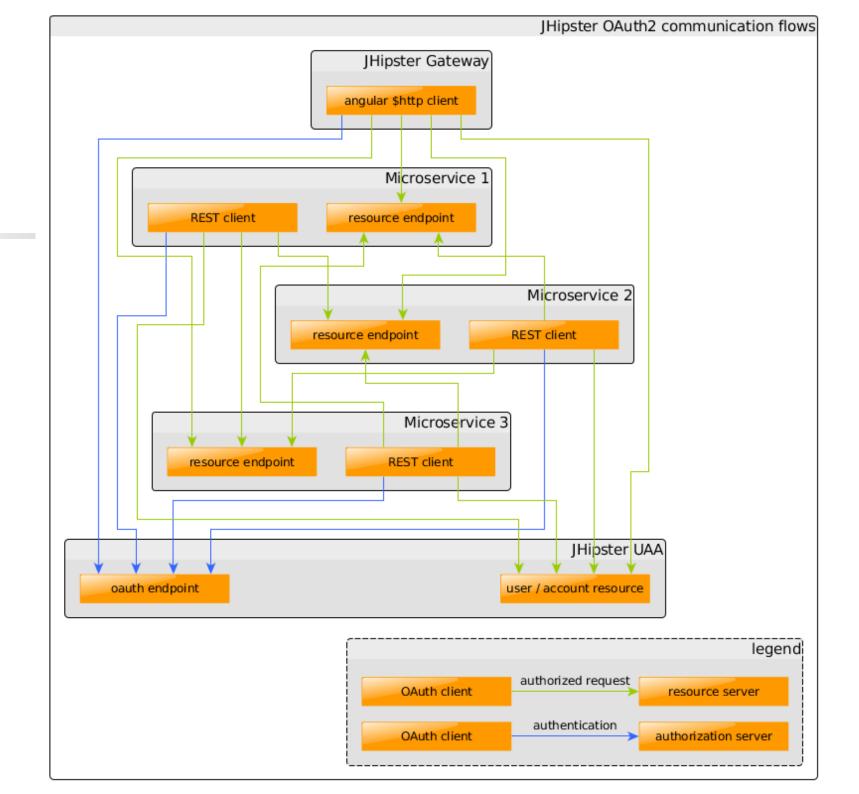
- N'implémenter la sécurité qu'au niveau du proxy. Les micro-services back-end ne sont pas protégés
- Chaque micro-service a sa propre politique de sécurité. Un jeton d'accès relayé permet de vérifier les ACLs
- Chaque micro-service a sa propre politique de sécurité et chaque micro-service demande son propre jeton pour effectuer ses appels REST



Modèle micro-service

Dans un modèle micro-service, les différents micro-services peuvent être clients et/ou serveur de ressources oAuth.

L'identité d'une requête et ses permissions peuvent varier en fonction des micro-services qu'elle traverse





Sécurité

Introduction Rappels oAuth2/OpenID Spring Security et oAuth2



Rôles du protocole

Le **Client** est l'application qui essaie d'accéder au compte utilisateur. Elle a besoin d'obtenir une permission de l'utilisateur pour le faire.

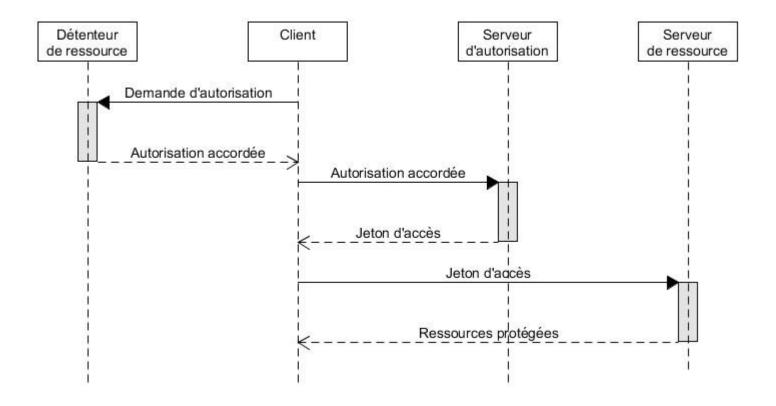
Le **serveur de ressources** est l'API utilisée pour accéder aux ressources protégées

Le **serveur d'autorisation** est le serveur qui autorise un client a accéder aux ressources en lui fournissant un jeton. Il peut demander l'approbation de l'utilisateur

L'utilisateur est la personne qui donne accès à certaines parties de son compte

Rq: Un participant du protocole peut jouer plusieurs rôles







Scénario

- 1. Pré-enregistrer le client auprès du service d'autorisation (=> client ID et un secret)
- Obtenir l'autorisation de l'utilisateur.
 (4 types de grant)
- 3. Obtention du token (date d'expiration)
- 4. Appel de l'API pour obtenir les informations voulues en utilisant le token
- 5. Validation du token par le serveur de ressource



Tokens

Les Tokens sont des chaînes de caractères aléatoire générées par le serveur d'autorisation

Les jetons sont ensuite présents dans les requêtes HTTP et contiennent des informations sensibles => HTTPS

Il y a 2 types de token

- Le jeton d'accès: Il a une durée de vie limité.
- Le Refresh Token: Délivré avec le jeton d'accès.
 Il est renvoyer au serveur d'autorisation pour renouveler le jeton d'accès lorsqu'il a expiré

Enregistrement du client

Le protocole ne définit pas comment l'enregistrement du client doit se faire mais définit les paramètres d'échange.

Le client doit fournir:

- Application Name: Le nom de l'application
- Redirect URLs: Les URLs du client pour recevoir le code d'autorisation et le jeton d'accès
- **Grant Types**: Les types d'autorisations utilisables par le client
- Javascript Origin (optionnel): Le host autorisé à accéder aux ressources via XMLHttpRequest

Le serveur répond avec :

- Client Id:
- Client Secret: Clé devant rester confidentielle



Périmètre d'accès

Le **scope** est un paramètre utilisé pour limiter les droits d'accès d'un client

Le serveur d'autorisation définit les scopes disponibles

Le client peut préciser le *scope* qu'il veut utiliser lors de l'accès au serveur d'autorisation

OAuth2 Grant Type

Différents moyens afin que l'utilisateur donne son accord : les **grant types**

- authorization code :
 - L'utilisateur est dirigé vers le serveur d'autorisation
 - L'utilisateur consent sur le serveur d'autorisation
 - Il est redirigé vers le client avec un code d'autorisation
 - Le client utilise le code pour obtenir le jeton
- implicit : Jeton fourni directement. Certains serveurs interdisent de mode
- password : Le client fournit les crédentiels de l'utilisateur
- client credentials : Le client est l'utilisateur
- device code :



Usage du jeton

Le jeton est passé à travers 2 moyens :

- Les paramètres HTTP. (Les jetons apparaissent dans les traces du serveur)
- L'entête d'Authorization

GET /profile HTTP/1.1
Host: api.example.com

Authorization: Bearer MzJmNDc3M2VjMmQzN

http://www.bubblecode.net/en/2016/01/22/understanding-oauth2/



Validation du jeton

Lors de la réception du jeton, le serveur de ressource doit valider l'authenticité du jeton et extraire ses informations différentes techniques sont possibles

- Appel REST vers le serveur d'autorisation
- Utilisation d'un support persistant partagé (ex. JdbcStore)
- Utilisation de JWT et validation via clé privé ou clé publique

JWT

JSON Web Token (JWT) est un standard ouvert défini dans la RFC 75191.

Il permet l'échange sécurisé de jetons (tokens) entre plusieurs parties.

La sécurité consiste en la vérification de l'intégrité des données à l'aide d'une signature numérique. (HMAC ou RSA).

Dans le cadre d'une application REST SpringBoot, le jeton contient les informations d'authentification d'un user : Subject + Rôles

Différentes implémentations existent en Java (io.jsonwebtoken, ...) ou le starter **spring-security-oauth2-jose**



Sécurité

Introduction Rappels oAuth2/OpenID Spring Security et oAuth2



Apport de SpringBoot

Le support de oAuth via Spring a été revu :

 Le projet spring-security-oauth2 a été déprécié et remplacé par SpringSecurity 5.

Voir:

https://github.com/spring-projects/spring-security/wiki/OAuth-2.0-Migration-Guide

Il n'y a plus de support pour un serveur d'autorisation

3 starters sont désormais fourni :

- OAuth2 Client: Intégration pour utiliser un login oAuth2 fournit par Google, Github, Facebook, ...
- OAuth2 Resource server : Application permettant de définir des ACLs par rapport aux scopes client et aux rôles contenu dans des jetons oAuth
- Okta: Pour travailler avec le fournisseur oAuth Okta



Solutions pour un serveur d'autorisation

- Utiliser un produit autonome
- Un projet Spring pour un serveur d'autorisation est en cours :

https://github.com/spring-projects-experimental/spring-authorization-server

 Une autre alternative est d'embarquer une solution oAuth comme KeyCloak dans un application SpringBoot Voir par exemple :

https://www.baeldung.com/keycloak-embedded-inspring-boot-app



Serveur de ressources

Dépendance :

```
<dependency>
    <groupId>org.springframework.boot</groupId>
     <artifactId>spring-boot-starter-oauth2-resource-server</artifactId>
</dependency>
```

Le serveur de ressources doit vérifier la signature du jeton pour s'assurer que les données n'ont pas été modifiées.

- jwk-set-uri contient la clé publique que le serveur peut utiliser pour la vérification
- issuer-uri pointe vers l'URI du serveur d'autorisation de base, qui peut également être utilisé pour localiser le endpoint fournissant la clé publique



Exemple application.yml

```
server:
  port: 8081
  servlet:
    context-path: /resource-server

spring:
  security:
    oauth2:
    resourceserver:
    jwt:
        issuer-uri: http://keycloak:8083/auth/realms/myRealm
        jwk-set-uri: http://keycloak:8083/auth/realms/myRealm/protocol/openid-connect/certs
```

Configuration typique SpringBoot

@Configuration

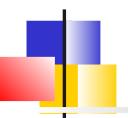
```
public class SecurityConfig extends WebSecurityConfigurerAdapter {
    @Override
    protected void configure(HttpSecurity http) throws Exception {
        http.cors()
            .and()
            .authorizeRequests()
              .antMatchers(HttpMethod.GET, "/user/info", "/api/foos/**")
                .hasAuthority("SCOPE_read")
              .antMatchers(HttpMethod.POST, "/api/foos")
                .hasAuthority("SCOPE_write")
              .anyRequest()
                .authenticated()
            .and()
              .oauth2ResourceServer()
                .jwt();
```



Personnalisations

Différents aspects de la configuration par défaut peuvent être personnalisées :

- Revendications personnalisées dans le jeton
- Charger la clé à partir d'un KeyStore




Déploiement

Alternatives

Support pour docker Spring Cloud Kubernetes



Evolution des infrastructures




Contraintes

- L'environnement de production doit implémenter 4 capacités clés:
 - Interface de gestion des services: Créer, mettre à jour et configurer des services. Idéalement une API REST invoquée par des commandes en ligne commande et GUI.
 - Gestion des services à l'exécution: tente de garantir que le nombre souhaité d'instances de service s'exécute à tout moment.
 - Surveillance/Observabilité : Fournit aux développeurs un aperçu et une vision détaillée aperçu de ce que font leurs services en production
 - Routage des requêtes : Les requêtes des utilisateurs sont acheminées vers les services.

٠.

Environnement de production





Alternatives de déploiement

Différentes options de packaging pour le déploiement existent :

- Packages spécifiques à un langage : Un jar, war, zip Javascript, ...
- Machines virtuelles qui incluent la pile technologique (OS, JVM, ...)
- Containers
- Serverless Deployment



Inconvénients des packages spécifique à un langage

Manque d'encapsulation de la pile technologique. => l'équipe Ops doit connaître précisément les besoins de provisionnement des machines

Aucune possibilité de limiter les ressources consommées par une instance de service.

=> Une instance de service peut consommer toutes les ressources CPU, Mémoire de la machine

Manque d'isolation lors de l'exécution de plusieurs instances de service sur la même machine.

Pas de support pour le placement des instances sur les ressources disponibles



Inconvénients des VMs

Utilisation peu efficace des ressources => Chaque service a la surcharge d'une machine entière, souvent surdimensionnée par rapport au service lui-même

Déploiements relativement lents

=> Construction longue car taille d'image très volumineuse, démarrage de service long

Surcharge d'administration système

=> Patch systèmes à appliquer



Déploiement

Alternatives Support pour docker Spring Cloud Kubernetes

Dockerfile basique

Il est facile de construire un jar exécutable d'une application Spring Boot via les plugins Maven/Gradle

Un Dockerfile basique est alors :

```
FROM openjdk:8-jdk-alpine
VOLUME /tmp
ARG JAR_FILE
COPY ${JAR_FILE} app.jar
ENTRYPOINT ["java","-jar","/app.jar"]
```

Pour le construire :

```
docker build --build-arg JAR_FILE=target/*.jar -t myorg/myapp .
```

Pour l'exécuter :

```
docker run -p 8080:8080 myorg/myapp
```

Dockerfile + sophistiqué

Pour pouvoir passer des variables d'environnement et des propriétés SpringBoot au démarrage

On peut alors démarrer l'image via :

```
docker run -p 9000:9000 -e "JAVA_OPTS=-Ddebug -Xmx128m"
myorg/myapp --server.port=9000
```



Taille des images

- Les images *alpine/slim* sont plus petites que les images standard *openjdk* de Dockerhub.
- 20 mB sont économisés en utilisant une **jre** plutôt qu'une jdk
- On peut également essayer d'utiliser *jlink* (à partir de Java11) pour se créer une image sur mesure en ne sélectionnant que les modules Java utilisés
 - Attention pas de cache, si tous les services Java utilisent des JRE personnalisés



Couches Docker

Un jar Spring Boot a naturellement des "couches" Docker en raison de son packaging.

On peut isoler dans une couche Docker les dépendances externes, ainsi tous les services utilisant les mêmes dépendances pourront se construire et se lancer plus vite.

(Cache des container runtime)

Dockerfile à couche

```
$ mkdir target/dependency
$ (cd target/dependency; jar -xf ../*.jar)
$ docker build -t myorg/myapp .
FROM openjdk:8-jdk-alpine
VOLUME /tmp
ARG DEPENDENCY=target/dependency
COPY ${DEPENDENCY}/BOOT-INF/lib /app/lib
COPY ${DEPENDENCY}/META-INF /app/META-INF
COPY ${DEPENDENCY}/BOOT-INF/classes /app
ENTRYPOINT ["java","-cp","app:app/lib/*","hello.Application"]
```

Accélérateur de démarrage

- Quelques astuces pour accélérer le démarrage du service :
 - Améliorer le scan du classpath avec spring-context-indexer¹
 - Limiter actuator à ce qui est vraiment nécessaire
 - SB 2.1+ et S 5.1+
 - Spécifier le chemin vers le fichier de config : spring.config.location
 - Désactiver JMX spring.jmx.enabled=false
 - Exécuter la JVM avec -noverify
 - Pour Java8, également -XX:+UnlockExperimentalVMOptions
 -XX:+UseCGroupMemoryLimitForHeap



Utilisateur dédié

Les services doivent s'exécuter avec un utilisateur non root

FROM openjdk:8-jdk-alpine

RUN addgroup -S demo && adduser -S demo -G demo USFR demo

Spring-Boot Plugin

Depuis la 2.3, Spring boot fournit des plugins Maven/Gradle capables de construire les images

- \$./mvnw spring-boot:build-image
- \$./gradlew bootBuildImage
 - Plus besoin de Dockerfile
 - Nécessite que le démon Docker s'exécute
 - Par défaut le nom de l'image est :
 docker.io/<group>/<artifact>: latest
 - Utilise les Cloud Native Buildpacks



Spotify Maven Plugin nécessite un *Dockerfile* et ajoute des objectifs permettant d'automatiser la construction de l'image dans le build Maven

Palantir Gradle est capable de générer un Dockerfile ou d'utiliser celui que l'on fournit

Jkube (Eclipse) propose un plugin Maven permettant la construction d'image

Jib est également un projet Google qui permet de construire des images optimisées (Docker ou OCI) sans Docker installé



BuildPacks

Cloud Foundry utilise les **buildbacks** qui transforment automatiquement le code source en conteneur¹

- Les développeurs n'ont pas besoin de se soucier des détails sur la construction du conteneur.
- Les buildpacks ont de nombreuses fonctionnalités pour la mise en cache des résultats de construction et des dépendances
 Souvent un buildpack s'exécute beaucoup plus rapidement qu'un docker natif



Sortie standard d'un buildpack

```
$ pack build myorg/myapp --builder=cloudfoundry/cnb:bionic --path=.
2018/11/07 09:54:48 Pulling builder image 'cloudfoundry/cnb:bionic' (use --no-pull flag to skip this step)
2018/11/07 09:54:49 Selected run image 'packs/run' from stack 'io.buildpacks.stacks.bionic'
2018/11/07 09:54:49 Pulling run image 'packs/run' (use --no-pull flag to skip this step)
*** DETECTING:
2018/11/07 09:54:52 Group: Cloud Foundry Open|DK Buildpack: pass | Cloud Foundry Build System Buildpack: pass | Cloud
 Foundry JVM Application Buildpack: pass
*** ANALYZING: Reading information from previous image for possible re-use
*** BUILDING:
----> Cloud Foundry OpenIDK Buildpack 1.0.0-BUILD-SNAPSHOT
----> OpenJDK JDK 1.8.192: Reusing cached dependency
----> OpenJDK JRE 1.8.192: Reusing cached launch layer
----> Cloud Foundry Build System Buildpack 1.0.0-BUILD-SNAPSHOT
----> Using Mayen wrapper
    Linking Maven Cache to /home/pack/.m2
----> Building application
    Running /workspace/app/mvnw -Dmaven.test.skip=true package
---> Running in e6c4a94240c2
---> 4f3a96a4f38c
---> 4f3a96a4f38c
Successfully built 4f3a96a4f38c
Successfully tagged myorg/myapp:latest
```



KNative

KNative est un projet initié par Google qui a pour put de fournir une infrastructure ServerLess au dessus d'un cluster Kubernetes

Comme les *buildpacks*, il est capable de construire les conteneurs à partir du code source.



Déploiement

Alternatives Support pour docker Spring Cloud Kubernetes



Alternatives

Différentes alternatives pour déployer sur un cluster Kubernetes :

- Utiliser les descripteurs natifs et le client kubectl
- Utiliser les packages *Helm* https://helm.sh/
- S'équiper d'un outil de IAAS tel que *Terraform* https://www.terraform.io/

Toutes ces alternatives nécessitent d'avoir publier les images des conteneurs dans un dépôt.

Ex: DockerHub

Exemple descripteur natif

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: delivery-service
  namespace: default
spec:
  replicas: 2
  selector:
    matchLabels:
      name: delivery-service
  template:
    metadata:
      labels:
        name: delivery-service
    spec:
      containers:
      - name: delivery-service
        image: dthibau/delivery-service:1.0.9
        imagePullPolicy: Always
kubectl apply -f delivery-service.yml
```



Pour adapter la configuration à l'environnement de production, on peut s'appuyer :

- Sur des variables d'environnement
- Sur des arguments de démarrage du conteneur
- Sur le service de ConfigMag offerte par Kubernetes

Exemple

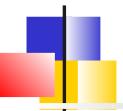
```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: delivery-service
  namespace: default
spec:
  replicas: 2
  selector:
    matchLabels:
      name: delivery-service
  template:
    metadata:
      labels:
        name: delivery-service
    spec:
      containers:
      - name: delivery-service
        env:
          - name: SPRING_PROFILES_ACTIVE
            value: prod, swagger
          - name: SPRING_DATASOURCE_URL
            valueFrom:
              configMapKeyRef:
                name: postgres-config
                key: POSTGRES_URL
        image: dthibau/delivery-service:1.0.9
        imagePullPolicy: Always
```

Spring Cloud Kubernetes

Spring Cloud Kubernetes est un projet dont l'objectif est de faciliter le déploiement de microservices SpringBoot vers Kubernetes

Il fournit des implémentations des interfaces de Spring Cloud Commons qui utilisent les services natifs de Kubernetes :

- @EnableDiscoveryClient
- Les objets PropertySource configurés via ConfigMaps
- Équilibrage de charge côté client via Netflix Ribbon (En cours de dépréciation)



Annexes



Alternative Consul



Alternative Consul

Un autre alternative aux outils Netflix est possible : *Consul*

Le produit *Consul* permet les 2 services de discovery et de configuration

Il est facilement intégrable dans SpringCloud



Consul vs Eureka (1)

Eureka est uniquement un service de discovery. L'architecture client/server, est en général constituée :

- d'un ensemble de serveurs Eureka (1 par datacenter).
- De clients avec un SDK embarqué pour s'enregistrer et découvrir les services



Consul vs Eureka (2)

Consul propose plus de fonctionnalités :

- Vérification de la santé plus riche (TCP, HTTP, Nagios/Sensu ou TTL comme Eureka)
- Stockage de paires clé/valeurs (config) et réplication d'état via le protocole Raft
- Prise en compte de plusieurs datacenter

Consul nécessite un serveur dans chaque datacenter et un agent sur chaque client.

L'agent permet aux applications d'être indépendantes de Consul. L'enregistrement s'effectue par des fichiers de configuration et la découverte via DNS ou par des load balancer.

Mise en place - discovery

Installation de Consul : Serveurs + agent pour chaque micro-services

```
Ajout de starter: spring-cloud-starter-consul-discovery
```

Configuration:

```
spring:
   cloud:
    consul:
     host: localhost
     port: 8500
     discovery:
        healthCheckPath: ${management.server.servlet.context-path}/health
        healthCheckInterval: 15s
```

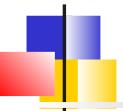
Mise en place - configuration

Installation de Consul : Serveurs + agent pour chaque micro-services

```
Ajout de starter: spring-cloud-starter-consul-config
```

Configuration:

```
spring:
   cloud:
   consul:
    config:
       enabled: true
       prefix: configuration # Surveillance et rafraîchissement automatique
       defaultContext: apps
       profileSeparator: '::'
```



Répartition de charge avec Ribbon



Introduction Ribbon

Ribbon (Netflix) est un répartiteur de charge côté client décentralisé intégré dans SpringCloud LoadBalancer.

Il permet de contrôler facilement les clients HTTP ou TCP.

Configuration Client Ribbon

Chaque répartiteur de charge est un ensemble de beans Spring collaborant pour contacter un serveur distant

L'ensemble a un **nom** fourni par le développeur (par exemple en utilisant l'annotation @FeignClient).

Spring Cloud crée les beans en utilisant une configuration (RibbonClientConfiguration).



Usage de Ribbon

spring-cloud-starter-ribbon

Ensuite, la configuration d'un client peut s'effectuer en utilisant des propriétés externes

```
<cli>ent>.ribbon.*
```

Ou programmatiquement

```
@Configuration
@RibbonClient(name = "foo", configuration =
   FooConfiguration.class)
public class TestConfiguration {
}
```

Exemple configuration

```
say-hello:
    ribbon:
        eureka:
            enabled: false
            listOfServers:
        localhost:8090,localhost:9092,localhost:9999
            ServerListRefreshInterval: 15000
```



Beans

La configuration crée un *ApplicationContext* pour chaque client nommé comprenant les beans suivants :

- *IClientConfig*, stocke la configuration
- *ILoadBalancer* : Le répartiteur
- ServerList : définit comment obtenir la liste des serveurs
- IRule décrivant la stratégie de répartition
- IPing : Donne la période des ping vers un serveur.

Répartition de charge et RestTemplate


```
@RibbonClient(name = "ribbonApp")
public class RibbonApp {
  @Bean
  @LoadBalanced
  RestTemplate restTemplate () {
    new RestTemplate()
  public void callMicroService() {
     // ribbonApp est le nom du client Ribbon
     Store store =
  restTemplate.getForObject("http://ribbonApp/store", Store.class);
```



Utilisation avec Eureka

Quand *Eureka* est utilisé en conjonction avec *Ribbon*

- ribbonServerList est surchargé avec une extension de DiscoveryEnabledNIWSServerList qui renseigne la liste de serveurs à partir d'Eureka
- Il remplace également l'interface IPing avec NIWSDiscoveryPing qui délègue à Eureka de déterminer si un serveur est UP



Pattern disjoncteur avec Hystrix



Introduction

Netflix a créé la librairie Hystrix qui implémente le pattern « *circuit breaker* »

- Une erreur dans un service bas niveau peut provoquer en cascade des erreurs jusqu'à l'utilisateur final.
- Lorsque des appels vers un service particulier atteint un seuil d'erreur (Par défaut, 20 erreurs en 5 secondes), le circuit s'ouvre et les appels ne sont plus effectués
- Un *fallback* peut être fourni par le développeur

Exemple de *Hystrix*

```
Starter : hystrix
@SpringBootApplication
@EnableCircuitBreaker
public class Application {
    public static void main(String[] args) {
        new SpringApplicationBuilder(Application.class).web(true).run(args);
@Component
public class StoreIntegration {
    @HystrixCommand(fallbackMethod = "defaultStores")
    public Object getStores(Map<String, Object> parameters) {
        //do stuff that might fail
    public Object defaultStores(Map<String, Object> parameters) {
        return /* something useful */;
}
```




Résilience avec Hystrix

Hystrix permet la résilience

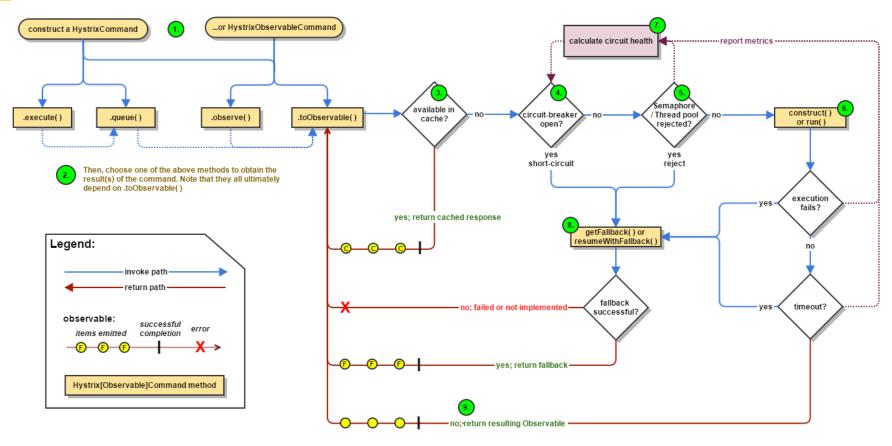
- Les appels sont effectués via un autre pool de threads
- Cela ne bloque pas la thread de service
- Peut implémenter des timeouts
- => Mécanisme de disjonction si un service ne répond pas ou répond mal
- Spring Boot permet une approche par annotation

Thread pools Hystrix









Ouverture/fermeture de circuit

La décision d'ouvrir le circuit (condition anormale) s'appuie

Sur un nombre d'erreurs dans une fenêtre de temps

La décision de fermer le circuit (retour aux conditions normales de fonctionnement) s'effectue ainsi :

- Après un certain temps ou le circuit est resté ouvert (circuitBreakerSleepWindowInMilliseconds)
- Une (seule) requête est tentée :
 - Si elle échoue le circuit reste ouvert
 - Si elle réussit le circuit redevient fermé.



L'annotation @HystrixCommand est fourni par la librairie "javanica" de Netflix.

Spring Cloud encapsule automatiquement les beans Spring annotés avec @HystrixCommand dans un proxy connecté au disjoncteur Hystrix.

Le disjoncteur calcule quand ouvrir ou fermer le circuit et quoi faire en cas d'erreur.



Indicateurs de santé

D'autre part, le statut des disjoncteurs sont exposés via l'endpoint /health

Il faut avoir activé *spring-actuator* dans les dépendances



Zuul



- **Zuul Routing** (également Netflix) permet d'automatiquement mapper des routes (URLs) vers des services enregistrés
- => Pas de configuration
- => Peut ajouter des filtres, etc.
- Il inclut également Ribbon et son répartiteur de charge
- Les règles de routage sont exprimées dans des langages JVM (essentiellement Java et Groovy)



Cas d'usage

Netflix utilisait Zuul pour :

- L'authentification et la sécurité
- Des tests de stress
- Canary Testing : Déploiement de nouvelles fonctionnalités sur un ensemble restreint d'utilisateurs
- Du délestage de charge
- Du routage dynamique
- De la migration de service
- Le traitement des réponses statiques
- Gestion active du trafic

Mise en place SpringBoot

Starter : zuul

```
@SpringBootApplication
@EnableDiscoveryClient
@EnableZuulProxy
public class ProxyApplication {

public static void main(String[] args) {
   SpringApplication.run(ProxyApplication.class, args);
}
```



Fonctionnement par défaut

Le proxy utilise *Ribbon* pour localiser un instance

Toutes les requêtes sont exécutées dans une commande *Hystrix*

- => Ainsi, les erreurs sont remontées dans les métriques Hystrix
- => Une fois que le circuit est ouvert, le proxy n'essaie plus de contacter le service.

Par défaut, un service nommé *users* reçoit les requêtes de /*users*

Configuration

```
# Tous les services sont ignorés à l'exception de users,
# on utilise par défaut Ribbon et Hystrix
zuul:
  ignoredServices: '*'
  routes:
    users: /myusers/**
# Alternative avec serviceId, Ribbon et Hystrix doivent être configurés manuellement
zuul:
  routes:
    users:
      path: /myusers/**
      serviceId: users service
# Ou, sans service de Discovery, Ribbon et Hystrix doivent être configurés manuellement
zuul:
  routes:
    users:
      path: /myusers/**
      url: http://example.com/users service
```

Cookies et entête HTTP


Il est possible de spécifier une liste des entêtes à ignorer.

zuul.ignoredHeaders

zuul.ignoreSecurityHeaders # entêtes
SpringSecurity

Les cookies pour le navigateur semblent venir tous du proxy.

=> Cela devient difficile de s'appuyer sur ces techniques à moins de partager les cookies dans tous les services de backend



Endpoint /routes

Si Spring Actuator est activé, un nouvelle endpoint est disponible : /routes

- Un *GET* affiche les routes configurées
- Un POST force un rafraîchissement des routes



Monitoring

Hystrix dashboard et Turbine

Flux Hystrix

Une application utilisant *Hystrix* peut générer un flux *json* permettant de surveiller les circuits

Le flux est généré si l'application est annotée avec @EnableCircuitBreaker

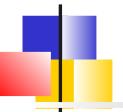
Avec la version 2.x il faut également la propriété :

management.endpoints.web.exposure.include: hystrix.stream

Le flux est alors accessible sur le endpoint /hystrix.stream

Tableau de bord Hystrix

Un flux *Hystrix* fourni par un micro-service peut être visualisé graphiquement par le tableau de bord Hystrix



/hystrix




Hystrix Dashboard

Cluster via	a Turbine	(defaul	t cluster): http://turbine-hostname:port/turbine.stream
	ustom cli	uster): h	ttp://turbine-hostname:port/turbine.stream?cluster=[clusterName] App: http://hystrix-app:port/hystrix.stream
Delay: 2000	ms	Title:	Example Hystrix App




Tableau de bord





Détails dashboard



Rolling 10 second counters with 1 second granularity

Successes 200,545 | 19 Thread timeouts
Short-circuited (rejected) 0 94 Thread-pool Rejections
Failures/Exceptions



Introduction Turbine

Hystrix Dashboard fournit des informations sur une seule application

Turbine permet d'agréger les informations de toutes les applications d'un cluster

Intégration de Turbine

Ajouter les dépendances :

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-turbine</artifactId>
</dependency>
```

Autoriser Turbine dans une application SpringBoot:

```
@SpringBootApplication
@EnableHystrixDashboard
@EnableTurbine
public class MonitorApplication {
   ...
}
```



Configuration

turbine:

clusterNameExpression: new String("default")

appConfig: MEMBERS-SERVICE, PROXY-SERVICE

Un flux turbine pour le cluster SAMPLE-HYSTRIX-AGGREGATE est disponible à


/turbine.stream?cluster=SAMPLE-HYSTRIX-AGGREGATE

La constitution du cluster est déduite d'Eureka, turbine récupère les flux Hystrix de toutes les instances et les agrège



Tableau de bord Turbine

Hystrix Stream: http://samplemonitor:8080/turbine.stream?cluster=SAMPLE-HYSTRIX-AGGREGATE





Spring Cloud Bus



Introduction

Spring Cloud Bus utilise un message broker pour faire communiquer les microservices.

L'usage principal est de diffuser les changements de configuration. Il joue alors le rôle d'un Actuator distribué.

Spring Cloud Bus supporte Apache Kafka, Redis, RabbitMQ



Objectifs

Sans Cloud Bus, la mise à jour de configuration d'un micro-service nécessite :

- Un redémarrage
- Ou si l'application contient Actuator, un appel individuel à l'URL /refresh

Spring Cloud Bus permet de propager les changements de configuration à tous les microservices via une seul opération



Config Server et WebHook

Au niveau du serveur de configuration, il est possible de rajouter une dépendance sur *spring-cloud-config-monitor* ainsi un endpoint */monitor* est disponible

Ce endpoint est capable de traiter les webhooks fourni par Github, Gitlab, ...

Lors de la réception d'un webhook, le serveur de config envoie un évènement sur le bus aux microservices qui ont changé.

L'événement provoque le rafraîchissement de la configuration



Rappels Docker




Introduction

- Plutôt que de virtualiser une machine complète, juste créer l'environnement d'exécution minimal pour fournir l'application, le service.
 - il n'est plus question de simuler le matériel et les services d'initialisation du système d'exploitation sont ignorés.
 - Seul le strict nécessaire réside dans le conteneur :
 l'application cible et quelques dépendances.
- L'apport d'une solution de containerisation est l' isolation d'un processus dans un système de fichiers à part entière



Containers vs VMs

Containers vs. VMs





Avantages de la containerisation

Rationalisation des ressources, à la différence de la virtualisation, seuls ce dont on se sert est chargé!

Chargement du container 50 fois plus rapide que le démarrage d'une VM

A ressources identiques, nb d'applications multipliées par 5 à 80.

Permet l'avènement des architecture microservices (application composée de nombreux services/container)



Impact sur le déploiement


Les développeurs et la PIC travaillent alors avec la même image de conteneur que celle utilisée en production.

 -=> Réduction considérable du risque de dysfonctionnements dû à une différence de configuration logicielle.

Il n'y a plus à proprement parler un déploiement brut sur un serveur mais plutôt l'utilisation d'orchestrateur de conteneurs.



Rappels docker architecture



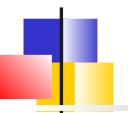
Commandes Docker

```
#Récupération d'une image
docker pull ubuntu
#Récupération et instanciation
docker run hello-world
#Mode interactif
docker run -i -t
#Visualiser les sortie standard d'un conteneur
docker logs <container id>
#Conteneurs en cours
docker ps
#Toutes les exécutions de conteneurs (même arrêt)
docker ps -a
#Lister les images
docker images
#Identifier les différences entre l'image et le conteneur
docker diff <container id>
#Committer les différences
docker commit <container id> <image name>
#Tagger une image d'un repository
docker tag <image_name>[:tag] <name>[:tag]
#Pousser vers un dépôt distant
docker push <image name>[:tag]
```

FROM ubuntu

Exemple DockerFile

```
MAINTAINER Kimbro Staken
RUN apt-get install -y software-properties-common python
RUN add-apt-repository ppa:chris-lea/node.js
RUN echo "deb http://us.archive.ubuntu.com/ubuntu/ precise universe" >>
 /etc/apt/sources.list
RUN apt-get update
RUN apt-get install -y nodejs
RUN mkdir /var/www
ADD app.js /var/www/app.js
EXPOSE 8080
CMD ["/usr/bin/node", "/var/www/app.js"]
docker build -t dthibau/myappli:latest
```



Communication entre machines

Chaque conteneur s'exécutant a sa propre interface réseau (gérée par Docker)

Par défaut, Il est isolé

- De la machine hôtes
- Des autres containers



Communication avec la machine hôte

Au démarrage d'un conteneur on peut :

- Associer un port exposé par le conteneur à un port local Option -p
- Monté un répertoire du conteneur sur le système de fichier local.
 Option -v



docker-compose

docker-compose est un outil pour définir et exécuter des applications Docker utilisant plusieurs conteneurs

- Avec un simple fichier, on spécifie les différents conteneurs, les ports exposés, les liens entre conteneurs.
- Ensuite avec une commande unique, on peut démarrer, arrêter, redémarrer l'ensemble des services.

Docker s'installe séparément sur Linux et est inclus dans Docker pour les distributions Mac ou Windows

Orienté au départ pour faciliter le développement et l'intégration ; il intègre de plus en plus des fonctionnalités pour la production



Exemple configuration

```
# Le fichier de configuration définit des services, des networks et des volumes.
version: '2'
services:
  annuaire:
    build: ./annuaire/ # context de build, présence d'un Dockerfile
    networks:
     - back
     - front
    ports:
     - "1111:1111" # Exposition de port
  documentservice:
    build: ./documentService/
    networks:
     - back
  proxy:
    build: ./proxy/
    networks:
      - front
    ports:
      - 8080:8080
# Analogue à 'docker network create'
networks:
  back:
  front:
```



build: Construire ou reconstruire les images

config : Valide le fichier de configuration

down: Stoppe et supprime les conteneurs

exec : Exécute une commande dans un container up

logs: Visualise la sortie standard

port : Affiche le port public d'une association de port


pull / push : Pull/push les images des services

restart : Redémarrage des services

scale : Fixe le nombre de container pour un service

start / **stop** : Démarrage/arrêt des services

up : Création et démarrage de conteneurs



spring-security-oauth2 @EnableAuthorizationServer



Introduction

Avec *spring-security-oauth2* dans le classpath, l'auto-configuration permet de facilement mettre en place le serveur d'autorisation et/ou ressources

L'architecture micro-services étend le modèle de *oAuth2* appliqué aux services comme Google/Facbook/Github

<u>Attention</u>: Spring Security 5 reprend certains des fonctionnalités de *spring-security-oAuth2*



Implémentation oAuth2

Avec Spring Security oAuth2:

- Les demandes pour les jetons sont traitées par des contrôleurs de SpringMVC
- L'accès aux ressources protégées est vérifié par des filtres http



Du côté du serveur d'autorisation, 2 endpoints sont fournies :

- AuthorizationEndpoint (par défaut /oauth/autorize) traite les requêtes d'autorisation (Autoriser le client à demander des jetons)
- TokenEndpoint (/oauth/token) pour demander des jetons

Pour le serveur de ressource, le filtre OAuth2AuthenticationProcessingFilter permet d'extraire le jeton d'une requête

Configuration de l'autorisation

L'annotation @EnableAuthorizationServer fournit une configuration par défaut d'un serveur d'autorisation (AuthorizationServerConfigurer).

Généralement, 3 aspects reste à être configurés :

- ClientDetailsServiceConfigurer : Comment récupérer les informations sur le client
- AuthorizationServerSecurityConfigurer : Les contraintes de sécurité sur les endpoints « jeton » (/oauth/*)
- AuthorizationServerEndpointsConfigurer : Le token store, le gestionnaire d'authentification permettant de déterminer les rôles de l'utilisateur final et de vérifier son mot de passe



Attributs d'un client

Un client a différents attributs :

- *clientId*: id.
- secret: (pour les clients ne nécessitant pas de login/mot de passe)
- scope: Le scope permettant de limiter les accès du client (~rôle)
- autorizedGrantTypes : Les moyens supportés pour le consentement du user (mot de passe, secret, implicit, ..)
- authorities: Permissions accordées aux clients (Permissions standard de Spring Security).

Exemple configuration clientDetails

```
@Override
public void configure(ClientDetailsServiceConfigurer clients) throws Exception {
// @formatter:off
clients.inMemory()
  .withClient("browser")
  .authorizedGrantTypes("refresh token", "password")
  .scopes("ui")
  .and()
  .withClient("account-service")
  .secret(env.getProperty("ACCOUNT SERVICE PASSWORD"))
  .authorizedGrantTypes("client_credentials", "refresh_token")
  .scopes("server")
  .and()
  .withClient("statistics-service")
  .secret(env.getProperty("STATISTICS SERVICE PASSWORD"))
  .authorizedGrantTypes("client credentials", "refresh token")
  .scopes("server");
```



Choix du TokenStore

Les jetons fournis au client sont générés et stockés dans des **TokenStore**

3 implémentations :

- InMemoryStore: Une fois le jeton obtenu, les serveurs de ressources doivent refaire des requêtes vers le serveur d'autorisation pour vérifier que le jeton est valide
- JdbStore: Les jetons sont stockés dans une base, le serveur de ressources doit pouvoir y accéder
- JwtTokenStore: Les jetons sont cryptés et le(s) serveurs de ressource détiennent le moyen de décrypter le jeton et d'en déduire les permissions accordées

Exemple configuration TokenStore et gestionnaire d'authentification utilisateur

```
@Bean
  public TokenStore tokenStore() {
        return new JwtTokenStore(accessTokenConverter());
// Sécurisation des endpoints
@Override
public void configure(AuthorizationServerEndpointsConfigurer
  endpoints) throws Exception {
endpoints
  .tokenStore(tokenStore)
  .authenticationManager(authenticationManager)
  .userDetailsService(userDetailsService);
```



Configuration des ACLs sur les endpoints jeton

```
@Override
public void configure(AuthorizationServerSecurityConfigurer
    oauthServer) throws Exception {
    oauthServer
    .tokenKeyAccess("permitAll()")
    .checkTokenAccess("isAuthenticated()");
}
```



Obtention de jeton

Avec la configuration par défaut, le endpoint /oauth/token permet d'obtenir le jeton typiquement en :

- Utilisant le crédentiel client pour s'authentifier en http sur le endpoint /oauth/token
- Utilisant le grant type : password
- En fournissant les crédentiels de l'utilisateur final

Exemple:

```
curl client:secret@localhost:8080/oauth/token
  -d grant type=password -d username=user -d password=pwd
```



Serveur de ressources

La création d'un serveur de ressources consiste à annoter

@EnableResourceServer et

- De configurer la sécurité (ACLs)
- Si le serveur de ressources est différent du serveur d'autorisation.
 Configurer le moyen pour décoder les jetons.



ACLs

Le jeton contient des informations sur :

- Le client et ses scopes
- L'utilisateur et ses rôles

Des droits d'accès sur les scopes peuvent alors être définis de cette façon :



Cloud Security

Introduction
Rappels oAuth2
Spring Boot et oAuth2
Spring Cloud Security

Apports de Spring Cloud Security

Construit sur **Spring Boot** et **Spring Security OAuth2**

Spring Cloud Security facilite la mise en place de pattern comme :

- Le relais des jetons oAuth à partir d'un front-end jusqu'aux services back-end avec Zuul
- Le relai de jetons entre des ressources serveurs
- Un intercepteur afin qu'un client Feign se comporte comme OAuth2RestTemplate (fetching tokens etc.)
- Configure l'authentification dans un proxy Zuul

Relais entre serveur de ressources (1)

```
@Configuration
@EnableOAuth2Sso
public class SiteSecurityConfigurer
  extends WebSecurityConfigurerAdapter {
    @Override
    protected void configure(HttpSecurity http) throws Exception {
        // ...
Configuration serveur de ressource :
security:
  oauth2:
    client:
      accessTokenUri: http://localhost:7070/authserver/oauth/token
      userAuthorizationUri: http://localhost:7070/authserver/oauth/authorize
      clientId: authserver
      clientSecret: passwordforauthserver
    resource:
      userInfoUri: http://localhost:9000/user
```

Relais entre serveur de ressources (2)

```
@Bean
public OAuth2RestOperations restOperations(
  OAuth2ProtectedResourceDetails resource, OAuth2ClientContext context) {
    return new OAuth2RestTemplate(resource, context);
@Autowired
private RestOperations restOperations;
public String callRemote() {
      return restOperations.getForObject("http://remote-service/api",
 String.class));
```

Zuul Proxy

```
@Controller
@EnableOAuth2Sso
@EnableZuulProxy
class Application {
L'annotation @EnableOAuth2Sso a pour effet que Zuul
 obtienne et valide des jetons auprès d'un serveur
 d'autorisation
De plus ces jetons sont transférés vers les services
 backend gérés par Zuul
```



Exemple de configuration Zuul

```
# customers obtient le jeton d'accès
# stores n'a que l'entête authorization
# recommendation n'a rien
proxy:
  auth:
    routes:
      customers: oauth2
      stores: passthru
      recommendations: none
```