PLB

FORMATION INFORMATIQUE ET MANAGEMENT

Architecture Micro-services avec Spring Cloud

David THIBAU – 2020

david.thibau@gmail.com

Agenda

- **Introduction**
  - Architecture Micro-services
  - Services techniques : frameworks vs infra
  - L'offre Spring-Cloud
- **Discovery et Config**
  - Service Eureka
  - Spring Cloud Config
- **Support pour les clients**
  - Répartition de charge
  - Le pattern Circuit breaker
  - Clients déclaratifs avec Feign
  - API Gateway
  - *Spring Cloud Contract*
- **Monitoring**
  - Agrégateur de flux Hystrix
  - Tracing avec Spring Sleuth
  - Centralisation des logs
- **Messaging**
  - Spring Cloud Stream : Concepts et introduction
  - Spring Cloud Data Flow
- **Spring Cloud Security**
  - Rappels oAuth2
  - Spring Boot et oAuth2
  - Spring Cloud Security
- **Déploiement**
  - Alternatives
  - Support pour les conteneurs
  - Spring Cloud et Kubernetes

Introduction

Architectures micro-services

Services techniques : frameworks vs infra

L’offre Spring Cloud

Introduction

Le terme « ***micro-services*** » décrit un nouveau pattern architectural visant à améliorer la rapidité et l'efficacité du développement et de la gestion de logiciel

C’est le même objectif que les méthodes agiles ou les approches *DevOps :* *« Déployer plus souvent »*

Architecture

L’architecture implique la décomposition des applications en très petit services

- faiblement couplés
- ayant une seule responsabilité
- Développés par des équipes full-stack indépendantes.

Le but étant de livrer et maintenir des systèmes complexes avec la rapidité et la qualité demandées par le business digital actuel

On l'a appelée également *SOA 2.0* ou *SOA For Hipsters*

Caractéristiques

Design piloté par le métier : La décomposition fonctionnelle est pilotée par le métier (voir *Evans's DDD approach*)

Principe de la responsabilité unique : Chaque service est responsable d'une seule fonctionnalité et la fait bien !

Une interface explicitement publiée : Un producteur de service publie une interface qui peut être consommée

DURS (Deploy, Update, Replace, Scale) indépendants : Chaque service peut être indépendamment déployé, mis à jour, remplacé, scalé

Communication légère : REST sur HTTP, STOMP sur WebSocket, ...

Bénéfices

Scaling indépendant : Seuls les services les plus sollicités sont scalés
=> Économie de ressources

Mise à jour indépendantes : Les changements locaux à un service peuvent se faire sans coordination avec les autres équipes
=> Agilité de déploiement

Maintenance facilitée : Le code d'un micro-service est limité à une seule fonctionnalité
=> Corrections, évolutions plus rapide

Hétérogénéité des langages : Utilisation des langages les plus appropriés pour une fonctionnalité donnée

Isolation des fautes : Un dysfonctionnement peut être plus facilement localiser et isoler.

Communication inter-équipe renforcée : Full-stack team

=> Favorise le CD des applications complexes

Contraintes

Réplication : Un micro-service doit être scalable facilement, cela a des impacts sur le design (stateless, etc...)

Découverte automatique : Les services sont typiquement distribués dans l’environnement d’exécution, le scaling peut être automatisé. Les points d'accès aux services doivent alors s'enregistrer dans un annuaire afin d'être localisés automatiquement

Monitoring : Les points de surveillances sont distribués. Les traces et les métriques doivent être agrégés en un point central

Résilience : Plus de services peuvent être en erreur. L'application doit pouvoir résister aux erreurs.

DevOps : L'intégration et le déploiement continu sont indispensables pour le succès.

Inconvénients et difficultés

- Trouver la bonne décomposition est difficile. Une mauvaise décomposition peut entraîner des couplages entre les micro-services
- Le côté distribué fait que le système complet est plus difficile à tester, déployer
- Le déploiement de fonctionnalités qui touche plusieurs services est plus délicat
- La migration d’une application monolithique existante vers les micro-services n’est pas simple

Architecture monolithique

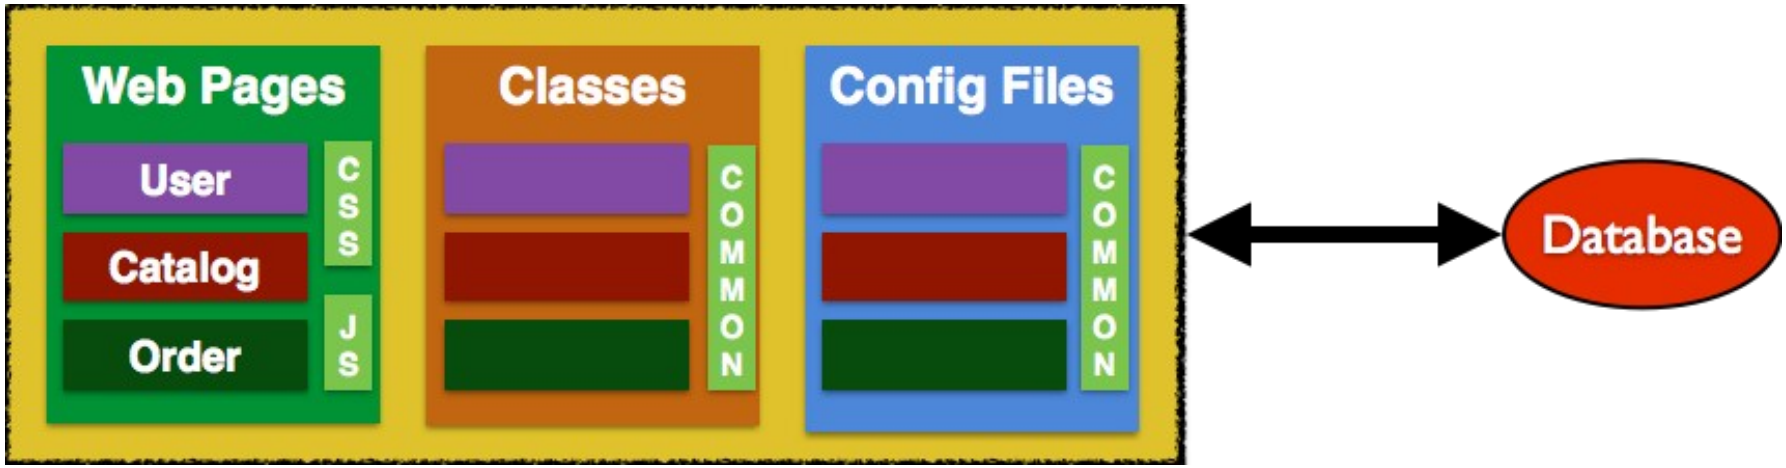

Version micro-service

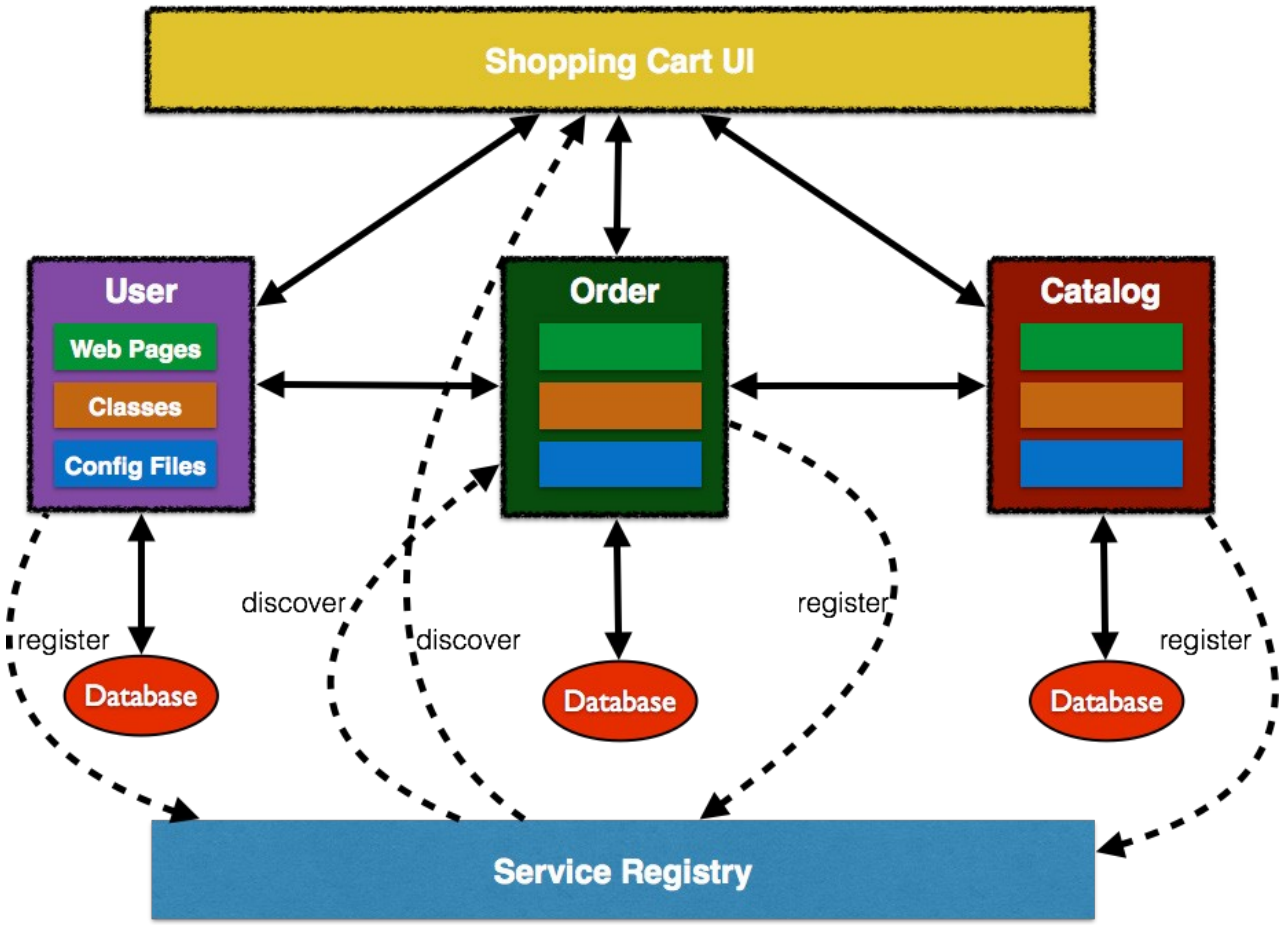

Patterns de composition

Les micro-services peuvent être combinés afin de fournir un micro-service composite.

Comme design patterns de composition citons :

- **L'agrégateur** : Agrégation de plusieurs micro-service et fourniture d'une autre API RESt
- **Proxy** : Délégation à un service caché avec éventuellement une transformation
- **Chaîne** : Réponse consolidée à partir de plusieurs sous-services
- **Branche** : Idem agrégateur avec le parallélisme

Agrégateur

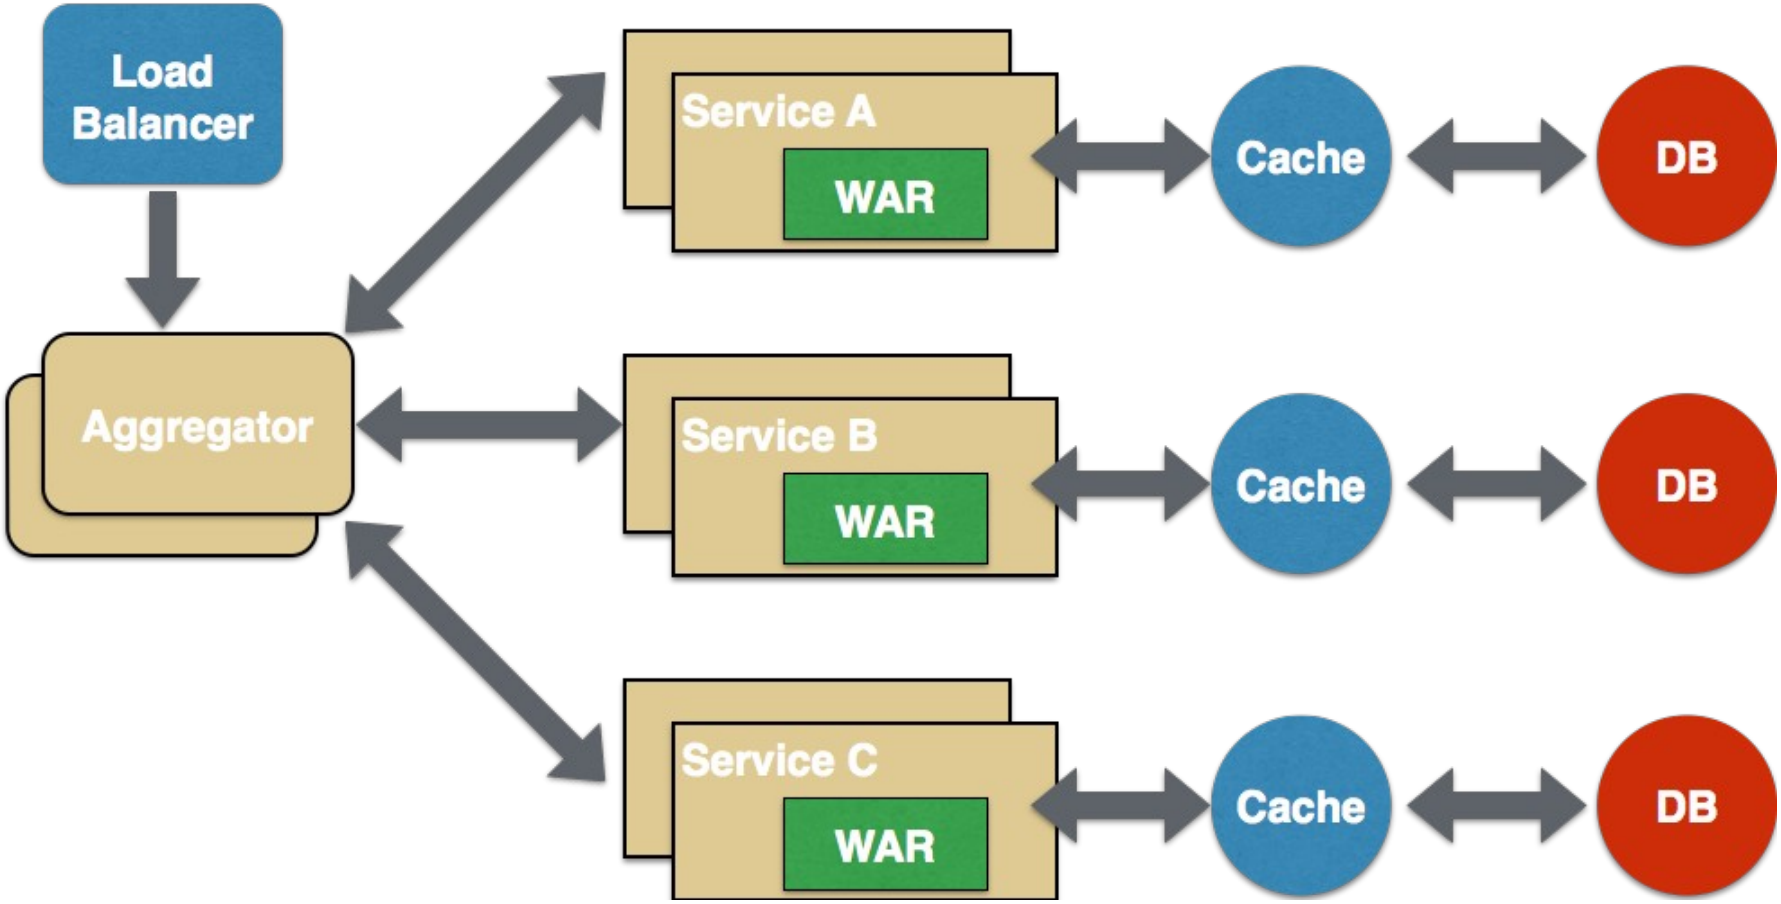
Load Balancer
Aggregator
Service A
WAR
Service B
WAR
Service C
WAR
Cache
Cache
Cache
DB
DB
DB

Proxy

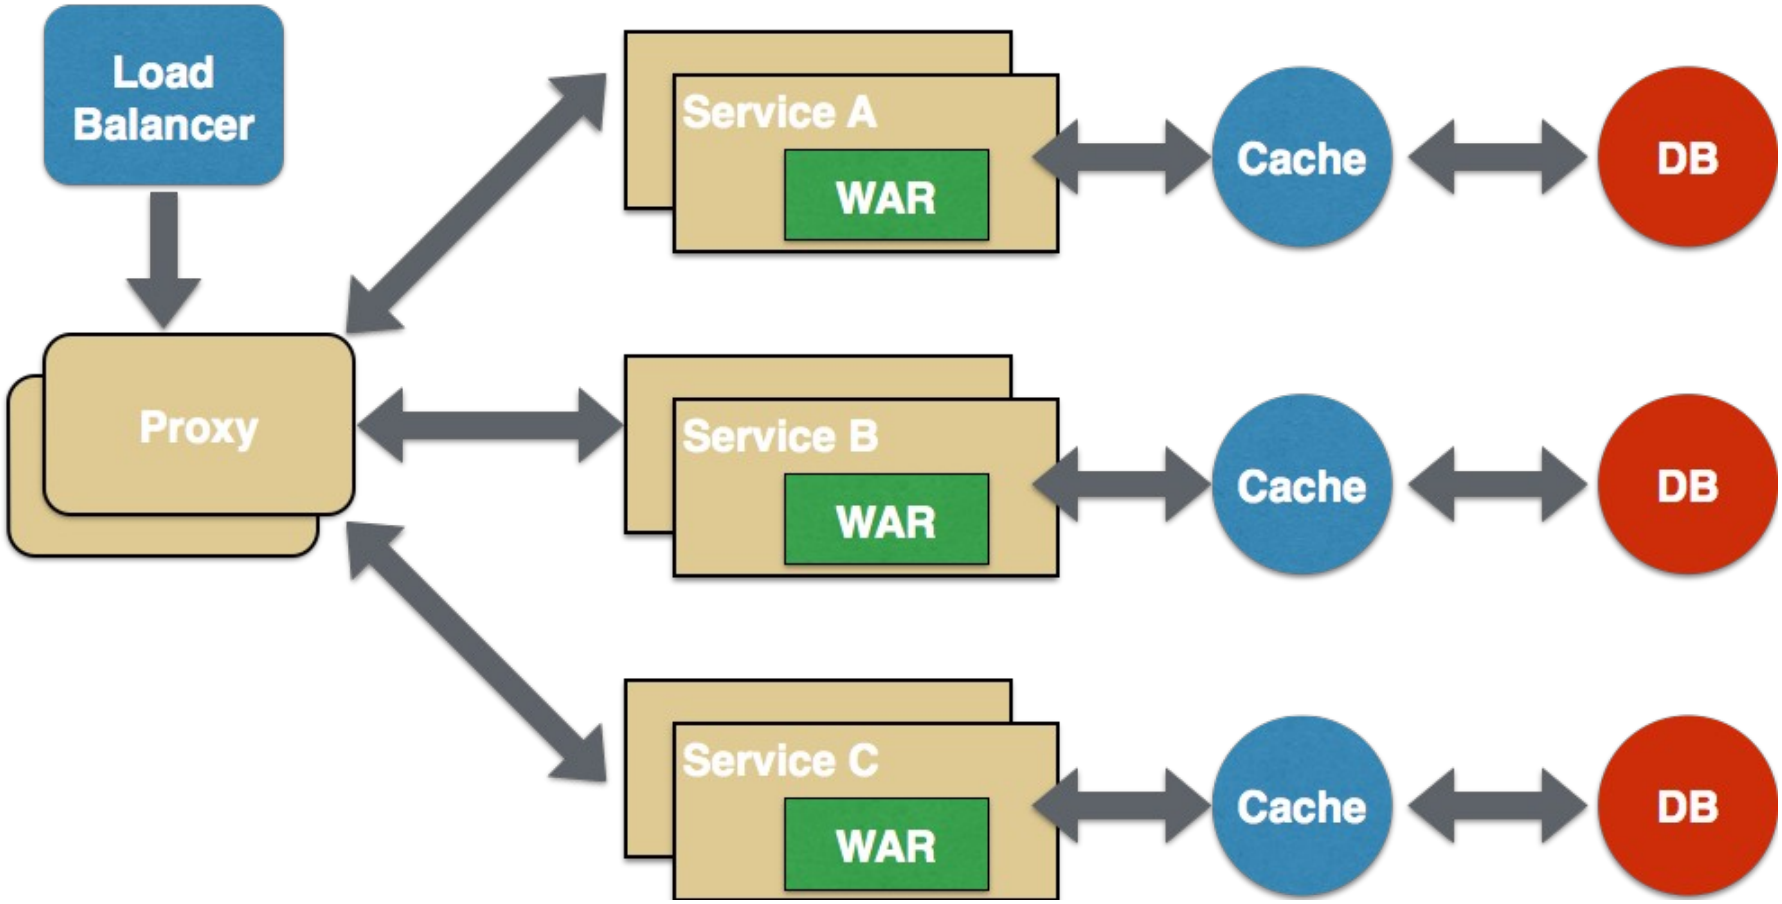
Load Balancer
Proxy
Service A
WAR
Service B
WAR
Service C
WAR
Cache
Cache
Cache
DB
DB
DB

Chaîne

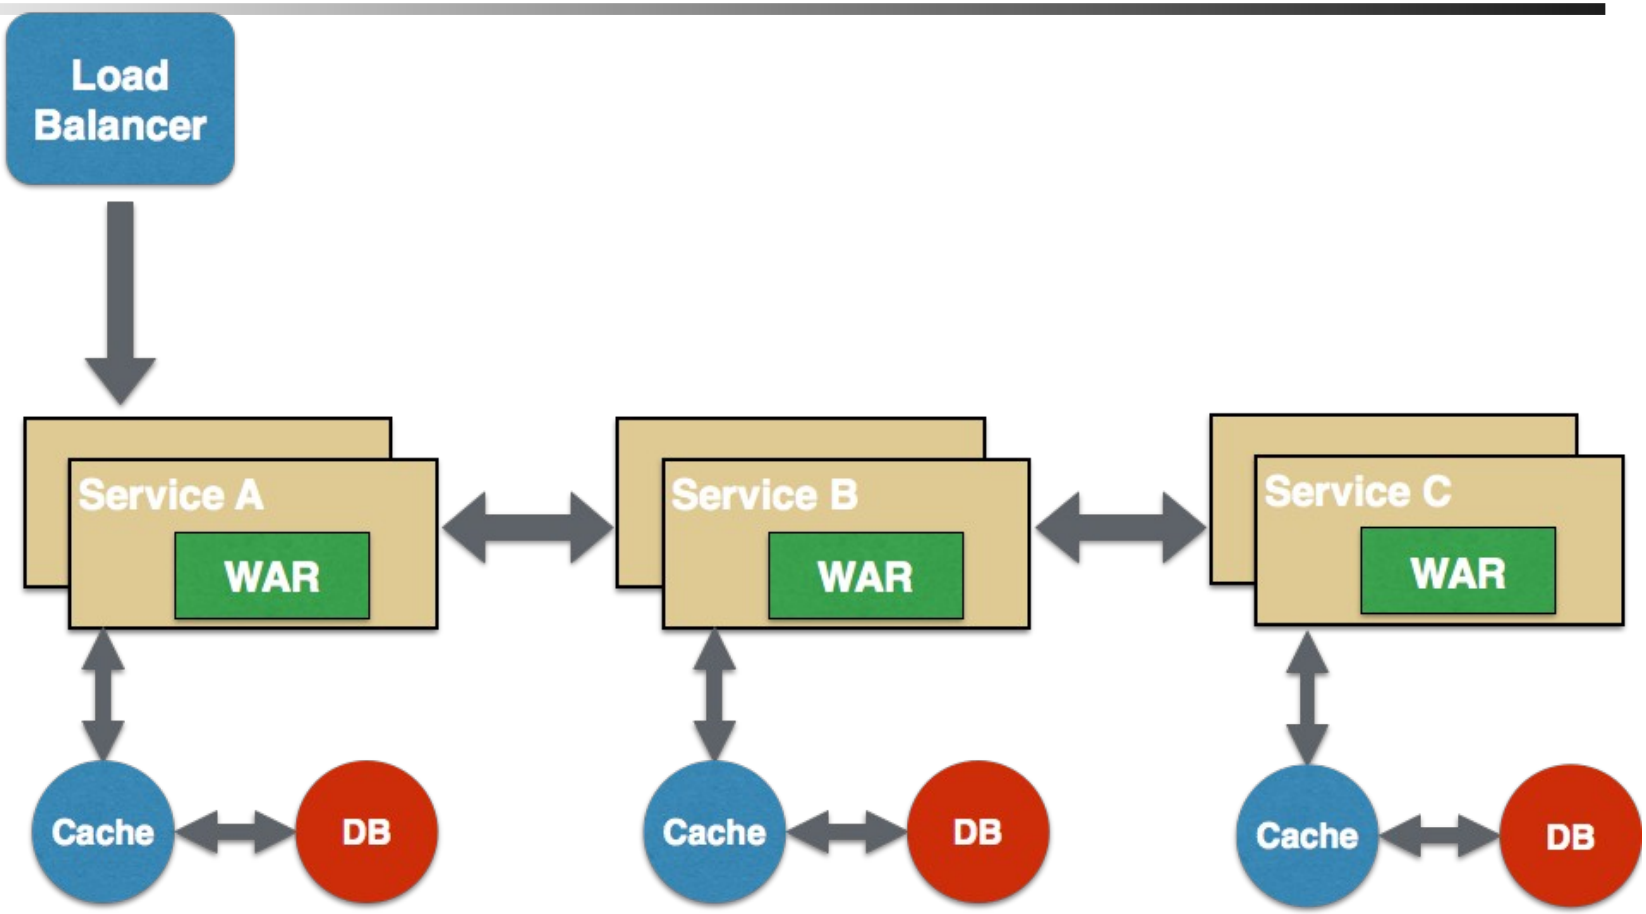
Load Balancer
Service A
WAR
Service B
WAR
Service C
WAR
Cache
DB
Cache
DB
Cache
DB

Branche

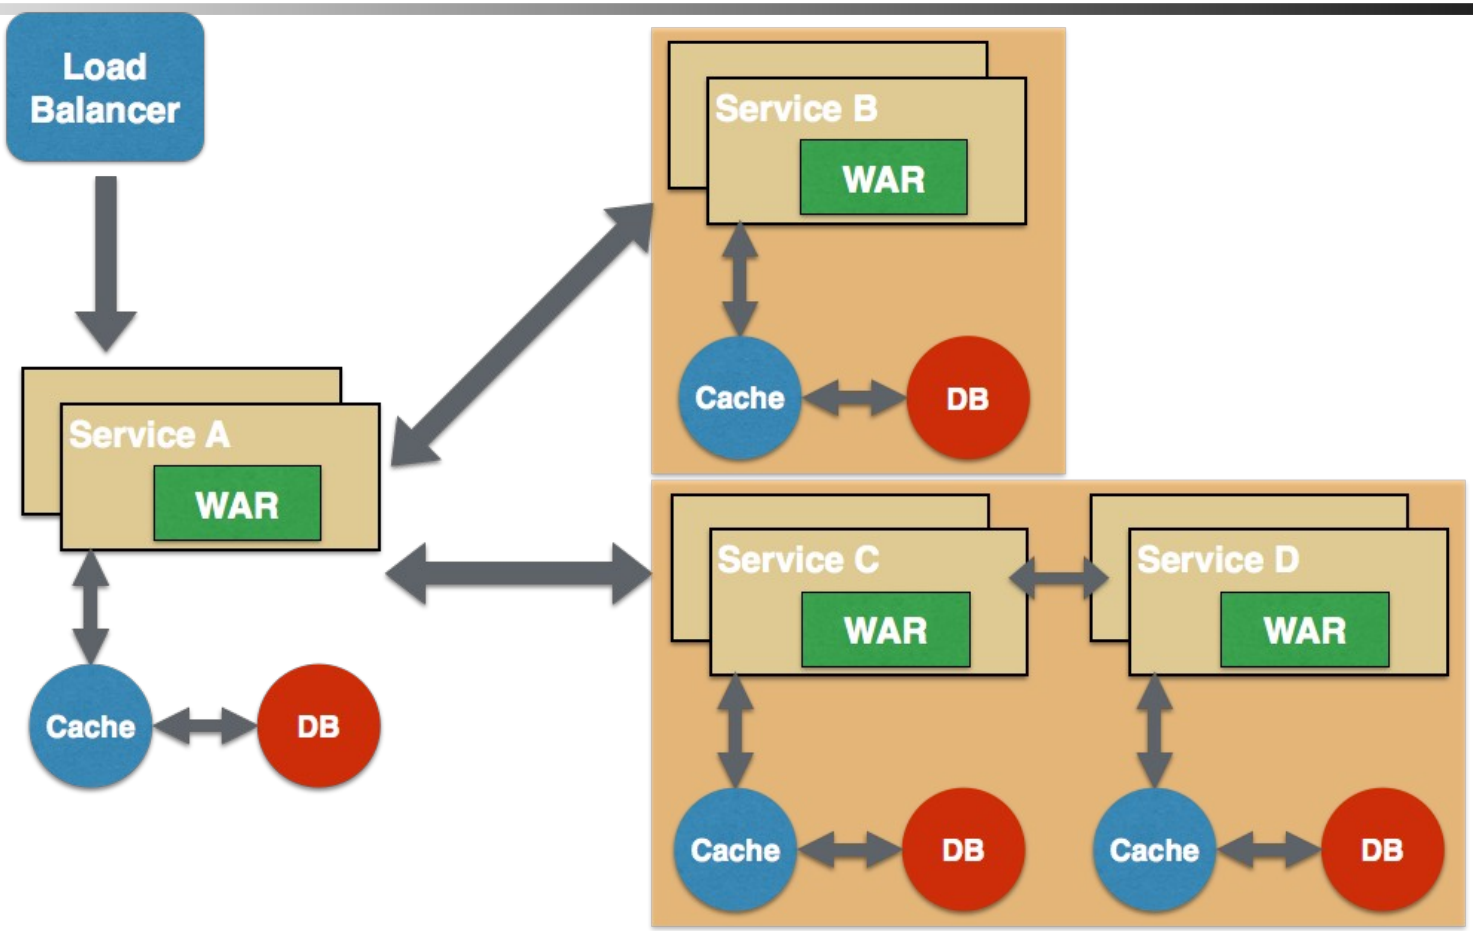
Load Balancer
Service A
WAR
Cache
DB
Service B
WAR
Cache
DB
Service C
WAR
Cache
DB
Service D
WAR
Cache
DB

Une architecture micro-service

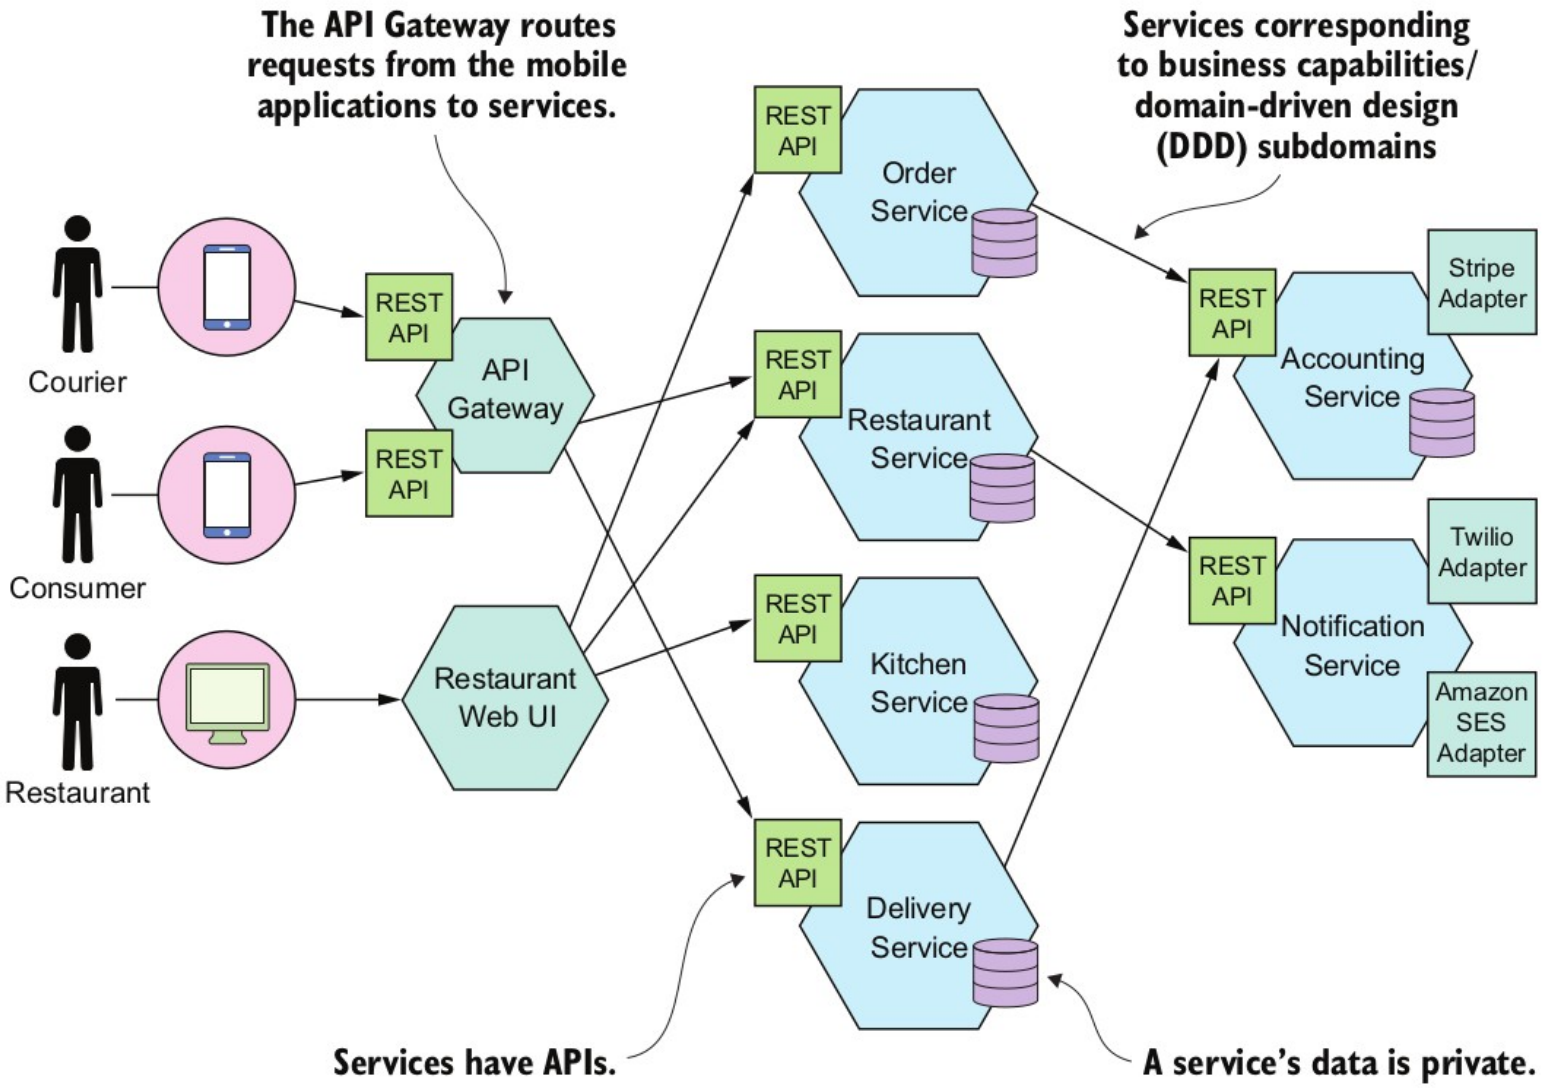

Microservices Pattern, Chris Richardson, 2017

Organisation DevOps

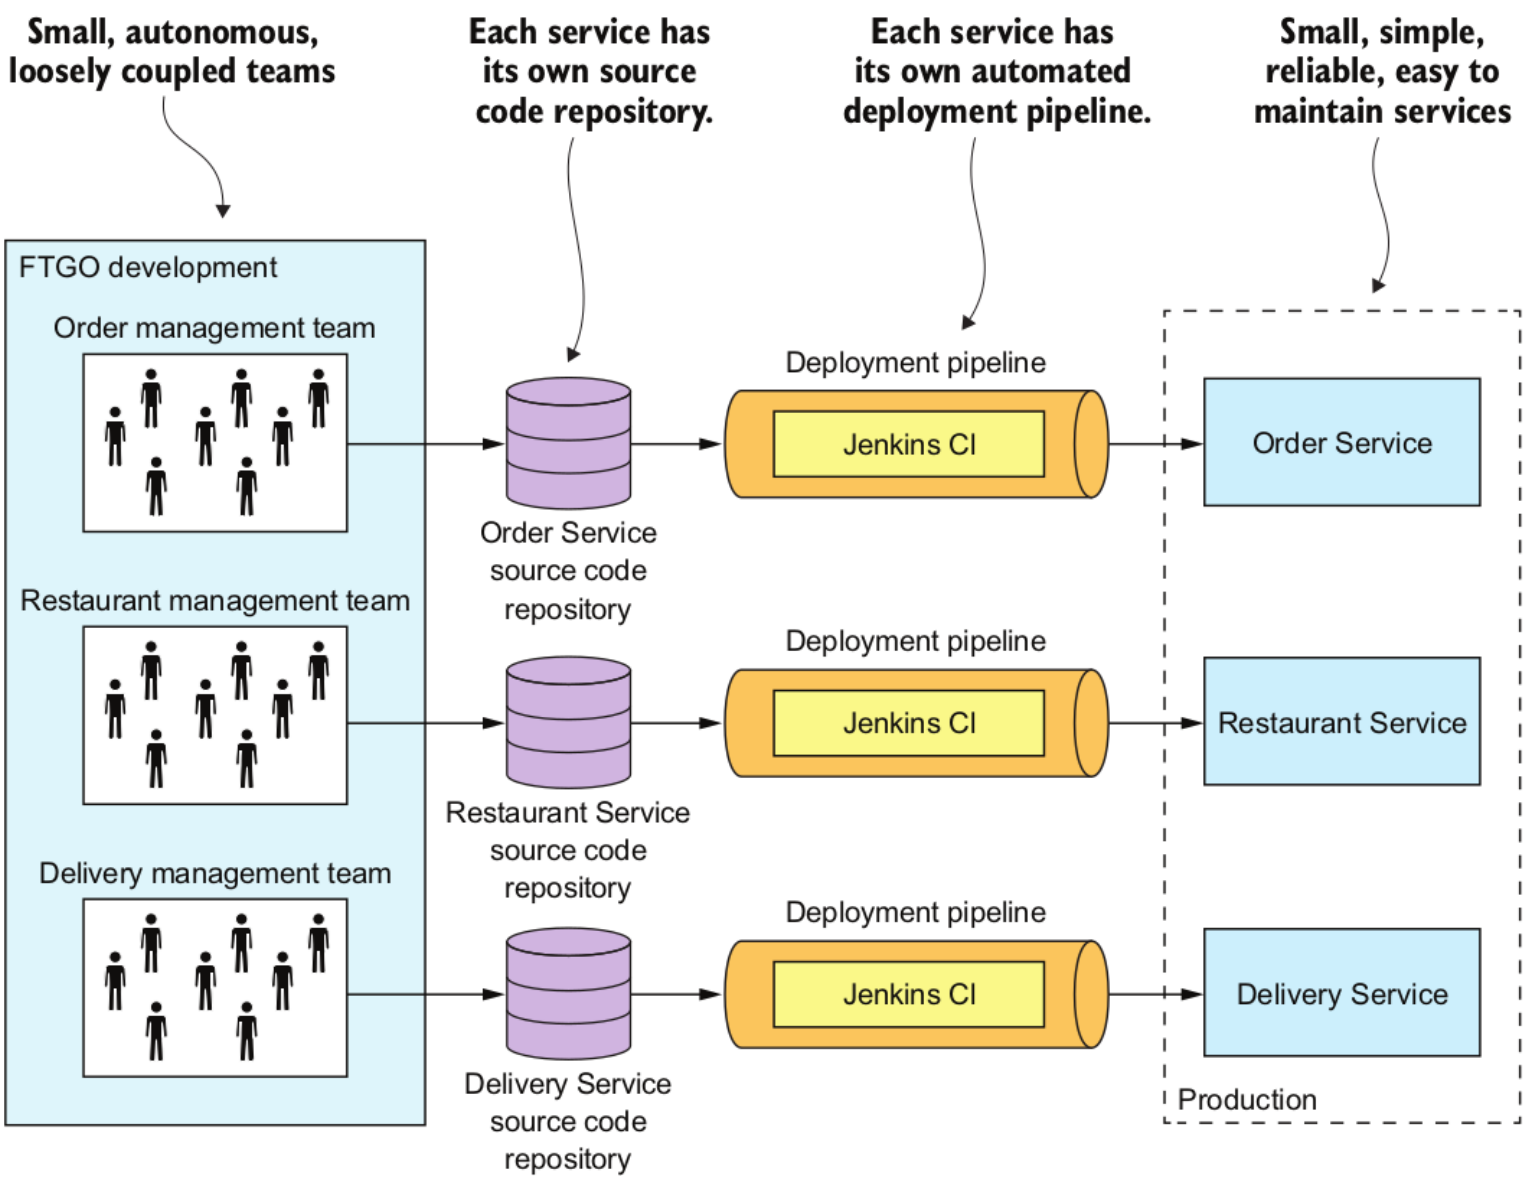

Problèmes à résoudre et design patterns

<u>Décomposition en services</u>, Patterns :

- DDD ou sous-domaines
- Fonctionnalités métier

<u>Communication entre service</u>, Aspects et patterns:

- Style (RPC, Asynchrone, etc.)
- Découverte des services, (Self-registry pattern, ...)
- Fiabilité : Circuit Breaker Pattern
- Messagerie transactionnelle
- APIs

<u>Distribution des données</u>, Aspects

- Gestion des transactions : Transactions distribuées ?
- Requêtes avec jointures ?

https://microservices.io/patterns/

Patterns et problèmes à résoudre

<u>Déploiement des services</u>, Patterns :

- Hôtes uniques avec différents processus
- Un container par service, Déploiements immuables, Orchestration de Containers
- Serverless

<u>Observabilité</u> afin de fournir des *insights* applicatifs :

- Health check API, Agrégation des traces, Tracing distribué, Détection d'exceptions, Métriques applicatifs, Audit

<u>Tests automatisés</u> :

- Service en isolation, Tests des contrats (APIs)

<u>Patterns transverses</u> :

- Externalisation des configurations, Pipelines CD, …

<u>Sécurité</u> :

- Jetons d'accès, *oAuth*, ...

Les 12 facteurs de réussite

I. Outil de scm : Unique source de vérité

II. Dépendances: Déclare et isoler les dépendances

III. **Configuration** : Configuration séparée du code, stockée dans l'environnement

IV. Services d'appui (backend) : Considère les services d'appui comme des ressources attachées,

V. Build, **release**, **run** : Permet la coexistence de différentes releases en production

VI. Processes : Exécute l'application comme un ou plusieurs processus stateless. Déploiement immuable

VII. Port binding : Application est autonome (pas de déploiement sur un serveur). Elle expose juste un port TCP

VIII. Concurrence : Montée en charge grâce au modèle de processus

IX. Disposability : Renforce la robustesse avec des démarrages et arrêts rapides

X. Dev/**prod parity** : Garder les environnements de développement, de pré-production et de production aussi similaires que possible

XI. Logs : Traiter les traces comme un flux d'événements

XII. Processus d'Admin : Considérer les tâches d'administration comme un processus parmi d'autres

https://12factor.net/

Introduction

Architectures micro-services

Services techniques : frameworks vs infrastructure

L’offre Spring Cloud

Services techniques

Les architectures micro-services nécessitent des services technique :

- Service **de discovery** permettant à un micro-service de s'enregistrer et de localiser ses micro-services dépendants
- Service de centralisation de **configuration** facilitant la configuration et l'administration des micro-services
- Services **d'authentification** offrant une fonctionnalité de SSO parmi l'ensemble des micro-services
- Service de **monitoring** agrégeant les métriques de surveillance en un point central
- Support pour la répartition de charge, le fail-over, la résilience aux fautes
- Service de session applicative, horloge synchronisée,

Projet « *Netflix* »

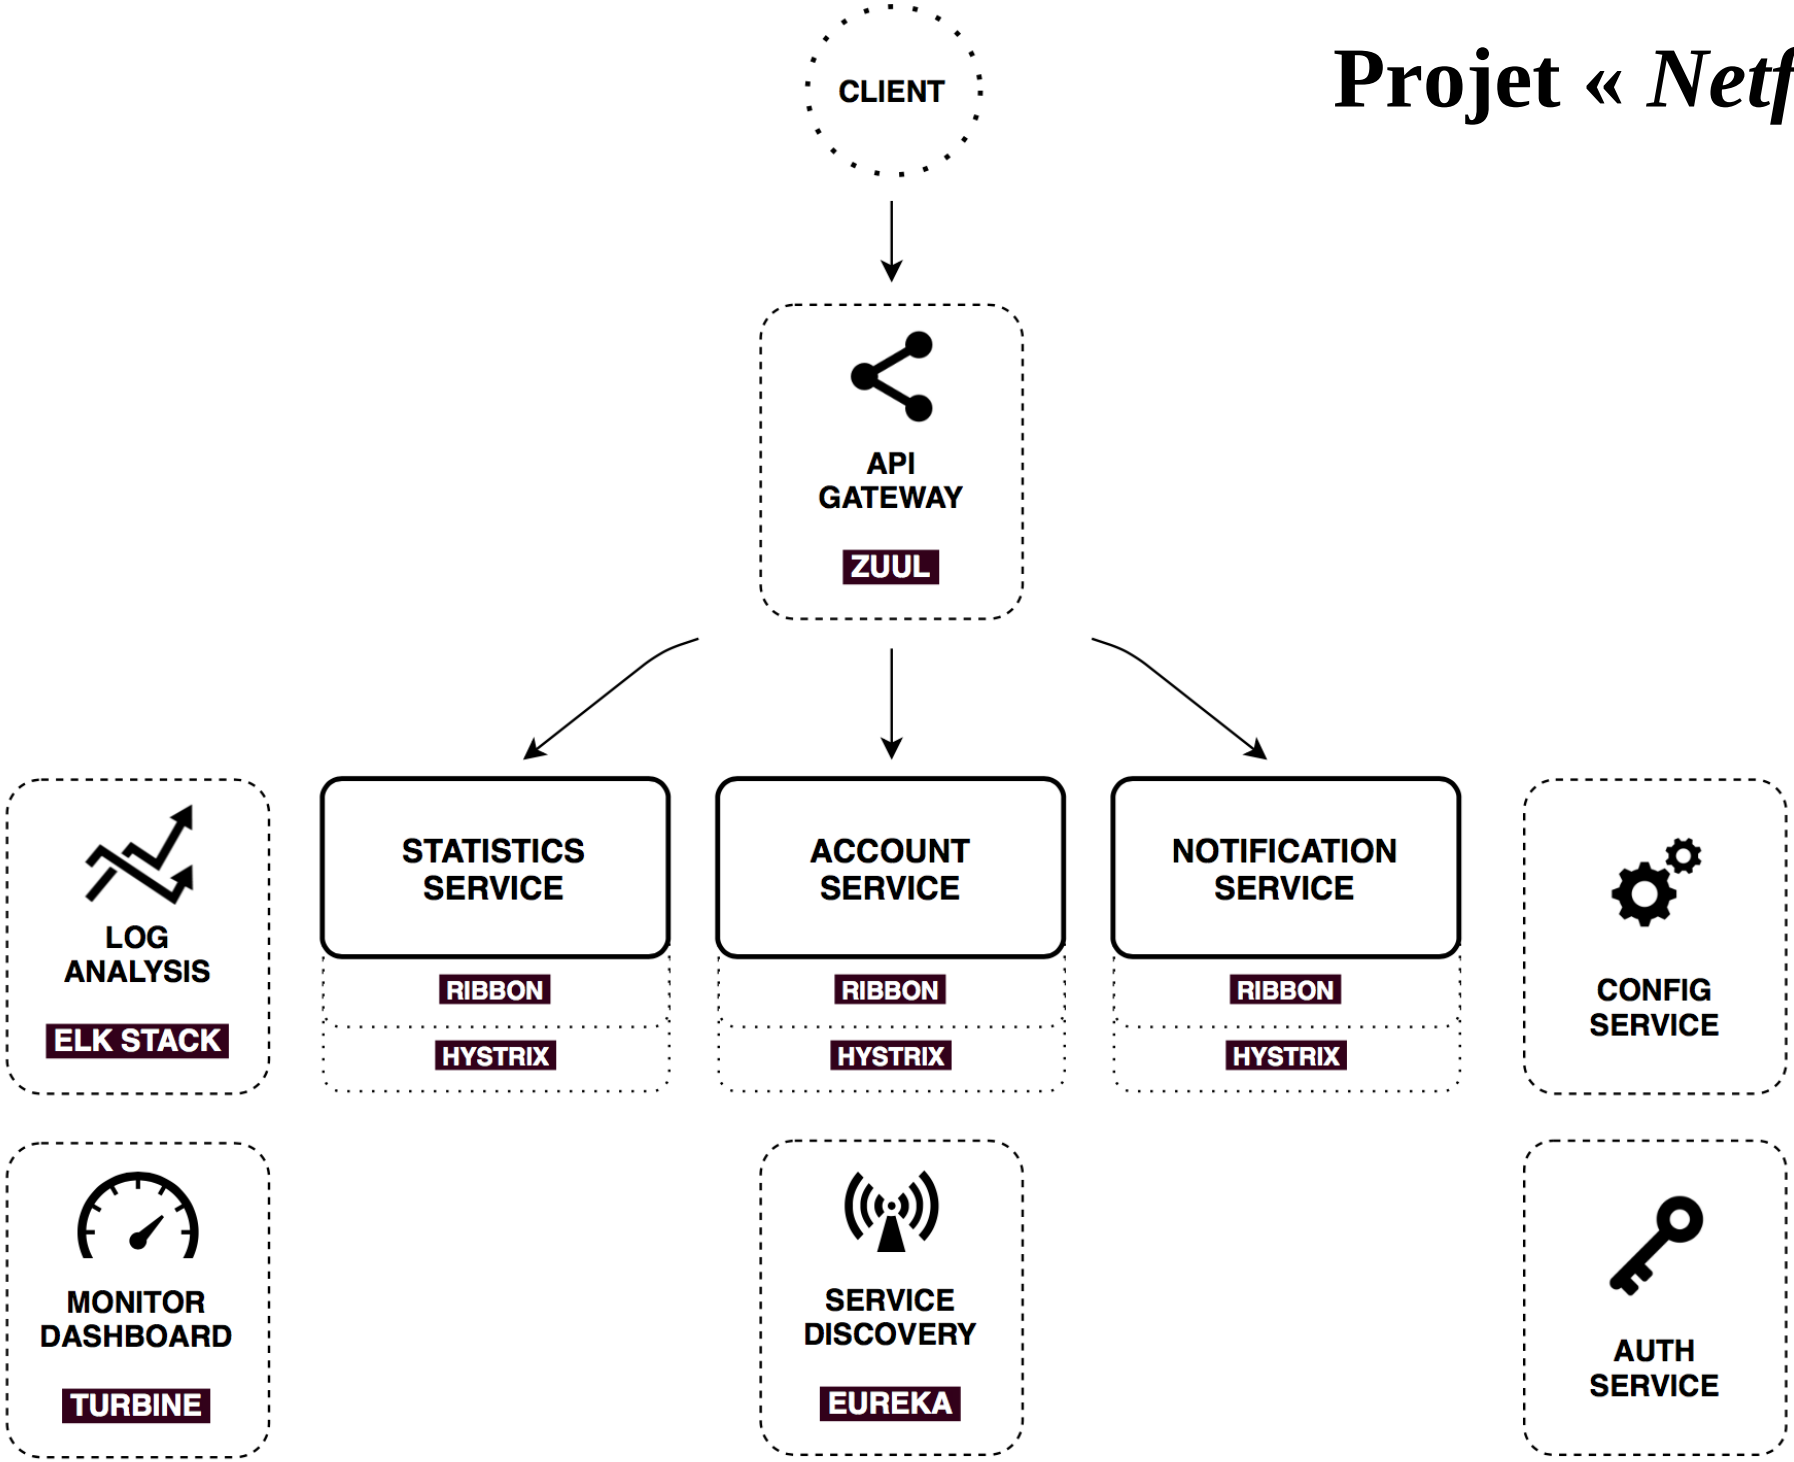

Infrastructure de déploiement

Infrastructure de déploiement pour ce type d'architecture :

- Serveur matériel provisionné : Pas imaginable
- Virtualisation + outils de gestion de conf (Puppet, Chef, Ansible) : Peu adapté
- Orchestrateur de Container (Kubernetes) : Fait pour
- Offre Cloud (AWS, Google, ...) : Economie ?
- Serverless : Nécessite des démarrages ultra-rapides

Services techniques

Qui fournit les services techniques ?

- Dans les premières architectures, c’est le software => framework Netflix
- Actuellement, de nombreux services techniques migre vers l’infrastructure :
  - Services, Config, Répartition de charge Kubernetes
  - Résilience, Sécurité, Monitoring : Service mesh de type Istio

Introduction

Architectures micro-services
Services techniques :
frameworks vs infrastructure
L’offre Spring Cloud

Offre Spring Cloud

Spring Cloud a donc vocation d’offrir tous les outils et services techniques nécessaire aux architectures fortement distribuées

Spring Cloud nécessite Spring Boot

Il offre :

- des facilités de déploiement vers des environnements Cloud (Amazon Web Services, Cloud Foundry, Heroku Paas)
- Des facilités pour la mise en place d'architecture Micro-services et plus généralement de systèmes distribués

Applications visées

Les applications visées sont de type SAAS software-as-a-service basées sur les technologies WEB et des méthodologies de développement DevOps

Les objectifs sont :

- Utiliser des formats déclaratifs pour l'**automatisation de la mise en place**. Cela pour minimiser les temps et les coûts pour intégrer de nouveaux développeurs au projet
- Avoir un contrat clair avec le système d'exploitation sous-jacent afin d'offrir le **maximum de portabilité** : La JVM
- Être adapté au déploiement sur les plate-formes de cloud afin d'**éviter le besoin de serveurs** et d'administration système
- Minimiser les divergence entre le développement et la production => **déploiement continu et agilité maximale**
- Qui puisse **se scaler sans de gros impacts** sur les outils, l'architecture ou les pratiques de développement

Offre Spring Cloud

Sprint Cloud basé sur Spring Boot fournit un framework de développement de micro-services qui :

- Apporte des abstractions des micro-services techniques nécessaires : Permettant d'adapter rapidement son code à une implémentation spécifique
- Du support pour les clients REST incluant la répartition de charge et la résilience
- Du support pour l'intégration des micro-services aux middleware de messagerie
- Bénéficie de l'environnement Spring Boot et de l'écosystème Spring (Testabilité, Spring MVC / REST, Spring Data (SQL ou NoSQL), ...

Starter de projet Spring Cloud

Les fichiers de dépendances des projets SpringCloud font intervenir 2 versions :

- La version Spring Boot
- La release Spring Cloud

```
<parent>
  <groupId>org.springframework.boot</groupId>
  <artifactId>spring-boot-starter-parent</artifactId>
  <version>1.5.10.RELEASE</version>
  <relativePath/> <!-- lookup parent from repository -->
</parent>
<dependencyManagement>
  <dependencies>
    <dependency>
      <groupId>org.springframework.cloud</groupId>
      <artifactId>spring-cloud-dependencies</artifactId>
      <version>Edgware.RELEASE</version>
      <type>pom</type>
      <scope>import</scope>
    </dependency>
  </dependencies>
</dependencyManagement>
```

Spring Boot / Spring Cloud

La plupart des fonctionnalités sont offertes par Spring Boot et l'auto-configuration

Les fonctionnalités supplémentaires de Spring Cloud sont offertes via 2 librairies :

- ***Spring Cloud Context*** : Utilitaires et services spécifiques pour le chargement de l'*ApplicationContext* d'une application Spring Cloud (bootstrap, cryptage, rafraîchissement, endpoints)
- ***Spring Cloud Commons*** est un ensemble de classes et d'abstraction utilisées dans les différentes implémentations des services techniques (Par exemple : Spring Cloud Netflix vs. Spring Cloud Consul).

Contexte de bootstrap

- Ue application Spring Cloud créée un contexte Spring de "***bootstrap***" à partir du fichier ***bootstrap.yml***.
- Ce contexte est responsable de charger les propriétés de configuration à partir de ressources externes
  Typiquement, un serveur de configuration distant.

Contexte bootstrap et contexte local

Les deux contextes (*bootstrap* et *local*) contribuent au contexte applicatif final de l'application

- Les propriétés de *bootstrap* (distant) ont la priorité la plus haute et ne peuvent donc pas être surchargées par une configuration locale.
- En général, le fichier de configuration local *bootstrap.yml* ne contient que l'identification de l'application et la localisation du service externe de configuration.

Exemple : *bootstrap.yml*

```yaml
spring:
  application:
    name: members-service
  cloud:
    config:
      uri: http://config:8888
      fail-fast: true
      password: ${CONFIG_SERVICE_PASSWORD}
      username: user
```

Spring Cloud Commons

Abstractions et implémentations

Discovery (Client et serveur) : Eureka, Consul, Zookeeper

LoadBalancer : Ribbon, SpringRestTemplate, Reactive Web Client

Circuit Breaker : Hystrix, Resilence4J, Sentinel, Spring Retry

Serveur de Discovery et Configuration

Service de Discovery, l'exemple Eureka

Spring Cloud Config

Pattern communs

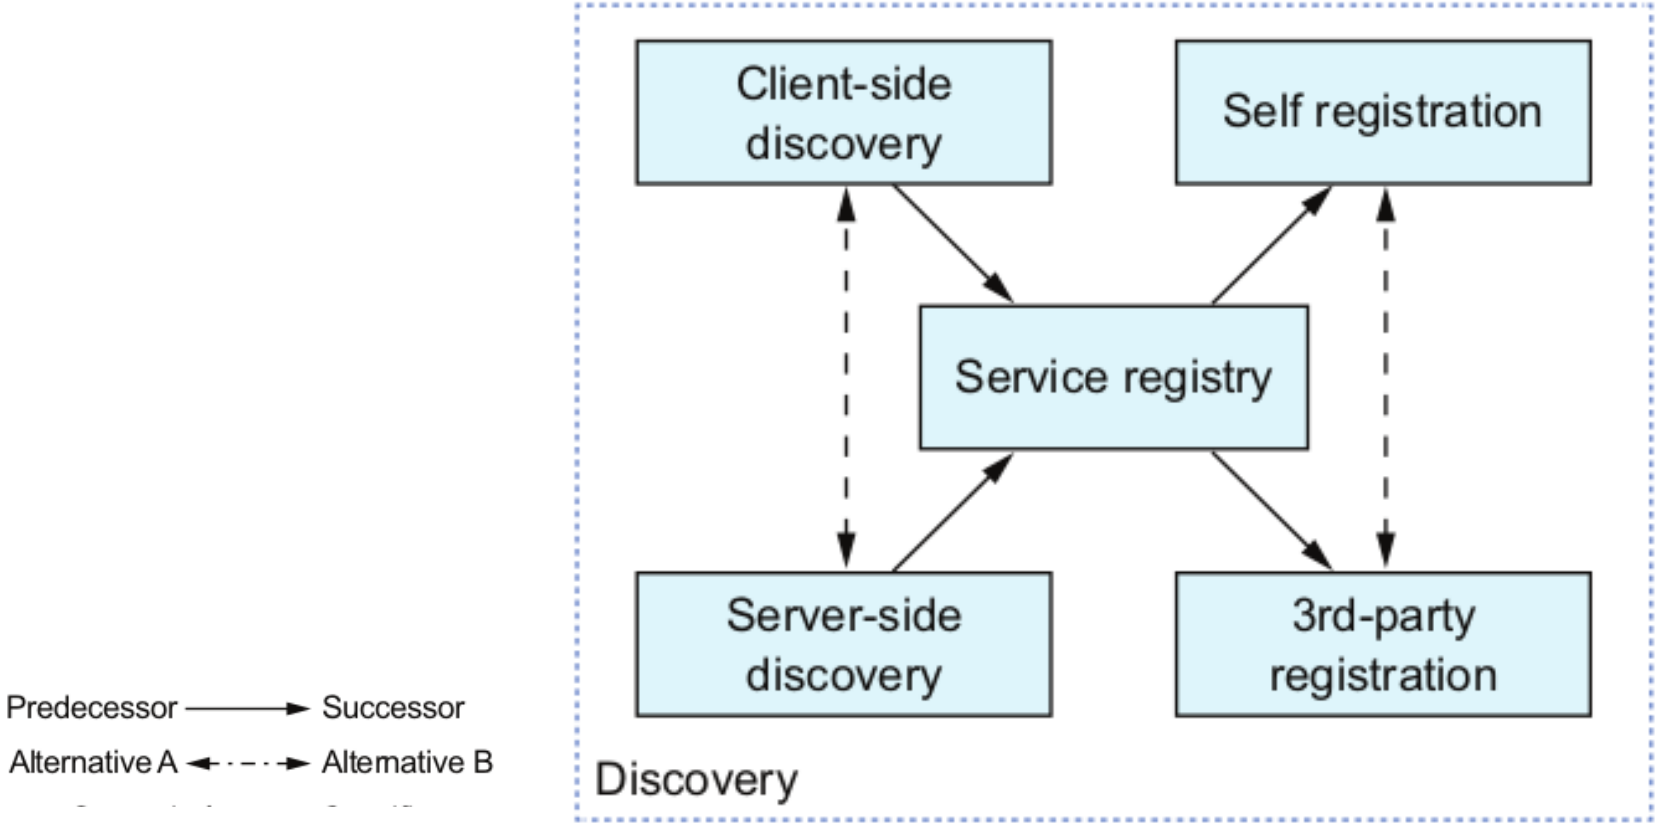

@EnableDiscoveryClient

L'annotation ***@EnableDiscoveryClient*** recherche des implémentations de l'interface ***DiscoveryClient*** :

- Spring Cloud Netflix **Eureka**,
- Spring Cloud **Consul** Discovery
- Spring Cloud **Zookeeper** Discovery.
- Spring Cloud **Kubernetes** Discovery

L'application s'enregistre alors auprès d'un serveur de discovery distant.

Service Discovery Eureka

La société Netflix a mis a disposition de la communauté Open Source ***Eureka*** qui est un service de registre pour les micro-services

Eureka offre plusieurs avantages :

- API Rest
- Supporte la réplication
- Cache pour le client
- Peut fonctionner en paire
- Rapide

Fonctionnement

Quand un client s’enregistre avec *Eureka*, il fournit des méta-données comme le hôte, le port, l’indicateur de santé, la page d’accueil

Eureka reçoit périodiquement des messages (heartbeat) de chaque instance des services.

Si il ne reçoit pas de messages au bout d’un *timeout* configurable, l’instance est supprimée du registre.

Mise en place serveur Eureka

L'application Eureka Server doit déclarer le starter

spring-cloud-starter-eureka-server

```
@SpringBootApplication
@EnableEurekaServer
public class AnnuaireApplication {

public static void main(String[] args) {
SpringApplication.run(AnnuaireApplication.class,
  args);
}
}
```

Page Eureka

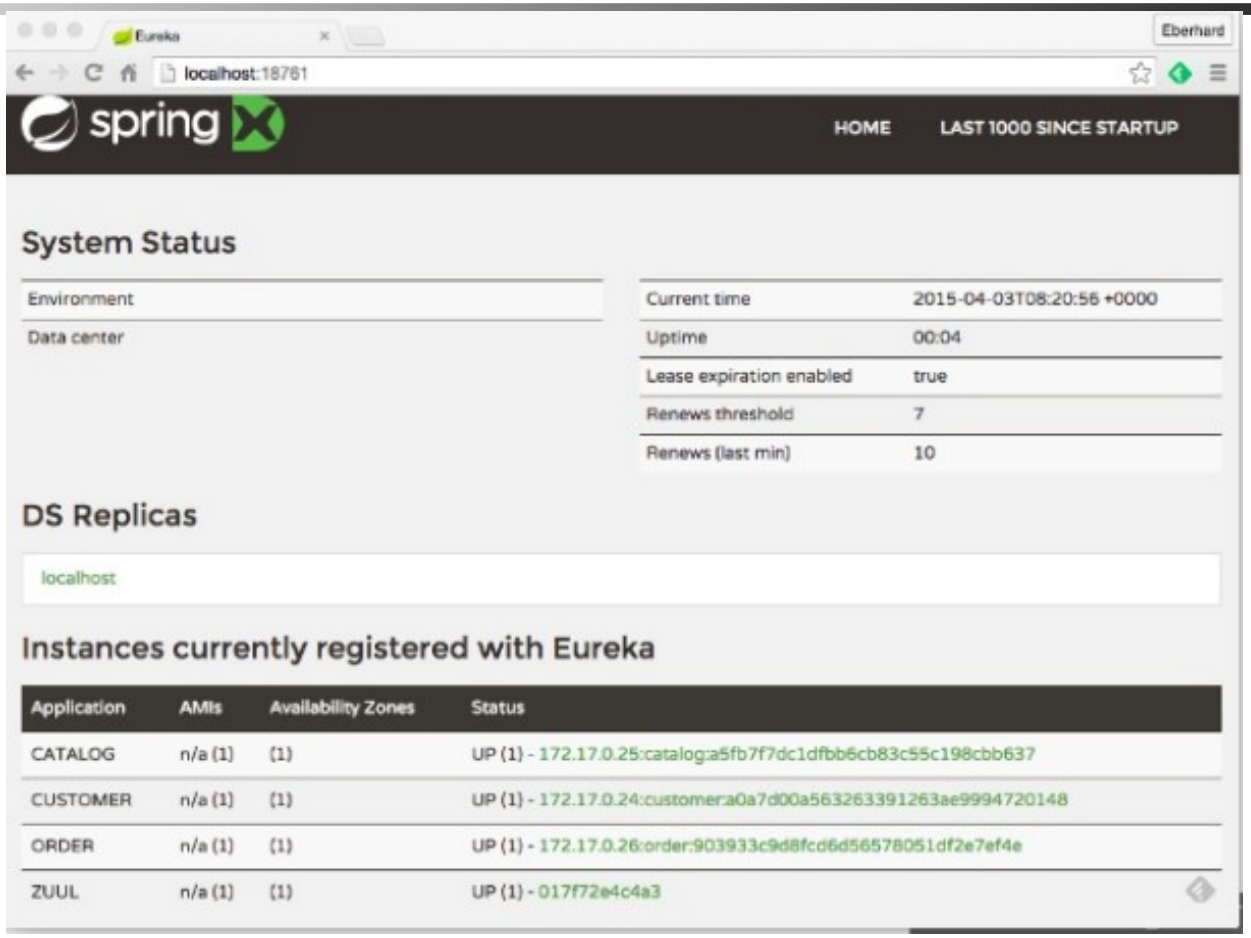
Eureka
Eberhard
localhost:18761
spring
HOME
LAST 1000 SINCE STARTUP
System Status
Environment
Data center
Current time 2015-04-03T08:20:56 +0000
Uptime 00:04
Lease expiration enabled true
Renews threshold 7
Renews (last min) 10
DS Replicas
localhost
Instances currently registered with Eureka
Application AMIs Availability Zones Status
CATALOG n/a (1) (1) UP (1) - 172.17.0.25:catalog:a5fb7f7dc1dfbb6cb83c55c198cbb637
CUSTOMER n/a (1) (1) UP (1) - 172.17.0.24:customer:a0a7d00a563263391263ae9994720148
ORDER n/a (1) (1) UP (1) - 172.17.0.26:order:903933c9d8fcd6d56578051df2e7ef4e
ZUUL n/a (1) (1) UP (1) - 017f72e4c4a3

Client Eureka dans Spring Cloud

Pour s'enregistrer sur un service Eureka.

Un client doit :

- Déclarer le starter
- Sans SpringBoot, autoriser l'auto-configuration avec *@EnableDiscoveryClient ou* éventuellement : *@EnableEurekaClient*

Configuration

Pour localiser le serveur Eureka

`eureka.client.serviceUrl.defaultZone`

Les valeurs par défaut pour l'enregistrement du nom de l'application, de l'hôte virtuel et du port sont :

- `${spring.application.name}`
- `${spring.application.name}`
- `${server.port}`

Instance / Client

L’annotation *@EnableDiscoveryClient ou @EnableEurekaClient* a 2 conséquences :

- L’application s’enregistre comme instance
- L’application s’enregistre comme client (Il peut interroger le serveur pour localiser les autres services)

Page de statut et indicateur de santé

Le serveur *Eureka* propose des liens vers différentes ressources du service enregistré. Par défaut ce sont les liens */actuator* mais cela peut être changé

```
eureka:
  instance:
    statusPageUrlPath: ${management.context-path}/info
    healthCheckUrlPath: ${management.context-path}/health
    homePageUrl: https://${eureka.hostname}/
```

Méta-données additionnelles

Des méta-données additionnelles peuvent être ajoutées dans

eureka.instance.metadataMap

Elles sont alors accessibles des clients distants qui peuvent en faire bon usage

Ces méta-données spécifiques sont utilisées par les solutions de Cloud supportées : Cloudfoundry, AWS par exemple

Exemple

```
spring:
  application:
     name: members-service  # Service registers under this name
eureka:
  client:
    serviceUrl:
      defaultZone: http://annuaire:1111/eureka/
  instance:
    LeaseRenewalIntervalInSeconds: 5 # 5s au lieu de 30s (dev)
    MetadataMap :
      instanceId=${spring.apllication.name}:$random.value}
```

Cache client et Serveur is a client

Le serveur Eureka n’a pas de support persistant mais les instances de service envoient périodiquement leur heartbeats afin que les informations soient à jour.

Les clients ont également en cache le contenu de l’annuaire (=> Ils ne sont pas obligés de contacter l’annuaire à chaque requête vers un autre service).

Par défaut, chaque serveur Eureka est également un client et nécessite au moins un serveur pair pour s’enregistrer.

Configuration *standalone*

La configuration *standalone* est utile lorsque l'on ne démarre qu'un seul service Eureka

```yaml
eureka:
  instance:
    hostname: localhost
  client:
    register-with-eureka: false
    fetch-registry: false
    serviceUrl:
      defaultZone: http://${eureka.instance.hostname}:${server.port}/eureka/
```

TP 1.1 et 1.2 : Enregistrement d'un premier service

Configuration en paire

```
---
spring:
  profiles: peer1
eureka:
  instance:
    hostname: peer1
  client:
    serviceUrl:
      defaultZone: http://peer2/eureka/

---
spring:
  profiles: peer2
eureka:
  instance:
    hostname: peer2
  client:
    serviceUrl:
      defaultZone: http://peer1/eureka/
```

Zones

Si les clients Eureka sont dans des zones différentes, il est préférable qu'ils accèdent au serveur Eureka le + proche.

Il faut alors indiquer dans quelle zone se trouve le client

```
eureka.instance.metadataMap.zone = zone1
eureka.client.preferSameZoneEureka = true
```

Utilisation du client Eureka

La principale API de *EurekaClient* est de localiser une instance d'un service :

```
@Autowired
private EurekaClient discoveryClient;

public String serviceUrl() {
    InstanceInfo instance =
  discoveryClient.getNextServerFromEureka("STORES", false);
    return instance.getHomePageUrl();
}
```

Serveur de Discovery et Configuration

Service de Discovery, l’exemple Eureka

Spring Cloud Config

Configuration centralisée

spring-cloud-config offre une alternative pour mettre en place une gestion centralisée de toutes les configurations des micro-services.

- Les mises à jour peuvent être dynamiques
- Le serveur peut être associé à un dépôt Git
  => Gestion de branches, des releases

Serveur de configuration

- Le serveur de configuration est une application Spring Boot annotée par ***@EnableConfigServer***
- La stratégie par défaut pour localiser les sources des propriétés est de cloner un dépôt git (*spring.cloud.config.server.git.uri*)
- Le serveur offre différents endpoints permettant de récupérer les valeurs de configuration :

```
/{application}/{profile}[/{label}]
/{application}-{profile}.yml
...
```

Résolution des valeurs de configuration

Les valeurs de configurations retournées par les endpoints dépendent de 3 paramètres :

- ***{application}*** qui correspond à la propriété "*spring.application.name*" du côté du client
- ***{profile}*** qui correspond à "*spring.profiles.active*" du côté du client
- ***{label}*** qui correspond à une révision ou tag du côté du serveur

Mise en place

```
@SpringBootApplication
@EnableConfigServer
public class ConfigServer {
  public static void main(String[] args) {
    SpringApplication.run(ConfigServer.class, args);
  }
}
```

Propriétés principales (*application.properties*)

```
server.port: 8888
spring.cloud.config.server.git.uri: file://${user.home}/config-repo
```

Dépendance

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-config-server</artifactId>
</dependency>
```

Backend Git

L'implémentation par défaut pour stocker les valeurs de configuration est un dépôt Git spécifié par : ***spring.cloud.config.server.git.uri***

Le répertoire de clonage est spécifié par : ***spring.cloud.config.server.git.basedir***

Le paramètre *{label}* est alors associé à une référence *git* (id de commit, branche ou tag)

Sécurité

Pour utiliser l'authentification basique HTTP, il suffit de préciser les propriétés :

- *spring.cloud.config.server.git.username*
- *spring.cloud.config.server.git.password*

Pour utiliser *ssh*, le plus simple est d'installer une clé publique sur le serveur

Backend de fichiers

Le serveur peut également charger les configurations à partir du classpath ou du système de fichiers

Il faut alors

- activer le profil ***native***
- et d'indiquer la propriété ***spring.cloud.config.server.native.searchLocations*** qui spécifie l'emplacement racine
  - soit à partir du classpath *classpath:/config*
  - Soit à partir du système de fichiers *file:./config*

Exemple Classpath

```
@SpringBootApplication
@EnableConfigServer
public class ConfigApplication {
  public static void main(String[] args) {
    SpringApplication.run(ConfigApplication.class, args);
  }
}
---
spring:
  cloud:
    config:
      server:
        native:
          search-locations: classpath:/shared
  profiles:
    active: native
```

Arborescence serveur

Le répertoire racine sur le seveur contient alors :

- ***application.yml*** : Valeurs de configuration partagées par tous les micro-services
- Des fichiers ***<application-name>.yml*** : Valeurs de configuration pour le micro-service <*application-name*>
- ***<application-name>-<profil>.yml*** : Des fichiers spécifiques à un profil[1].

1. Les profils peuvent également être spécifiés dans <application-name>.yml

Endpoints proposés

Une fois démarré le serveur propose les endpoints suivants :

- ***/application/default*** : Les propriétés partagées pars tous les micro-services
- ***/{application-name}/default*** : Les propriétés d'un service donné dans le profil par défaut
- ***/{application-name}/profil*** : Les propriétés d'un service donné dans un profil donné.

Usage client

Les clients dépendent de :

spring-cloud-config-client

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-config</artifactId>
</dependency>
```

Ils définissent l'adresse du serveur de configuration (par défaut localhost:8888) via la propriété :

spring.cloud.config.uri: http://myconfigserver.com

Configurations optionnelles

Si l'on veut interdire le démarrage en cas de non contact du serveur de configuration :

`spring.cloud.config.failFast=true`

Si on veut autoriser plusieurs tentatives de connexions :

- `spring-retry` et `spring-boot-starter-aop` dans le classpath
- puis les propriétés `spring.cloud.config.retry.*`

L'emplacement par défaut des configurations (`/{name}/{profile}/{label}`) peut être surchargé par `spring.cloud.config.*`

Propriétés des micro-services

Les propriétés de configuration des micro-services sont donc présents à 2 endroits :

- ***bootstrap.yml*** : Présent en local, il ne contient en général que :
  - *spring.application.name*
  - La configuration du serveur de config
- Fichiers sur le serveur de config :
  - propriétés communes des micro-services,
  - propriétés spécifiques application
  - spécifique profil

Changement dynamique d’environnement

Si la configuration est modifiée (fichier de config modifié ou *push git*), celle-ci peut être répercutée dynamiquement sur les clients du serveur de config

Lors d’une modification, un événement de type *EnvironmentChangeEvent* est généré

- Il contient la liste des clés de configuration qui ont changées.
- Les clients ne détectent pas automatiquement les changements. On peut alors utiliser :
  - ***Spring Cloud Bus*** pour pousser les événements automatiquement vers les services
  - ***Actuator*** et une requête POST pour demander le rafraîchissement d’un micro-service

Utilisation d'Actuator

Le endpoint refresh d'actuator doit être activée.

Une requête POST sur ***/actuator/refresh*** permet de à certains beans Spring de recharcher leur configuration.

- Les beans applicatifs voulant se recharger doivent être annotés par ***@RefreshScope***

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec *OpenFeign*
Gateway et routing
Consumer Driven Contract

Clients REST

Dans cette architecture un micro-service est souvent le client REST d'un autre micro-service

Les clients doivent avoir des capacités :

- De répartition dynamique de charge
- De résilience (code alternatif en cas de dysfonctionnement du serveur)

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract

Introduction

La répartition de charge côté client consiste à interroger le service de *Discovery* pour connaître les instances disponibles et appliquer un algorithme de répartition (ex. Round Robin) pour répartir les requêtes.

- Cela peut être fait directement en utilisant l'API DiscoveryClient
- Ou en utilisant l'API *spring-cloud-loadbalancer* de SC Commons

Implémentation via *DiscoveryClient*

```
@Autowired
DiscoveryClient discoveryClient;

…

List<ServiceInstance> instances =
  discoveryClient.getInstances("another-service");

Instance instance = _chooseOneInstance(instances);
String url = "http://"+instance.getHost()
  +":"+instance.getPort();

restTemplate.rootUri(url);

...
```

Spring Cloud LoadBalancer

Spring Cloud fournit sa propre abstraction et implémentation d'équilibreur de charge côté client.

Le client Rest découvre les instances disponibles à partir du service de discovery.

- Il utilise le bean *DiscoveryClient* disponible dans le classpath
- Il peut également utiliser une librairie de cache (par défaut *Caffeine*)

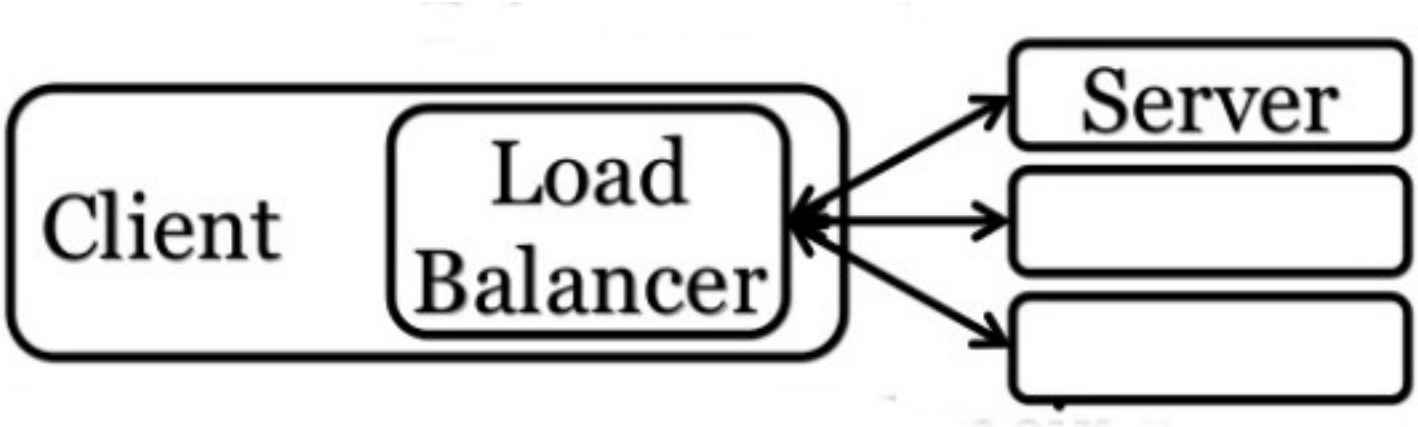

Avantages Client-side

Avec l'équilibrage de charge côté client, c’est le client qui décide quel nœud reçoit la requête car il connaît la topologie.

Théroriquement, ll peut en amont éviter de surcharger un service qui est trop chargé ou inaccessible .

Dépendances

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-loadbalancer</artifactId>
</dependency>
< !-- Plus discovery client, par exemple -->
<dependency>
<groupId>org.springframework.cloud</groupId>
<artifactId>spring-cloud-starter-netflix-eureka-client</artifactId>
</dependency>
```

@LoadBalanced

Il suffit d'annoter un bean de type *RestTemplate* avec ***@LoadBalanced*** pour bénéficier de l'implémentation sous-jacente de l'interface de *Spring Cloud Commons* .

Par défaut, l'implémentation legacy Ribbon sauf si : *spring.cloud.loadbalancer.ribbon.enabled: false*

```
@Configuration
public class ClientConfiguration {

@Autowired
RestTemplateBuilder builder;

@Bean
@LoadBalanced
RestTemplate restTemplate() {
  return builder.build();
}}
```

@LoadBalanced Pile réactive

Dans un contexte réactive la même annotation ***@LoadBalanced*** est utilisée

- L'annotation se place sur une méthode fournissant un ***WebClient.Builder.***
- Le builder permet de construire un ***WebClient***
- Le *WebClient* est utilisé pour effectuer les requêtes Rest

Exemple

```
    @Bean
    @LoadBalanced
    WebClient.Builder builder() {
        return WebClient.builder();
    }

    @Bean
    WebClient webClient(WebClient.Builder builder) {
        return builder.build();
    }

// Utilisation du bean
Flux<Greeting> call(String url) {
    return
  webClient.get().uri(url).retrieve().bodyToFlux(Greeting.class);
}
```

Usage

```
@Log4j2
@Component
class ConfiguredWebClientRunner {


  ConfiguredWebClientRunner(WebClient http) {
    call(http, "http://api/greetings").subscribe(
   greeting -> log.info("configured: " + greeting.toString()));
    }
}
```

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract

Contexte du pattern

Lorsqu'un service en appelle un autre de manière synchrone, il est toujours possible que l'autre service ne soit pas disponible ou présente une latence si élevée qu'il est essentiellement inutilisable. Des ressources précieuses telles que des threads peuvent être consommées dans l'appelant en attendant que l'autre service réponde. Cela pourrait conduire à l'épuisement des ressources, ce qui rendrait le service appelant incapable de traiter d'autres demandes. La défaillance d'un service peut potentiellement se répercuter sur d'autres services dans l'application.[1]

https://microservices.io/patterns/reliability/circuit-breaker.html

Solution

Un client doit invoquer un service distant via un proxy qui fonctionne de la même manière qu'un disjoncteur électrique.

- Lorsque le nombre de défaillances consécutives dépasse un seuil, le disjoncteur se déclenche et, pendant la durée d'un délai d'expiration, toutes les tentatives d'appel du service distant échouent immédiatement.
- Une fois le délai expiré, le disjoncteur autorise le passage d'un nombre limité de demandes de test. Si ces demandes aboutissent, le disjoncteur reprend son fonctionnement normal. Sinon, en cas d'échec, le délai d'expiration recommence.

Spring Cloud Breaker Pattern

Spring Cloud Breaker fournit une abstraction et donc une API cohérente à utiliser pour les librairies implémentant le pattern circuit breaker. Il supporte :

- Netfix Hystrix
- Resilience4J
- Sentinel
- Spring Retry

Concepts cœur

Pour utiliser le pattern dans son application, Spring Cloud injecte un ***CircuitBreakerFactory*** en fonction des starters trouvés dans le classpath.

Sa méthode *create()* permet de définir une classe ***CircuitBreaker*** dont la méthode *run()* prend 2 lambda en arguments :

- Le code à exécuter dans l'autre thread
- Optionnellement, un code de fallback

Exemple

```
@Service
public static class DemoControllerService {
private RestTemplate rest;
private CircuitBreakerFactory cbFactory;


public DemoControllerService(RestTemplate rest, CircuitBreakerFactory cbFactory) {
this.rest = rest;
this.cbFactory = cbFactory;
}


public String slow() {
return cbFactory.create("slow").run(() -> rest.getForObject("/slow",
   String.class), throwable -> "fallback");
}


}
```

Patterns Resilience4J

Retry : Répéter les exécutions échouées
De nombreux fautes sont transitoires et peuvent s'auto-corriger après un court délai.

Circuit Breaker : blocages temporaires des défaillances possibles
Lorsqu'un système éprouve de sérieuses difficultés, il est préférable d'échouer rapidement que d'attendre les clients.

Rate limiter : Limiter les exécutions
Limitez le taux des requêtes

Time Limiter : Limiter le temps d'exécution des requêtes
Au-delà d'un certain intervalle d'attente, un résultat positif est peu probable

Bulkhead : Limiter les exécutions concurrentes
Les ressources sont isolées dans des pools de sorte que si l'une échoue, les autres continuent de fonctionner.

Cache : Mémoriser un résultat réussi
Une partie des demandes peut être similaire.

Fallback : Fournir un résultat alternatif pour les échecs
Les choses échoueront toujours - planifiez ce que vous ferez lorsque cela se produira.

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract

Introduction

Feign est un client de service REST déclaratif, facilitant le développement.

Pour utiliser *Feign*, juste créer une interface et l'annoter !

Il offre un support pour des annotations pluggable, les annotations JAX-RS, des dés/encodeurs pluggable

Mise en place

spring-cloud-starter-feign

```
@SpringBootApplication
@EnableEurekaClient
@EnableFeignClients
public class Application {

    public static void main(String[] args) {
        SpringApplication.run(Application.class, args);
    }

}
```

Client

```
// « stores » : client nommé correspondant au service
// Eureka
@FeignClient("stores")
public interface StoreClient {
    @RequestMapping(method = RequestMethod.GET, value = "/stores")
    List<Store> getStores();


    @RequestMapping(method = RequestMethod.POST, value =
   "/stores/{storeId}", consumes = "application/json")
    Store update(@PathVariable("storeId") Long storeId, Store store);
}
```

Utilisation avec *Feign*

Si *Hystrix* est dans le classpath, toutes les méthodes d'une interface *@FeignClient* sont encapsulées dans une méthode *HystrixCommand*

- Pour activer/désactiver ce comportement : ***feign.hystrix.enabled=true|false***
- Pour configurer la commande de fallback il faut renseigner
  - Soit l'attribut ***fallback*** en indiquant un bean implémentant l'interface
  - Soit l'attribut ***fallbackFactory***

Exemple avec *Feign et fallback*

```
@FeignClient(name = "hello", fallback = HystrixClientFallback.class)
protected interface HystrixClient {
    @RequestMapping(method = RequestMethod.GET, value = "/hello")
    Hello iFailSometimes();
}


@Service
class HystrixClientFallback implements HystrixClient {
    @Override
    public Hello iFailSometimes() {
        return new Hello("fallback");
    }
}
```

Exemple avec *Feign et fallbackFactory*

```
@FeignClient(name = "hello", fallbackFactory = HystrixClientFallbackFactory.class)
protected interface HystrixClient {
@RequestMapping(method = RequestMethod.GET, value = "/hello")
Hello iFailSometimes();
}

@Component
static class HystrixClientFallbackFactory implements
  FallbackFactory<HystrixClient> {
@Override
public HystrixClient create(Throwable cause) {
  return new HystrixClientWithFallBackFactory() {
    @Override
    public Hello iFailSometimes() {
      return new Hello("fallback; reason was: " + cause.getMessage());
    }
  };
}
}
```

Indicateurs de santé

D’autre part, le statut des disjoncteurs sont exposés via l’endpoint ***/health***

```
{
    "hystrix": {
        "openCircuitBreakers": [
            "StoreIntegration::getStoresByLocationLink"
        ],
        "status": "CIRCUIT_OPEN"
    },
    "status": "UP"
}
```

Il faut avoir activé *spring-actuator* dans les dépendances

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract

Introduction

Le pattern ***API Gateway*** permet à un client nécessitant plusieurs services de back-end de ne s’adresser qu’à **un seul** service.

La gateway route alors les requêtes vers les back-end implémentant les services demandés

En plus des fonctionnalités de routing, la gateway peut intégrer des services transverses à toute l’architecture micro-service : authentification, CORS, filtrage d’entêtes HTTP, ...

Spring Cloud Routing

Spring Cloud Routing propose 2 starters dédiés aux fonctionnalités de routing

- Netflix Zuul (Projet en maintenance)
- Spring Cloud Gateway

Caractéristiques Spring Cloud Gateway

- Construit sur Spring Framework 5, Project Reactor et Spring Boot 2.0
  => Netty et modèle réactif exclusivement
- Capable de faire correspondre les routes en fonction de n'importe quel attribut de requête.
- Les filtres sont spécifiques aux routes.
- Intégration du disjoncteur Hystrix.
- Intégration Spring Cloud DiscoveryClient
- Possibilité de limiter la cadence des requêtes
- URL rewriting

Exemple gateway

```
@Bean
public RouteLocator myRoutes(RouteLocatorBuilder builder) {
    return builder.routes()
// Routing + ajout d’entête
        .route(p -> p
            .path("/get")
            .filters(f -> f.addRequestHeader("Hello", "World"))
            .uri("http://httpbin.org:80"))
// Utilisation de Hystrix
        .route(p -> p
            .host("*.hystrix.com")
            .filters(f -> f.hystrix(config -> config
                .setName("mycmd")
                .setFallbackUri("forward:/fallback")))
            .uri("http://httpbin.org:80"))
        .build();
}
```

Intégration avec *DiscoveryClient*

Pour créer des routes vis à vis des services enregistrés dans le serveur de discovery :

```
spring.cloud.gateway.discovery.locator.enabled=true
```

Par défaut, des routes sont définies pour chaque service enregistrés

Les URLs ***/serviceId/****** sont routées vers le service en enlevant le préfixe

Zuul routing

Zuul Routing (également Netflix) permet d'automatiquement mapper des routes (URLs) vers des services enregistrés

=> Pas de configuration

=> Peut ajouter des filtres, etc.

Il inclut également Ribbon et son répartiteur de charge

Les règles de routage sont exprimées dans des langages JVM (essentiellement Java et Groovy)

Cas d’usage

Netflix utilisait *Zuul* pour :

- L’authentification et la sécurité
- Des tests de stress
- Canary Testing : Déploiement de nouvelles fonctionnalités sur un ensemble restreint d’utilisateurs
- Du délestage de charge
- Du routage dynamique
- De la migration de service
- Le traitement des réponses statiques
- Gestion active du trafic

Mise en place *SpringBoot*

Starter : zuul

```
@SpringBootApplication
@EnableDiscoveryClient
@EnableZuulProxy
public class ProxyApplication {

public static void main(String[] args) {
SpringApplication.run(ProxyApplication.class, args);
}

}
```

Fonctionnement par défaut

Le proxy utilise *Ribbon* pour localiser un instance

Toutes les requêtes sont exécutées dans une commande *Hystrix*

- => Ainsi, les erreurs sont remontées dans les métriques Hystrix
- => Une fois que le circuit est ouvert, le proxy n'essaie plus de contacter le service.

Par défaut, un service nommé ***users*** reçoit les requêtes de ***/users***

Configuration

```
# Tous les services sont ignorés à l'exception de users,
# on utilise par défaut Ribbon et Hystrix
zuul:
  ignoredServices: '*'
  routes:
    users: /myusers/**

# Alternative avec serviceId, Ribbon et Hystrix doivent être configurés manuellement
zuul:
  routes:
    users:
      path: /myusers/**
      serviceId: users_service

# Ou, sans service de Discovery, Ribbon et Hystrix doivent être configurés manuellement
zuul:
  routes:
    users:
      path: /myusers/**
      url: http://example.com/users_service
```

Cookies et entête HTTP

Il est possible de spécifier une liste des entêtes à ignorer.

```
zuul.ignoredHeaders

zuul.ignoreSecurityHeaders # entêtes
  SpringSecurity
```

Les cookies pour le navigateur semblent venir tous du proxy.
=> Cela devient difficile de s'appuyer sur ces techniques à moins de partager les cookies dans tous les services de backend

Endpoint */routes*

Si Spring Actuator est activé, un nouvelle endpoint est disponible : ***/routes***

- Un *GET* affiche les routes configurées
- Un *POST* force un rafraîchissement des routes

Support pour les clients

Répartition de charge
Pattern Disjoncteur
Clients déclaratifs avec Feign
Gateway et routing
Consumer Driven Contract

Spring Cloud Contract

Spring Cloud Contract est un projet qui permet d'adopter une approche *Consumer Driven Contract*

A partir d'une spécification d'interaction entre un producteur/serveur et consommateur/client, cela permet

- De générer des tests d'acceptation côté producteur
- De créer des mocks serveur pour le client

DSL

Spring Cloud Contract et son projet projet principal ***Verifier*** fournit un **DSL** (*Groovy* ou *.yaml*) qui permet de spécifier le contrat

Le contrat permet alors de produire :

- Les définitions de stub JSON à utiliser par *WireMock* lors des tests d'intégration sur le code client.
  Le code de test doit toujours être écrit à la main mais les données de test sont produites.
- Les tests d'acceptations complets côté serveurs (*Spock* ou *JUnit*)

SCC permet également les tests de routing de message lors de l'utilisation de Spring Cloud Stream

Exemple Groovy

```
import org.springframework.cloud.contract.spec.Contract
Contract.make {
    description "should return even when number input is even"
    request{
        method GET()
        url("/validate/prime-number") {
            queryParameters {
                parameter("number", "2")
            }
        }
    }
    response {
        body("Even")
        status 200
    }
}
```

Tests générés côté serveur

```
public class ContractVerifierTest extends BaseTestClass {

@Test
public void validate_shouldReturnEvenWhenRequestParamIsEven() throws Exception {
    // given:
    MockMvcRequestSpecification request = given();

    // when:
    ResponseOptions response = given().spec(request)
      .queryParam("number","2")
      .get("/validate/prime-number");

    // then:
    assertThat(response.statusCode()).isEqualTo(200);

    // and:
    String responseBody = response.getBody().asString();
    assertThat(responseBody).isEqualTo("Even");
}
```

Tests Clients

```
@RunWith(SpringRunner.class)
@SpringBootTest(webEnvironment = SpringBootTest.WebEnvironment.MOCK)
@AutoConfigureMockMvc
@AutoConfigureJsonTesters
@AutoConfigureStubRunner(
  stubsMode = StubRunnerProperties.StubsMode.LOCAL,
  ids = "com.baeldung.spring.cloud:spring-cloud-contract-producer:+:stubs:8090")
public class BasicMathControllerIntegrationTest {

    @Autowired
    private MockMvc mockMvc;

    @Test
    public void given_WhenPassEvenNumberInQueryParam_ThenReturnEven()
      throws Exception {

        mockMvc.perform(MockMvcRequestBuilders.get("/calculate?number=2")
          .contentType(MediaType.APPLICATION_JSON))
          .andExpect(status().isOk())
          .andExpect(content().string("Even"));
    }
}
```

Monitoring

Hystrix dashboard et Turbine
Tracing avec *Spring Cloud Sleuth*
Centralisation des logs

Flux Hystrix

- Une application utilisant *Hystrix* peut générer un flux *json* permettant de surveiller les circuits
- Le flux est généré si l'application est annotée avec ***@EnableCircuitBreaker***
- Avec la version 2.x il faut également la propriété :

```
management.endpoints.web.exposure.include: hystrix.stream
```

- Le flux est alors accessible sur le endpoint ***/hystrix.stream***

Tableau de bord Hystrix

Un flux *Hystrix* fourni par un micro-service peut être visualisé graphiquement par le tableau de bord Hystrix

```
<dependencies>
  <dependency>
    <groupId>org.springframework.cloud</groupId>
    <artifactId>spring-cloud-starter-hystrix-dashboard</artifactId>
  </dependency>
</dependencies>
```

+

```
@EnableHystrixDashboard
```

=> Endpoint **/hystrix**

/hystrix

Hystrix Dashboard

http://hostname:port/turbine/turbine.stream

Cluster via Turbine (default cluster): http://turbine-hostname:port/turbine.stream
Cluster via Turbine (custom cluster): http://turbine-hostname:port/turbine.stream?cluster=[clusterName]
Single Hystrix App: http://hystrix-app:port/hystrix.stream

Delay: 2000 ms Title: Example Hystrix App

Monitor Stream

Tableau de bord

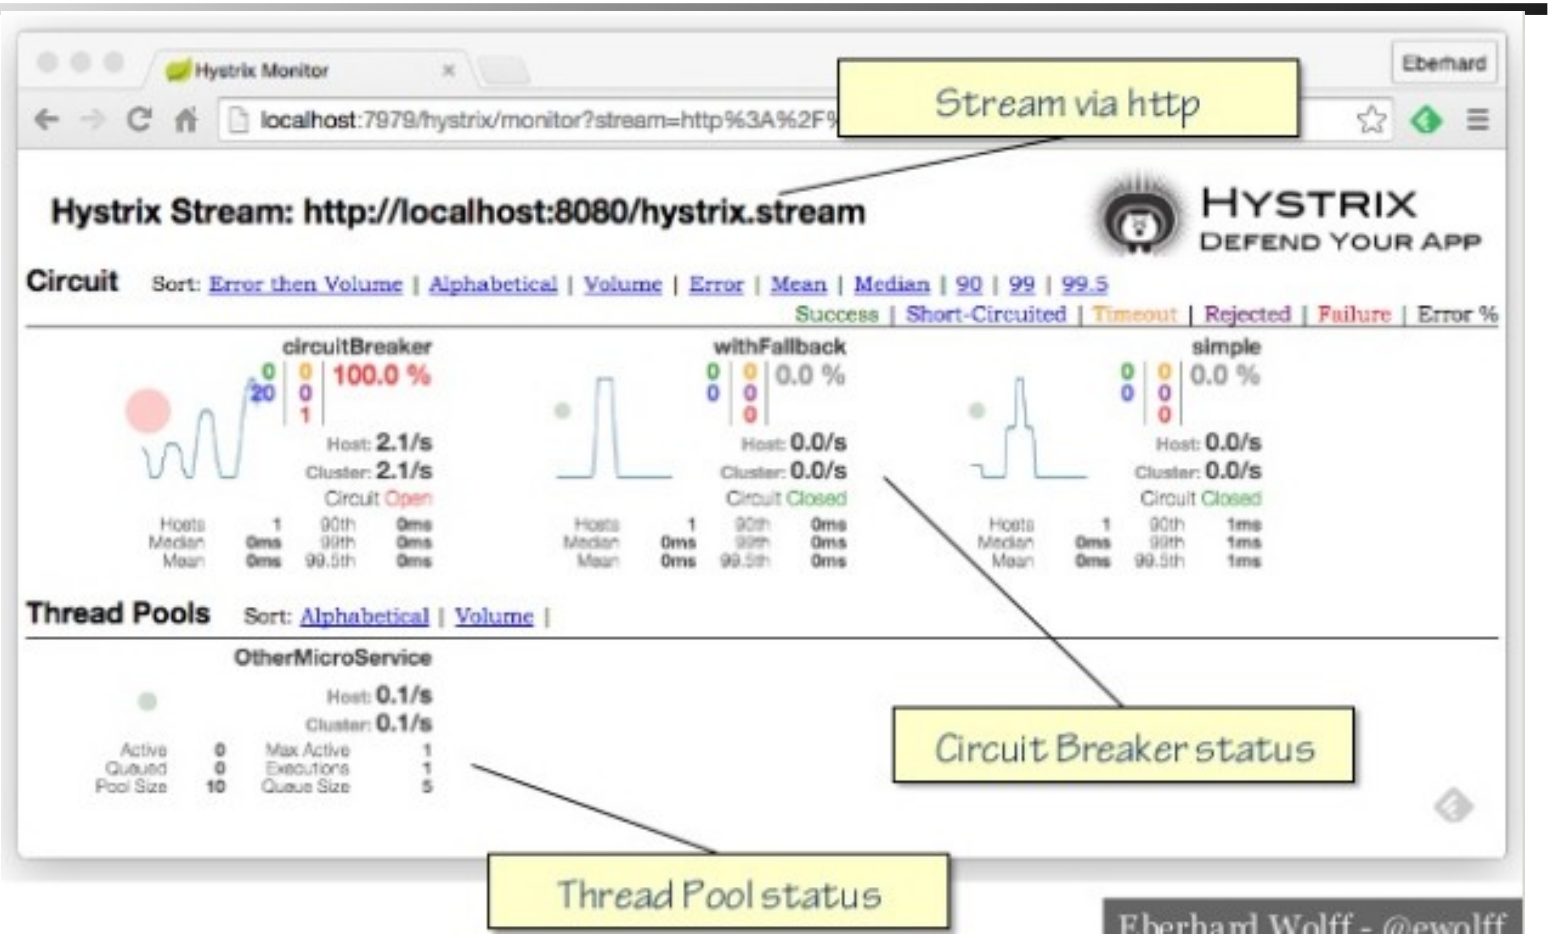

Détails dashboard

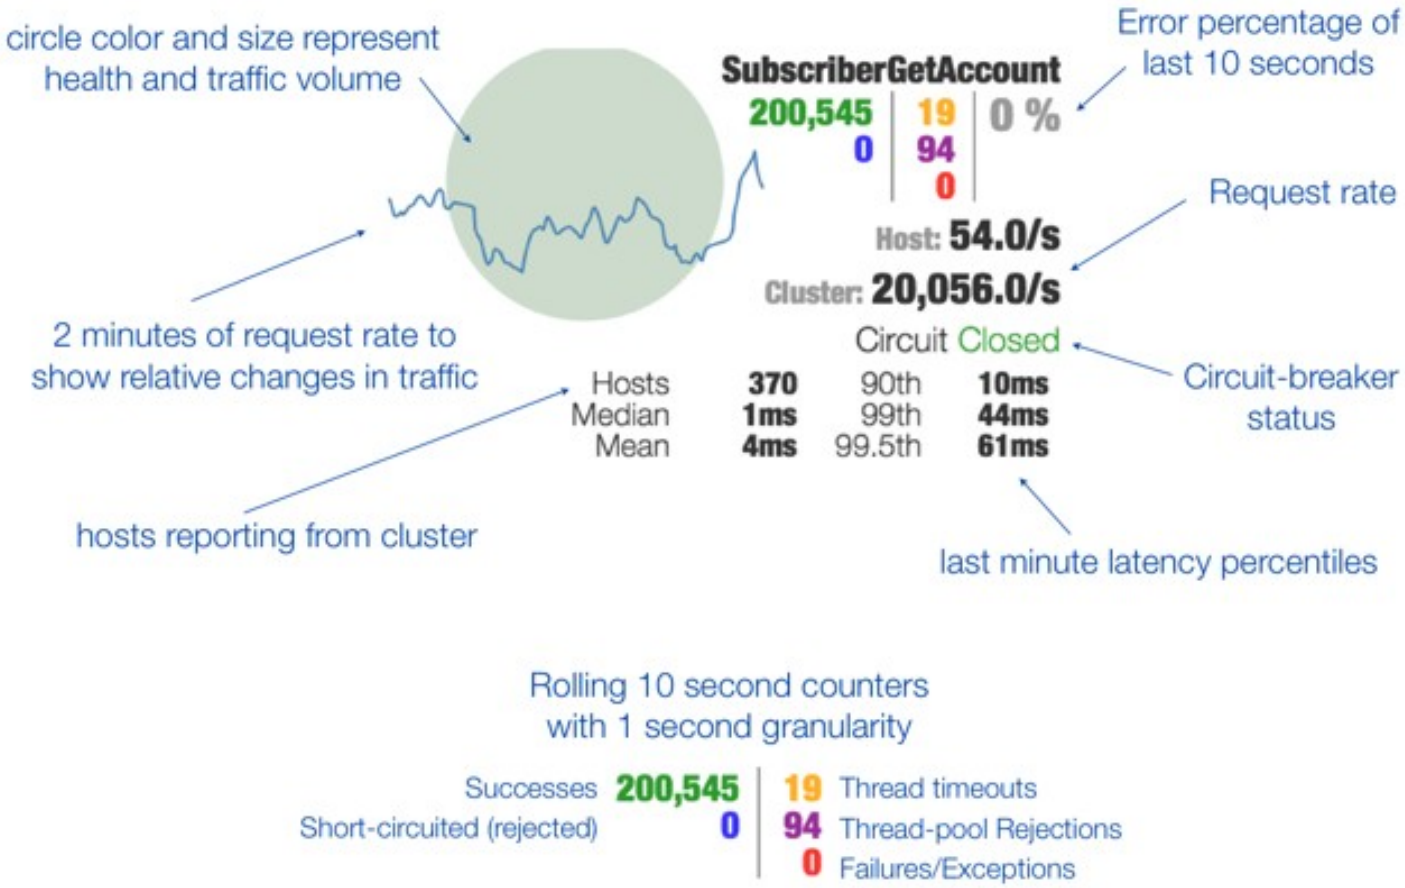

Introduction Turbine

Hystrix Dashboard fournit des informations sur une seule application

Turbine permet d'agréger les informations de toutes les applications d'un cluster

Intégration de Turbine

Ajouter les dépendances :

```
<dependency>
  <groupId>org.springframework.cloud</groupId>
  <artifactId>spring-cloud-starter-turbine</artifactId>
</dependency>
```

Autoriser Turbine dans une application SpringBoot :

```
@SpringBootApplication
@EnableHystrixDashboard
@EnableTurbine
public class MonitorApplication {
  ...
}
```

Configuration

```
turbine:
  clusterNameExpression: new String("default")
  appConfig: MEMBERS-SERVICE,PROXY-SERVICE
```

Un flux turbine pour le cluster SAMPLE-HYSTRIX-AGGREGATE est disponible à

`/turbine.stream?cluster=SAMPLE-HYSTRIX-AGGREGATE`

La constitution du cluster est déduite d'Eureka, turbine récupère les flux Hystrix de toutes les instances et les agrège

Tableau de bord Turbine

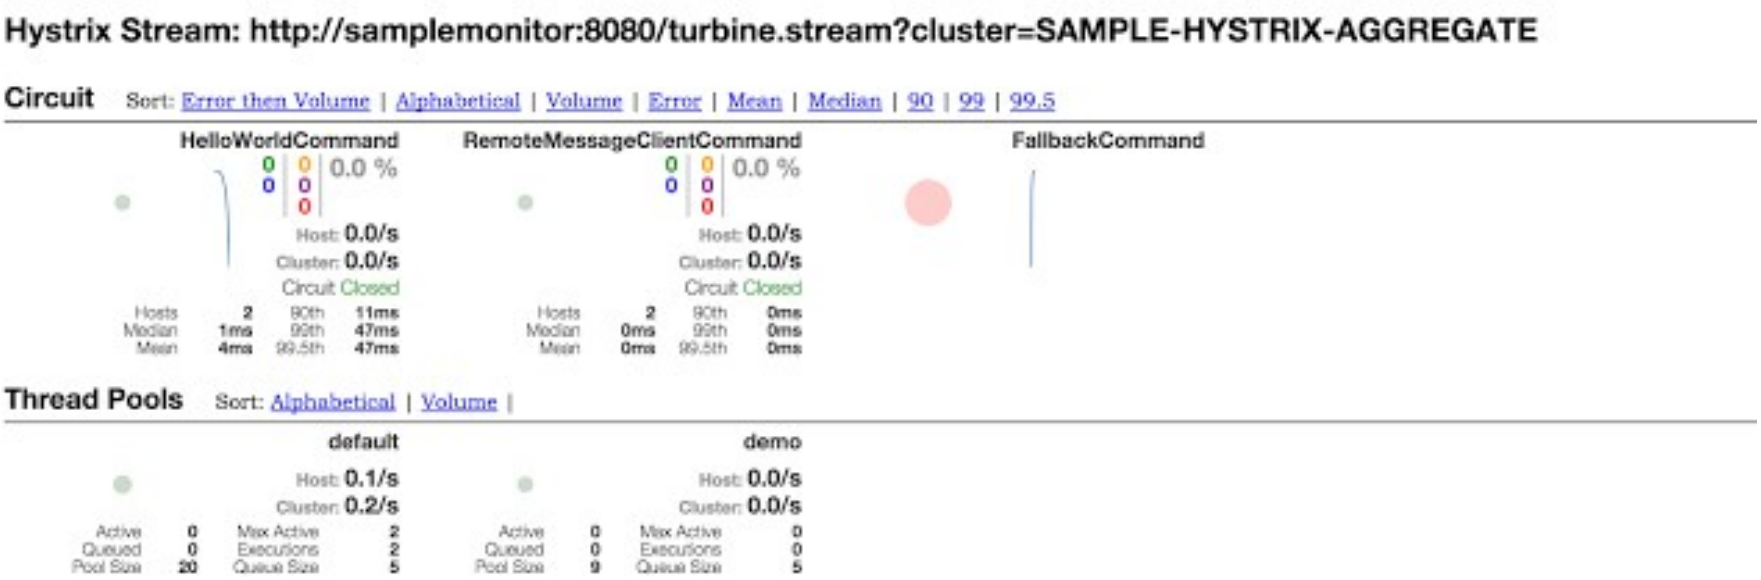

TP 4.1 : Turbine dashboard

Monitoring

Hystrix dashboard et Turbine

Tracing avec Spring Cloud Sleuth

Centralisation des logs

Introduction

Spring Cloud Sleuth permet d'ajouter dans les messages de logs des *ids* permettant de tracer un séquence d'appels de méthodes correspondant à une requête HTTP, le démarrage d'un job, une thread ...

- Il s'intègre sans effort avec *Logback* et *SLF4J* et utilise la librairie de tracing *Brave* .

Dans le cadre d'une architecture micro-services, *Sleuth* sert à tracer le cheminement d'une requête à travers tous les micro-services qu'elle a invoqué.

Vocabulaire

Sleuth définit 2 notions :

- ***Traces*** identifiant une requête unique ou le démarrage d'un job. Toutes les différentes étapes de traitement partageront le même *traceId*.
- ***Spans***, identifie une étape de traitement. Une trace peut donc être composée de plusieurs spans. *Sleuth* ajoute un *spanId* pour chaque étape de traitement

En utilisant ces Ids on peut facilement isoler les traces relatives à une requête particulière.

Mise en place

Dépendance :
`org.springframework.cloud:spring-cloud-starter-sleuth`

Impact sur les traces de l'appli :

```
2017-01-10 22:36:38.254  INFO
  [SpringApplicationName,4e30f7340b3fb631,4e30f7340b3fb631,false] 12516
  --- [nio-8080-exec-1] c.b.spring.session.SleuthController : Hello Sleuth
2017-01-10 22:51:48.664  INFO
  [SpringApplicationName,4e30f7340b3fb631,4e30f7340b3fb631,false] 12516
  --- [nio-8080-exec-1] c.baeldung.spring.session.SleuthService  : Doing some work
```

[nom application, traceId, spanId, export]

- Nom application : Propriété *spring.application.name*.
- TraceId : id affecté à une requête, un job.
- SpanId : Identifie une unité de travail. Pour la première étape *TraceId=SpanId*.
- Export : Booléen qui indique si cette trace a été exporté vers un agrégateur comme *Zipkin*.

Ajout manuel de spans

- Il est possible de manuellement créer des nouveaux spans dans une application.

```
@Autowired
private Tracer tracer;
// ...
public void doSomeWorkNewSpan() throws InterruptedException {
    logger.info("I'm in the original span");

    Span newSpan = tracer.newTrace().name("newSpan").start();
    try (SpanInScope ws = tracer.withSpanInScope(newSpan.start())) {
        Thread.sleep(1000L);
        logger.info("I'm in the new span doing some cool work that needs its own span");
    } finally {
        newSpan.finish();
    }
    logger.info("I'm in the original span");
}
```

Ajout manuel de spans (2)

Les traces deviennent.

```
2017-01-11 21:07:54.924
  INFO [SpringApplicationName,9cdebbffe8bbbade,9cdebbffe8bbbade,false] 12516
  --- [nio-8080-exec-6] c.b.spring.session.SleuthController      : New Span
2017-01-11 21:07:54.924
  INFO [SpringApplicationName,9cdebbffe8bbbade,9cdebbffe8bbbade,false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService  :
  I'm in the original span
2017-01-11 21:07:55.924
  INFO [SpringApplicationName,9cdebbffe8bbbade,1e706f252a0ee9c2,false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService  :
  I'm in the new span doing some cool work that needs its own span
2017-01-11 21:07:55.924
  INFO [SpringApplicationName,9cdebbffe8bbbade,9cdebbffe8bbbade,false] 12516
  --- [nio-8080-exec-6] c.baeldung.spring.session.SleuthService  :
  I'm in the original span
```

Zipkin

Zipkin est un projet open-source qui permet de recevoir et visualiser des traces.

Il est disponible :

- Sous forme de jar
- Ou d'image docker *openzipkin/zipkin*

Architecture

- Chaque micro-service exporte ses spans vers le serveur *Zipkin*
- Le serveur les stocke et propose une interface permettant de consulter les traces

Interface Zipkin

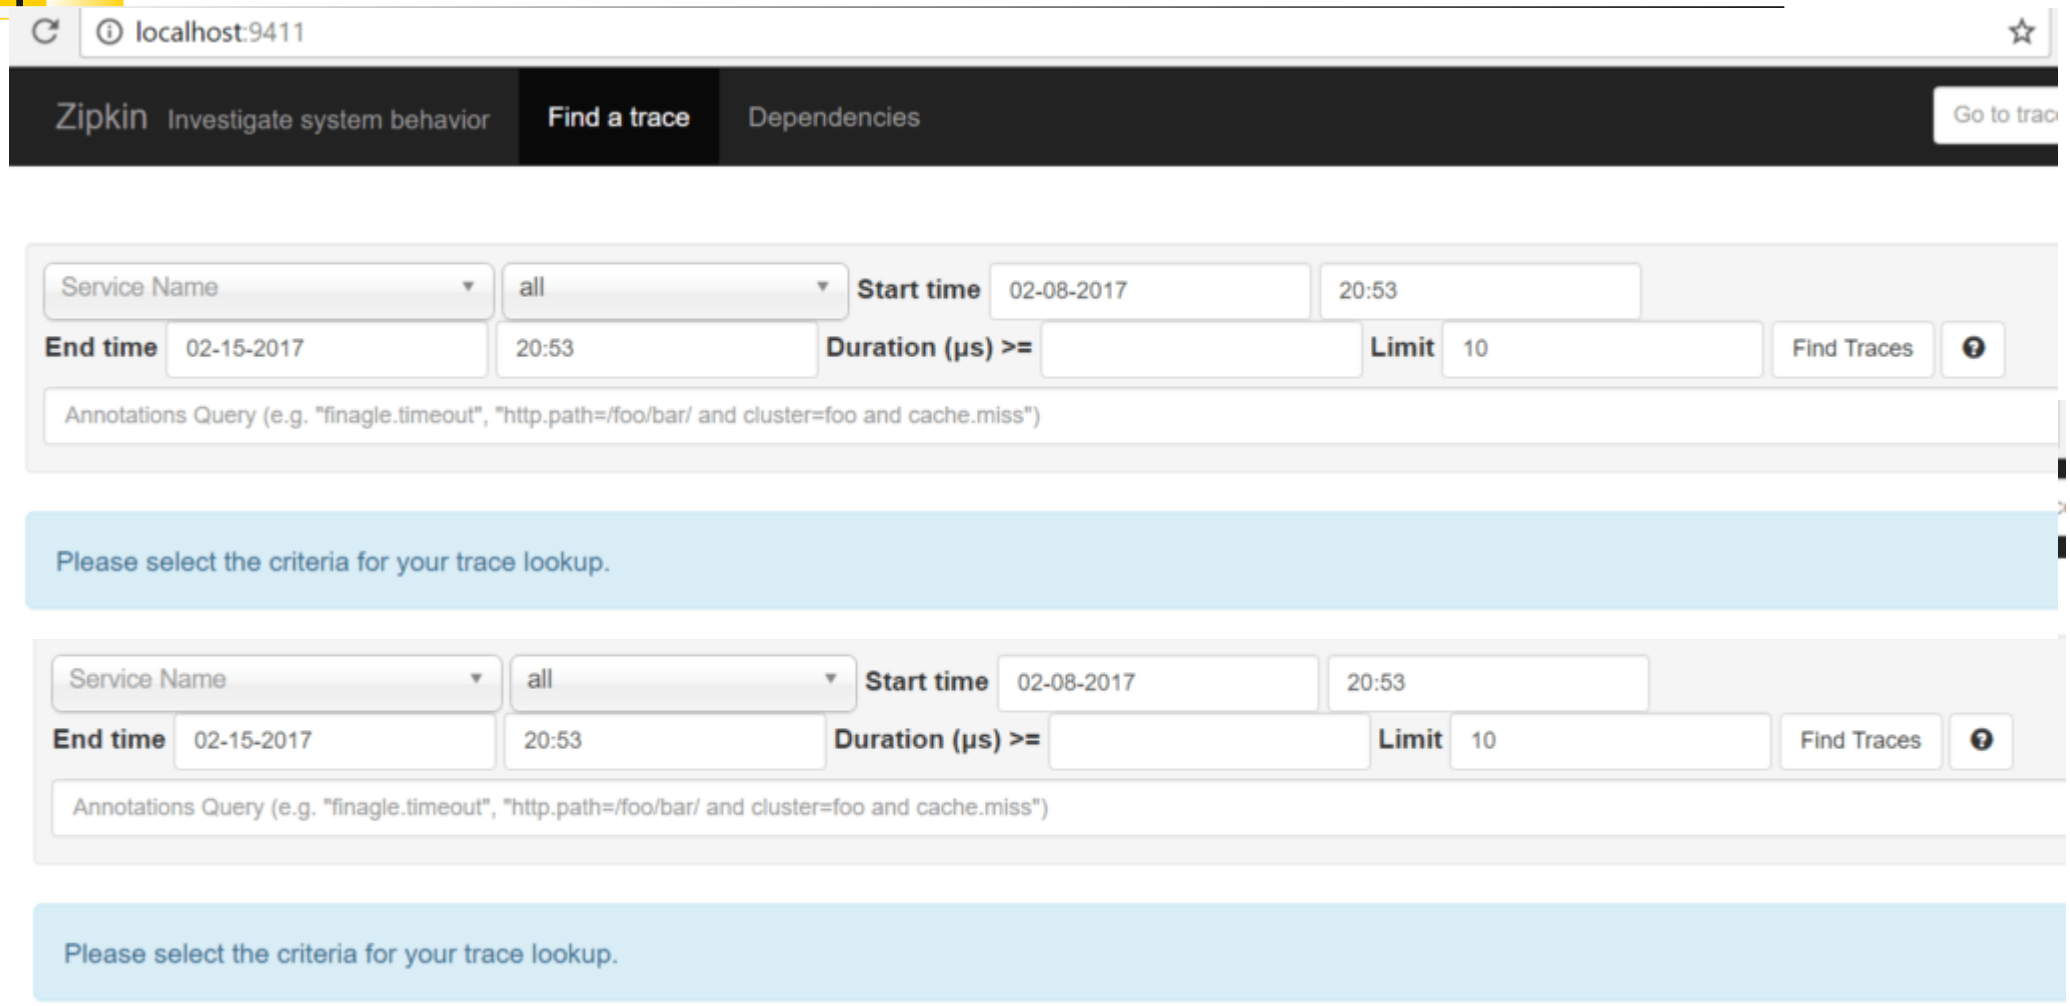

Configuration des services

- Dans un contexte SpringCloud, chaque service doit ajouter la dépendance :
  `org.springframework.cloud:spring-cloud-starter-zipkin`
- Et doit déclarer dans sa configuration l'URL Zipkin

```
spring:
  zipkin:
    base-url: http://zipkin:9411/
  sleuth:
    sampler:
      probability: 1
```

TP 4.2 : Tracing avec sleuth et Zipkin

Monitoring

Hystrix dashboard et Turbine
Tracing avec Spring Cloud Sleuth
Centralisation des logs

Gestion des logs

Une préconisation pour le développement des micro-services est qu’il ne ne se préoccupe jamais du routage ou du stockage de son flux de sortie.
=> Ne doit pas tenter d’écrire ou de gérer des fichiers journaux.

Au lieu de cela, chaque micro-service écrit son flux d’événements sur stdout.

En production, chaque flux est capturé par l'environnement d'exécution, assemblé avec tous les autres flux de la stack et acheminé vers une ou plusieurs destinations finales pour visualisation et archivage à long terme.

Elastic Stack

Une des solutions les plus courantes pour centraliser, visualiser et analyser les traces est la solution *ElasticStack*

Cette pile est constituée de :

- ***Beats*** : convoyeurs de données installés avec les applications SpringBoot
- ***Logstash*** : Micro-service chargé de normaliser les différentes traces et de les soumettre à un ElasticSearch
- ***ElasticSearch*** : Micro-service permettant d'indexer les traces et offrant des fonctionnalités de recherche et d'agrégation
- ***Kibana*** : Application front-end offrant une UI pour l'analyse

Architecture en cluster

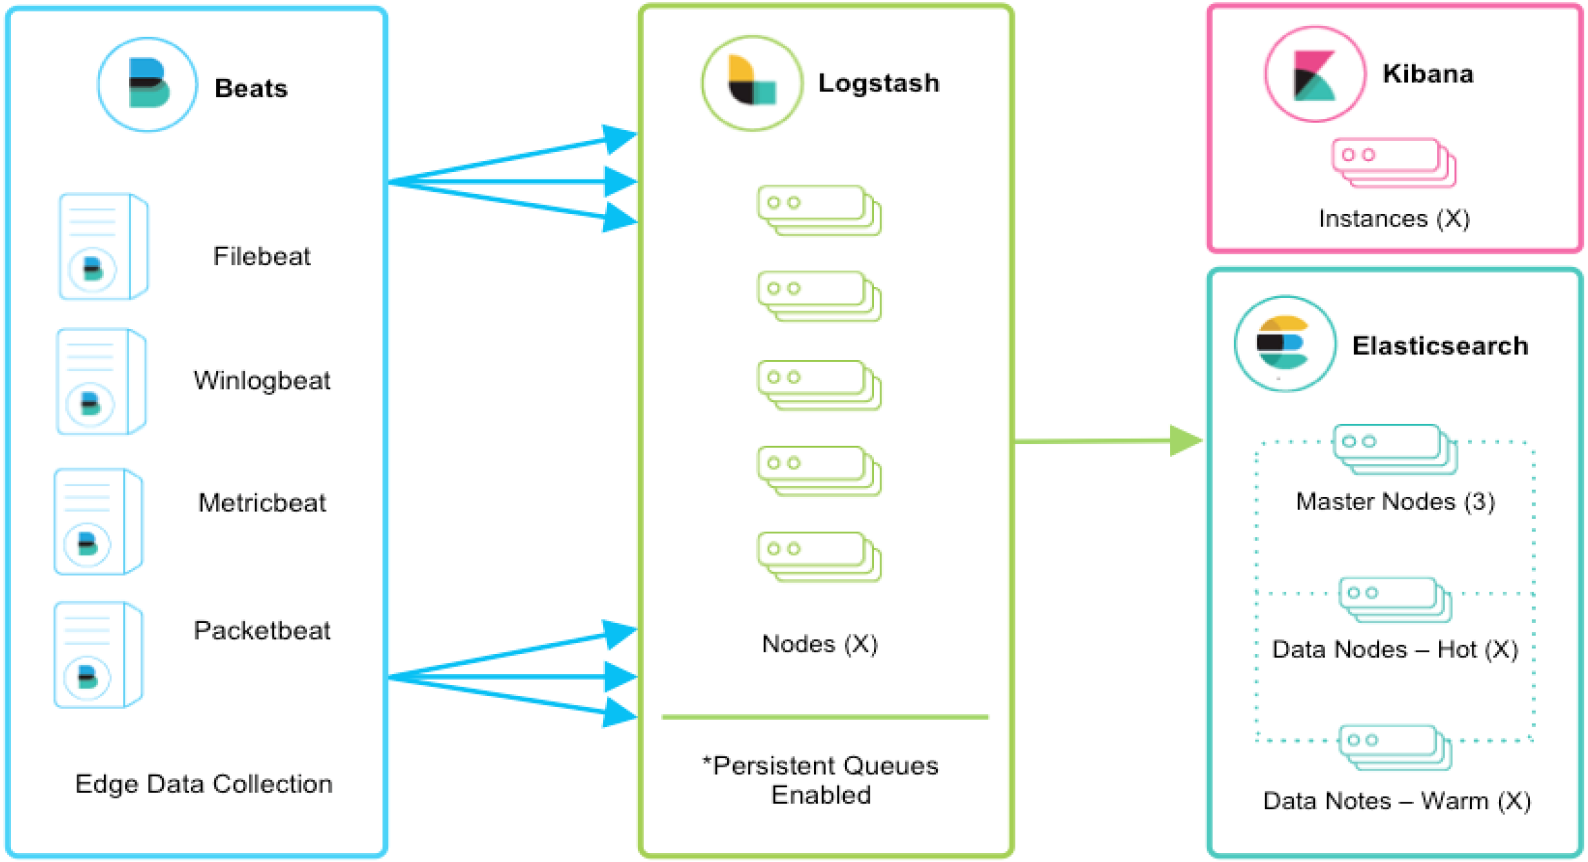

Messaging

Spring Cloud Stream
Spring Cloud Data Flow

Introduction

Spring Cloud Stream est le framework pour construire des applications micro-service pilotées par des flux de messages.

- Utilise *Spring Boot* et *Spring Integration* pour la connectivité avec les messages brokers
- Repose sur les concepts de
  - *topic persistant* (*publish/subscribe*),
  - groupe de consommateurs
  - et de partitions

Exemple d’architecture

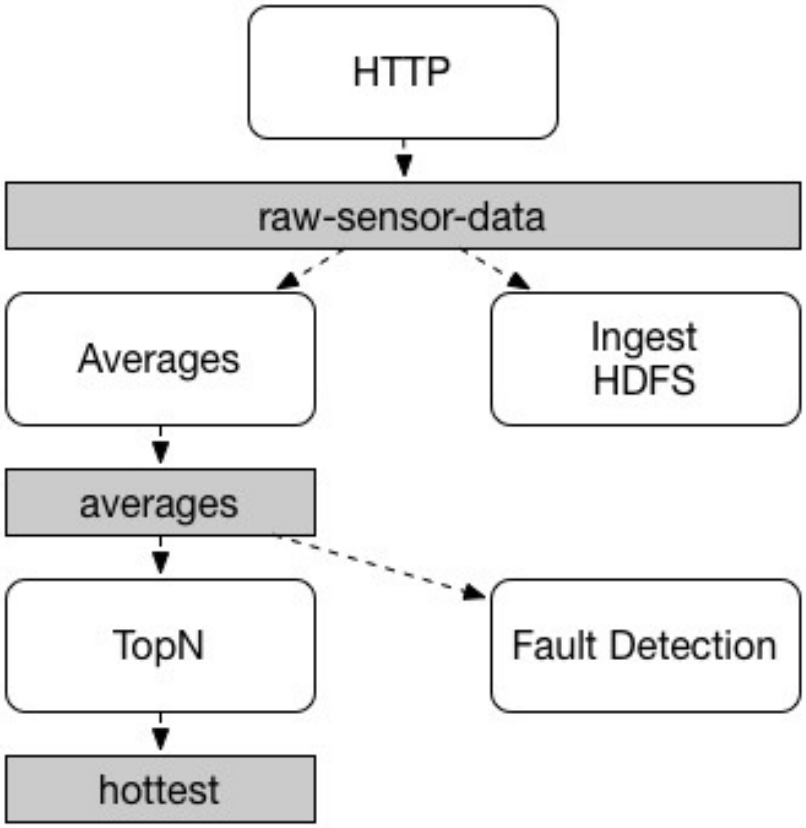

Utilisation

Starter : ***spring-cloud-stream***

- Une ou plusieurs **interfaces** déclarant les canaux d'entrée et/ou de sortie
- ***@EnableBinding*** pour auto-configurer la connectivité des canaux avec le système de messagerie sous-jacent
- ***@StreamListener*** sur les méthodes voulant réagir à un flux
- Utilisation de l'API ***MessageChannel*** pour envoyer des messages

Exemple

```
@SpringBootApplication
@EnableBinding(Sink.class)
public class VoteRecordingSinkApplication {

  public static void main(String[] args) {
    SpringApplication.run(VoteRecordingSinkApplication.class, args);
  }

  @StreamListener(Sink.INPUT)
  public void processVote(Vote vote) {
      votingService.recordVote(vote);
  }
}
-----
public interface Sink {
  String INPUT = "input";

  @Input(Sink.INPUT)
  SubscribableChannel input();
}
```

Concepts principaux

- Les applications Cloud Stream se basent sur la présence d'un **middleware neutre**
- Elles communiquent avec l'extérieur à travers des **canaux** (channels) d'entrée / sortie
- Les canaux sont associés à des systèmes de messagerie (Kafka, RabbitMQ, ...) à travers des **binders spécifiques** à l'implémentation

Architecture

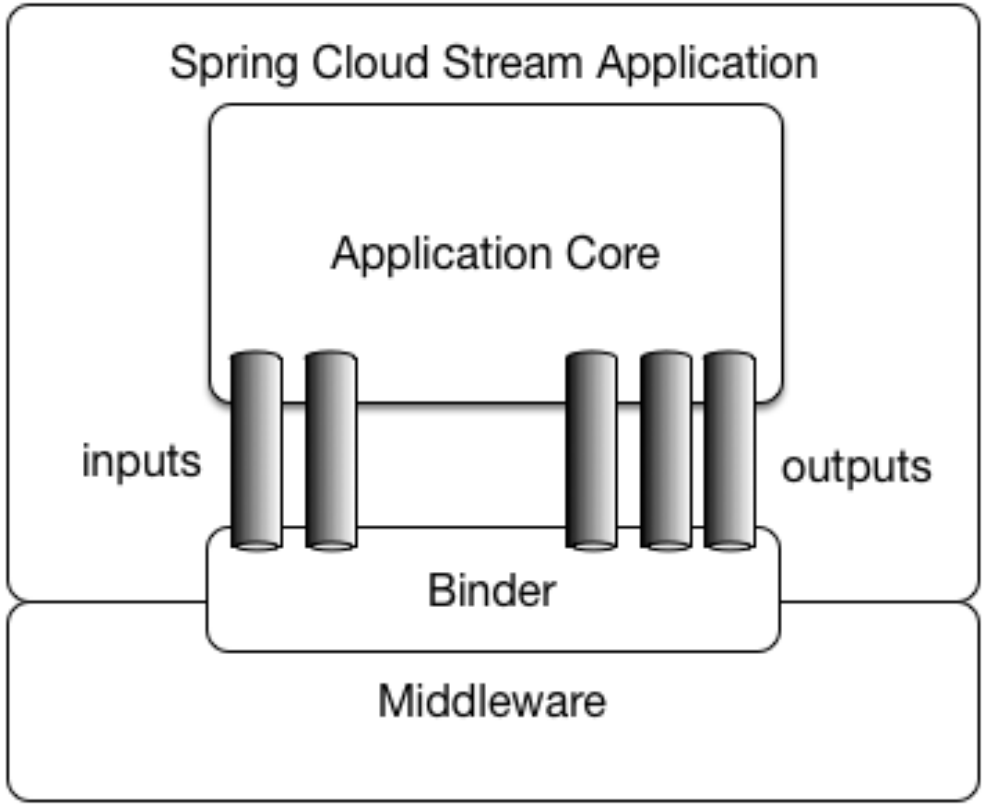

Publish & Subscribe

La communication entre applications suit un modèle ***publish-subscribe***, les données sont alors diffusées à travers des topics partagés

La notion de **groupe de consommateurs** permet la scalabilité

- Un message n'est reçu que par un seul membre du groupe

Par défaut, les topics sont **durables**.
Ce qui garantit la livraison des messages mêmes si les consommateurs sont arrêtés au moment de l'émission

Partitionnement

- Spring Cloud Stream supporte le **partitionnement** des messages
- Cela garantit que les messages identifiés par une caractéristique commune seront traités par la même instance de consommateur (Modèle *stateful*)

Modèle de programmation

@EnableBinding configure la connectivité

@Input et ***@Output*** dans des interfaces définissent les canaux d'entrée.

Spring fournit 3 interfaces. *Source :* 1 seul canal de sortie, *Sink* 1 seul canal d'entrée et *Processor* les 2 types de canaux

Les implémentations de ces interfaces ou directement les canaux peuvent être **injectées** permettant l'envoi de message par exemple

Les annotations de Spring Integration ou ***@StreamListener*** (plus simple) peuvent être utilisées pour traiter les messages

Également du support pour des API reactive, ou l'agrégation d'application (plus de messagerie)

Messaging

Spring Cloud Stream

Spring Cloud Data Flow

Introduction

Domaine d’usage : Traitement de données par flux et traitement par lots basé sur des Microservices pour Cloud Foundry et Kubernetes.

Spring Cloud Data Flow fournit des outils permettant de créer des pipelines des traitement de données par lots.

- Les pipelines sont constitués d'applications Spring Boot, construites à l'aide de Spring Cloud Stream ou Spring Cloud Task.

Cas d’utilisation : ETL, import/export, traitement en continu d’évènements, analyse prédictive, ...

Architecture

L’architecture de l’offre est composée de 2 composants :

- ***Data Flow Serveur*** : Contient la bibliothèque des micro-services de base et les pipelines de traitement
- ***Skipper Serveur*** : S’occupe des déploiements dans les environnements Cloud à partir de repository d’artefact

Architecture

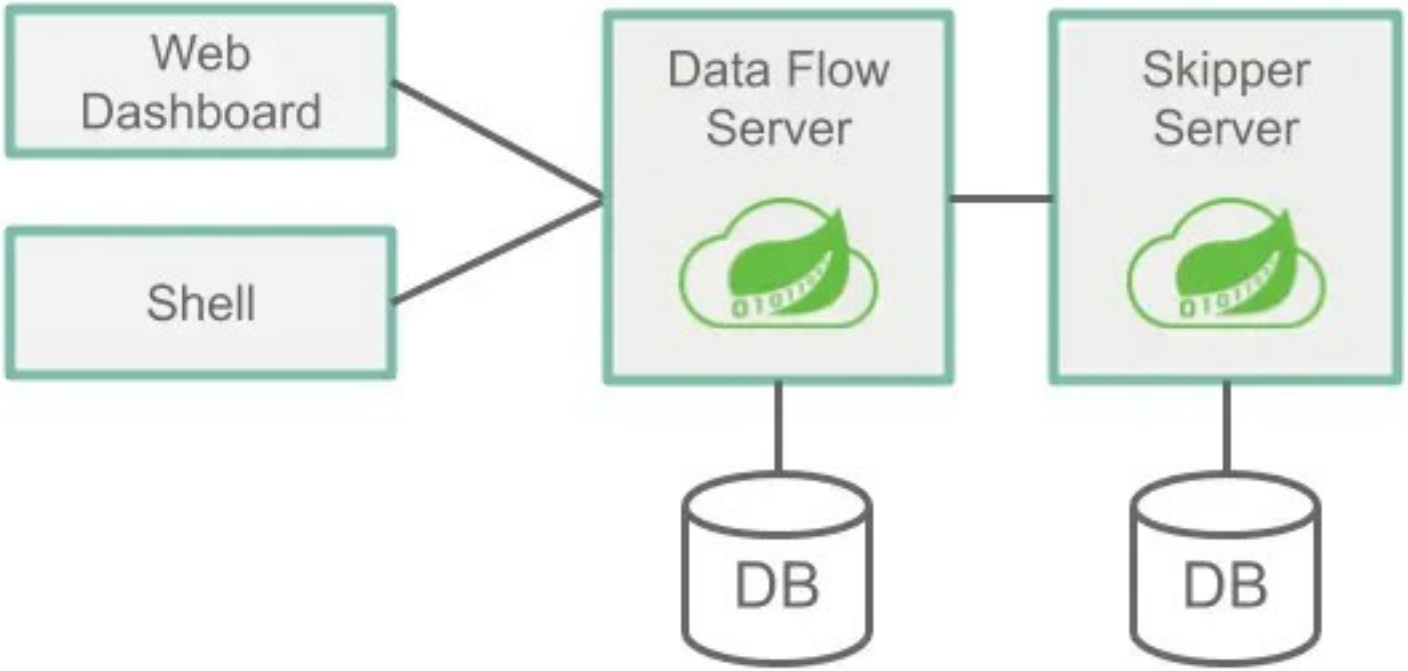

DataFlow Serveur

- Parse, valide, aide à l’édition et stocke les définitions de flux et de travaux batch exprimées via un DSL
- Stocke les artefacts .jar ou images docker
- Définit les propriétés de configuration des artefacts (flux d’entrées/sorties flux, propriétés de déploiements telles que le nombre initial d'instances, les besoins en mémoire et le partitionnement des données).
- Démarre les déploiements de travaux batch et délègue la planification des travaux
- Délégation du déploiement de flux à Skipper.
- Offre une historique d'exécution et un audit

Skipper serveur

Déploiement de flux sur une ou plusieurs plates-formes.

Mise à niveau et restauration du flux sur une ou plusieurs plates-formes à l'aide d'une stratégie de mise à jour blue/green basée sur une machine d'état.

Stockage de l'historique du fichier manifeste de chaque flux (qui représente la description finale des applications déployées).

Cloud Security

Introduction
Rappels oAuth2
Spring Boot et oAuth2
Spring Cloud Security

Introduction

Plusieurs approches pour sécuriser une architecture micro-services :

- N’implémenter la sécurité qu’au niveau du proxy. Les micro-services back-end ne sont pas protégés
- Chaque micro-service a sa propre politique de sécurité. Un jeton d’accès relayé permet de vérifier les ACLs
- Chaque micro-service a sa propre politique de sécurité et chaque micro-service demande son propre jeton pour effectuer ses appels REST

Modèle micro-service

Dans un modèle micro-service, les différents micro-services peuvent être clients et/ou serveur de ressources *oAuth*.

L'identité d'une requête et ses permissions peuvent varier en fonction des micro-services qu'elle traverse

http://stytex.de/blog/2016/02/01/spring-cloud-security-with-oauth2/

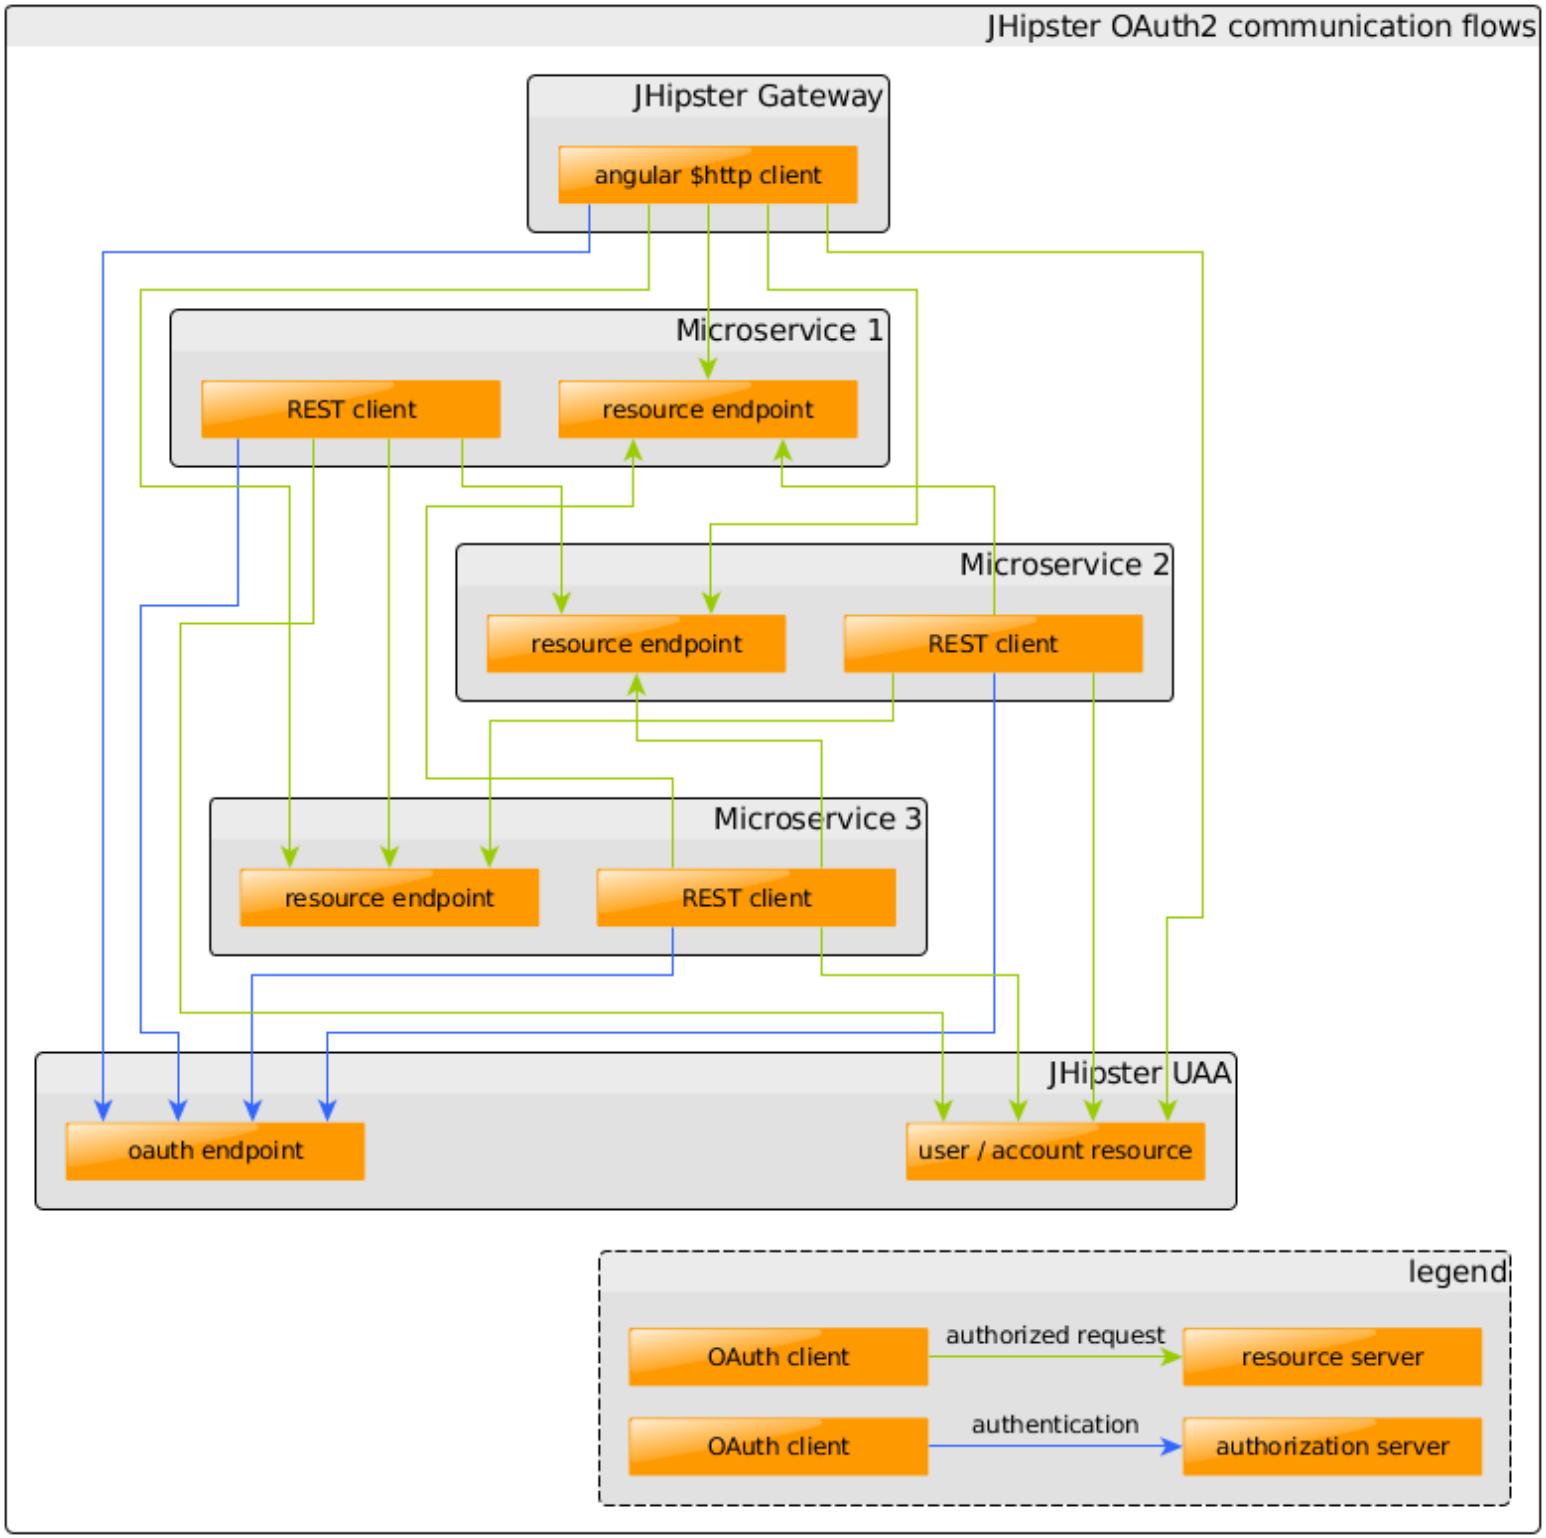
JHipster OAuth2 communication flows
JHipster Gateway
angular $http client
Microservice 1
REST client
resource endpoint
Microservice 2
resource endpoint
REST client
Microservice 3
resource endpoint
REST client
JHipster UAA
oauth endpoint
user / account resource
legend
OAuth client
authorized request
resource server
OAuth client
authentication
authorization server

Cloud Security

Introduction
Rappels oAuth2
Spring Boot et oAuth2
Spring Cloud Security

Rôles du protocole

Le **Client** est l'application qui essaie d'accéder au compte utilisateur. Elle a besoin d'obtenir une permission de l'utilisateur pour le faire.

Le **serveur de ressources** est l'API utilisée pour accéder aux ressources protégées

Le **serveur d'autorisation** est le serveur qui autorise un client a accéder aux ressources en lui fournissant un jeton. Il peut demander l'approbation de l'utilisateur

L'utilisateur est la personne qui donne accès à certaines parties de son compte

Rq : Un participant du protocole peut jouer plusieurs rôles

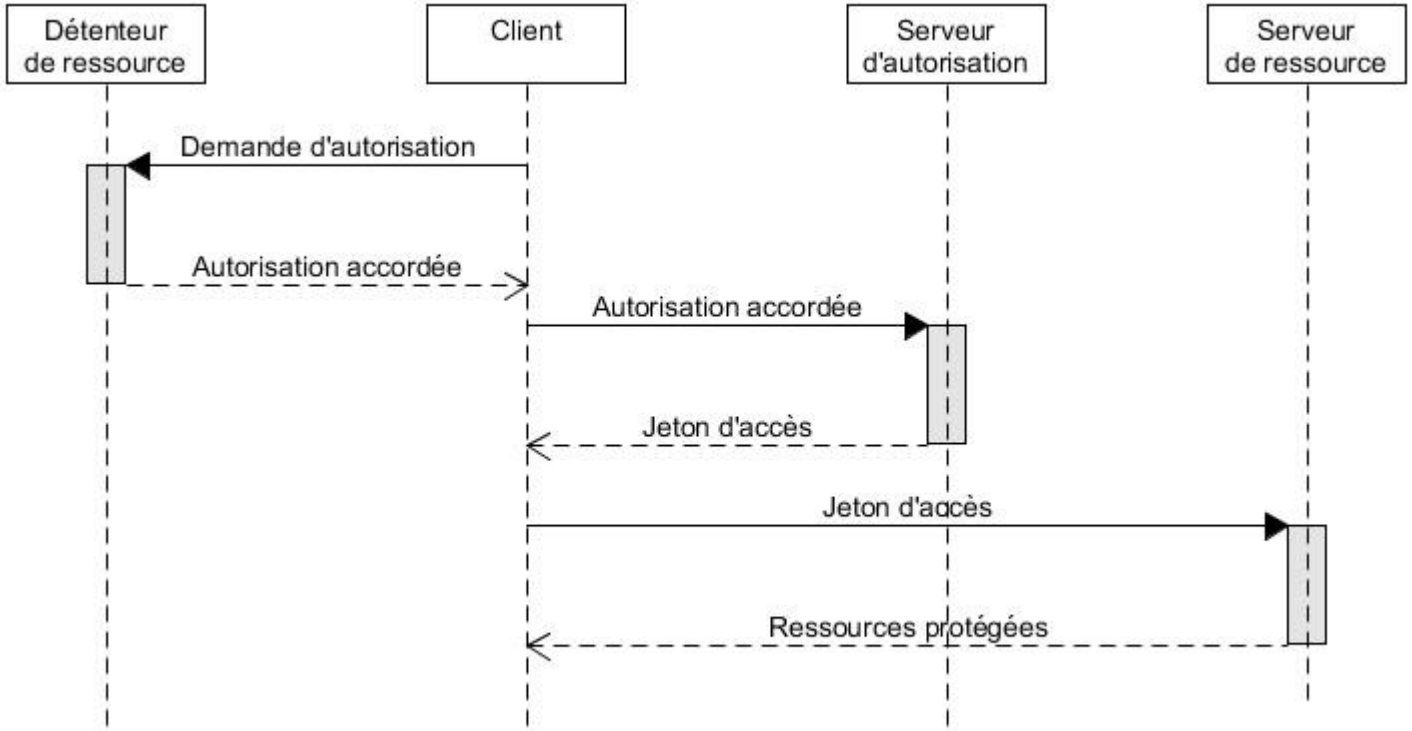
Détenteur de ressource
Client
Serveur d'autorisation
Serveur de ressource
Demande d'autorisation
Autorisation accordée
Autorisation accordée
Jeton d'accès
Jeton d'accès
Ressources protégées

Scénario

1. Pré-enregistrer le client auprès du service d'autorisation (=> client ID et un secret)
2. Obtenir l'autorisation de l'utilisateur. (4 types de grant)
3. Vérifier la réponse du service *oAuth* (state)
4. Obtention du token (date d'expiration)
5. Appel de l'API pour obtenir les informations voulues en utilisant le token

Tokens

Les Tokens sont des chaînes de caractères aléatoire générées par le serveur d'autorisation

Les jetons sont ensuite présents dans les requêtes HTTP et contiennent des informations sensibles => HTTPS

Il y a 2 types de token

- Le **jeton d'accès**: Il a une durée de vie limité.
- Le ***Refresh Token***: Délivré avec le jeton d'accès. Il est renvoyer au serveur d'autorisation pour renouveler le jeton d'accès lorsqu'il a expiré

Périmètre d’accès

Le ***scope*** est un paramètre utilisé pour limiter les droits d’accès d’un client

Le serveur d’autorisation définit les *scopes* disponibles

Le client peut préciser le *scope* qu’il veut utiliser lors de l’accès au serveur d’autorisation

Enregistrement du client

Le protocole ne définit pas comment l'enregistrement du client doit se faire mais définit les paramètres d'échange.

Le client doit fournir :

- ***Application Name***: Le nom de l'application
- ***Redirect URLs***: Les URLs du client pour recevoir le code d'autorisation et le jeton d'accès
- ***Grant Types*** : Les types d'autorisations utilisables par le client
- ***Javascript Origin*** (optionnel): Le host autorisé à accéder aux ressources via *XMLHttpRequest*

Le serveur répond avec :

- ***Client Id***:
- ***Client Secret***: Clé devant rester confidentielle

OAuth2 Grant Type

Différents moyens afin que l'utilisateur donne son accord : les **grant types**

- ***authorization code*** :
  - L'utilisateur est dirigé vers le serveur d'autorisation
  - L'utilisateur consent sur le serveur d'autorisation
  - Il est redirigé vers le client avec un code d'autorisation
  - Le client utilise le code pour obtenir le jeton
- ***implicit*** : Jeton fourni directement. Certains serveurs interdisent de mode
- ***password :*** Le client fournit les crédentiels de l'utilisateur
- ***client credentials*** : Le client est l'utilisateur
- ***device code*** :

Usage du jeton

Le jeton est passé à travers 2 moyens :

- Les paramètres HTTP. (Les jetons apparaissent dans les traces du serveur)
- ***L'entête d'Authorization***

```
GET /profile HTTP/1.1
Host: api.example.com
Authorization: Bearer MzJmNDc3M2VjMmQzN
```

http://www.bubblecode.net/en/2016/01/22/understanding-oauth2/

JWT

JSON Web Token (JWT) est un standard ouvert défini dans la RFC 75191.

Il permet l'échange sécurisé de jetons (tokens) entre plusieurs parties.

La sécurité consiste en la vérification de l’intégrité des données à l’aide d’une signature numérique. (HMAC ou RSA).

Dans le cadre d’une application REST SpringBoot, le jeton contient les informations d’authentification d’un user : Subject + Rôles

Différentes implémentations existent en Java, dont *io.jsonwebtoken*

Cloud Security

Introduction
Rappels oAuth2
Spring Boot et oAuth2
Spring Cloud Security

Apport de SpringBoot

Le support de oAuth via Spring a été revu :

- Le projet ***spring-security-oauth2*** a été déprécié et remplacé par SpringSecurity 5.
  Voir :
  https://github.com/spring-projects/spring-security/wiki/OAuth-2.0-Migration-Guide
- Il n'y a plus de support pour un serveur d'autorisation

3 starters sont désormais fourni :

- ***OAuth2 Client*** : Intégration pour utiliser un login oAuth2 fournit par Google, Github, Facebook, ...
- ***OAuth2 Resource server*** : Application permettant de définir des ACLs par rapport aux scopes client et aux rôles contenu dans des jetons oAuth
- ***Okta*** : Pour travailler avec le fournisseur oAuth Okta

Solutions pour un serveur d’autorisation

- Utiliser un produit autonome
- Un projet Spring pour un serveur d’autorisation est en cours :
  https://github.com/spring-projects-experimental/spring-authorization-server
- Une autre alternative est d’embarquer une solution *oAuth* comme *KeyCloak* dans un application SpringBoot
  Voir par exemple :
  https://www.baeldung.com/keycloak-embedded-in-spring-boot-app

Serveur de ressources

Dépendance :

```
<dependency>
   <groupId>org.springframework.boot</groupId>
   <artifactId>spring-boot-starter-oauth2-resource-server</artifactId>
</dependency>
```

Le serveur de ressources doit vérifier la signature du jeton pour s’assurer que les données n’ont pas été modifiées.

- ***jwk-set-uri*** contient la clé publique que le serveur peut utiliser pour la vérification
- ***issuer-uri*** pointe vers l'URI du serveur d'autorisation de base, qui peut également être utilisé pour localiser le endpoint fournissant la clé publique

Exemple *application.yml*

```yaml
server:
  port: 8081
  servlet:
    context-path: /resource-server

spring:
  security:
    oauth2:
      resourceserver:
        jwt:
          issuer-uri: http://keycloak:8083/auth/realms/myRealm
          jwk-set-uri: http://keycloak:8083/auth/realms/myRealm/protocol/openid-connect/certs
```

Configuration typique *SpringBoot*

```
@Configuration
public class SecurityConfig extends WebSecurityConfigurerAdapter {

    @Override
    protected void configure(HttpSecurity http) throws Exception {
        http.cors()
            .and()
            .authorizeRequests()
              .antMatchers(HttpMethod.GET, "/user/info", "/api/foos/**")
                .hasAuthority("SCOPE_read")
              .antMatchers(HttpMethod.POST, "/api/foos")
                .hasAuthority("SCOPE_write")
              .anyRequest()
                .authenticated()
            .and()
              .oauth2ResourceServer()
                .jwt();
    }
}
```

Voir : https://github.com/Baeldung/spring-security-oauth.git

Personnalisations

Différents aspects de la configuration par défaut peuvent être personnalisées :

- Revendications personnalisées dans le jeton
- Charger la clé à partir d'un KeyStore

TP 6.1 : @EnableAuthorizationServer

Cloud Security

Introduction
Rappels oAuth2
Spring Boot et oAuth2
Spring Cloud Security

Apports de Spring Cloud Security

Construit sur ***Spring Boot*** *et* ***Spring Security OAuth2***

Spring Cloud Security facilite la mise en place de pattern comme :

- Le relais des jetons *oAuth* à partir d'un front-end jusqu'aux services back-end avec Zuul
- Le relai de jetons entre des ressources serveurs
- Un intercepteur afin qu'un client *Feign* se comporte comme *OAuth2RestTemplate* (fetching tokens etc.)
- Configure l'authentification dans un proxy Zuul

Relais entre serveur de ressources (1)

```
@Configuration
@EnableOAuth2Sso
public class SiteSecurityConfigurer
  extends WebSecurityConfigurerAdapter {

    @Override
    protected void configure(HttpSecurity http) throws Exception {
        // ...
    }
}
```

Configuration serveur de ressource : (Alternative utilisation de JWT)

```
security:
  oauth2:
    client:
      accessTokenUri: http://localhost:7070/authserver/oauth/token
      userAuthorizationUri: http://localhost:7070/authserver/oauth/authorize
      clientId: authserver
      clientSecret: passwordforauthserver
    resource:
      userInfoUri: http://localhost:9000/user
```

Relais entre serveur de ressources (2)

```
@Bean
public OAuth2RestOperations restOperations(
  OAuth2ProtectedResourceDetails resource, OAuth2ClientContext context) {
    return new OAuth2RestTemplate(resource, context);
}
------
@Autowired
private RestOperations restOperations;



public String callRemote() {
      return restOperations.getForObject("http://remote-service/api",
 String.class));


}
```

Zuul Proxy

```
@Controller
@EnableOAuth2Sso
@EnableZuulProxy
class Application {



}
```

L'annotation `@EnableOAuth2Sso` a pour effet que *Zuul* obtienne et valide des jetons auprès d'un serveur d'autorisation

De plus ces jetons sont transférés vers les services backend gérés par Zuul

Exemple de configuration Zuul

```
# customers obtient le jeton d'accès
# stores n'a que l'entête authorization
# recommendation n'a rien
proxy:
  auth:
    routes:
      customers: oauth2
      stores: passthru
      recommendations: none
```

Déploiement

Alternatives

Support pour docker

Spring Cloud Kubernetes

Evolution des infrastructures

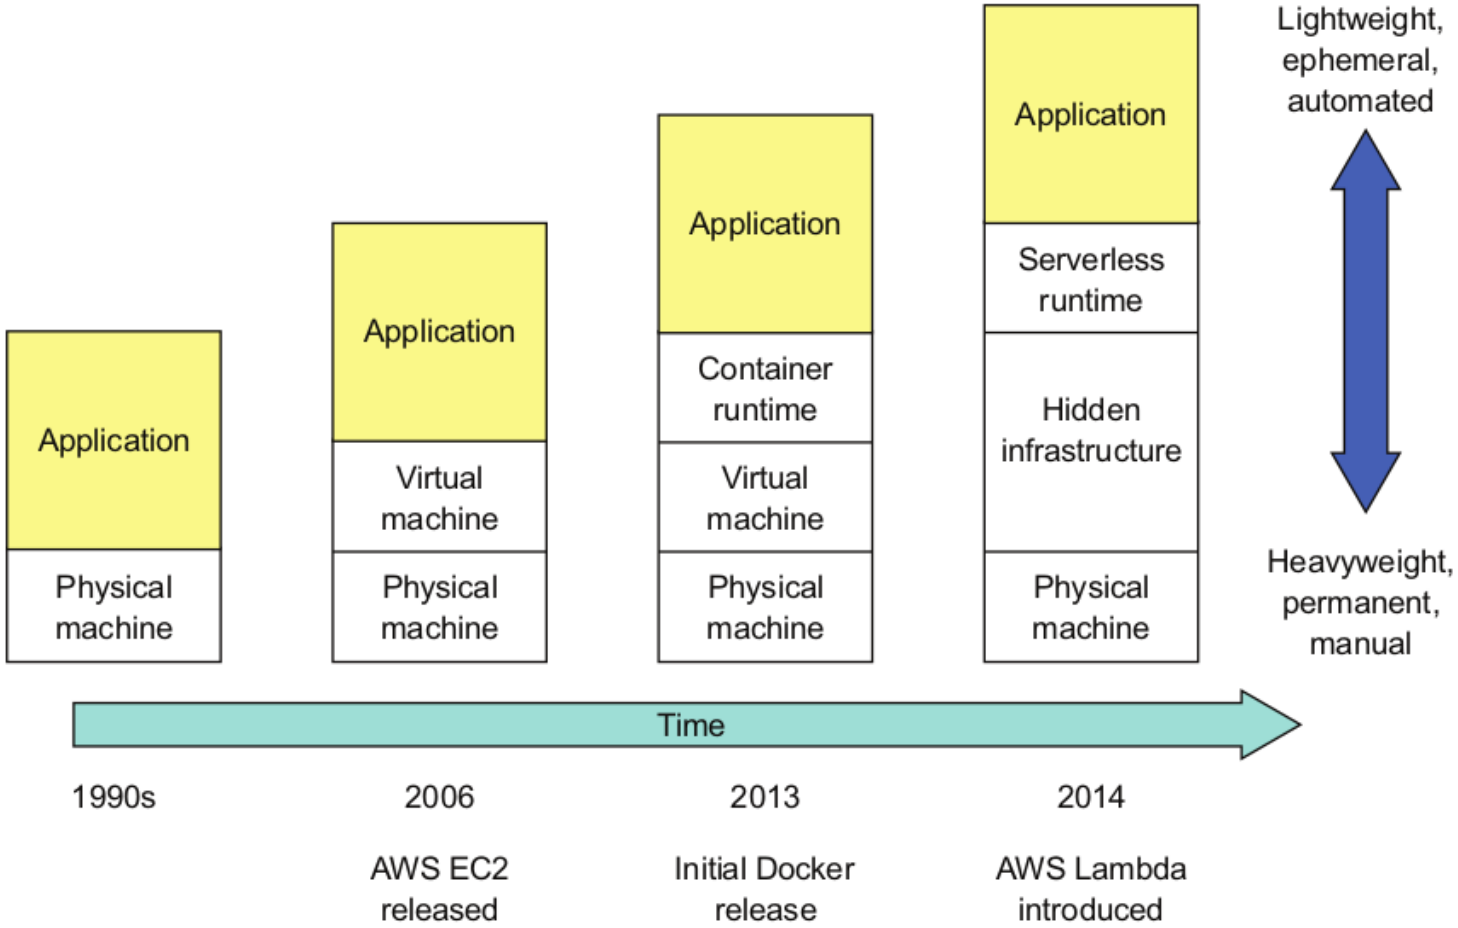

Contraintes

L’environnement de production doit implémenter 4 capacités clés:

- Interface de gestion des services: Créer, mettre à jour et configurer des services. Idéalement une API REST invoquée par des commandes en ligne commande et GUI.
- Gestion des services à l'exécution: tente de garantir que le nombre souhaité d'instances de service s'exécute à tout moment.
- Surveillance/Observabilité : Fournit aux développeurs un aperçu et une vision détaillée aperçu de ce que font leurs services en production
- Routage des requêtes : Les requêtes des utilisateurs sont acheminées vers les services.

Environnement de production

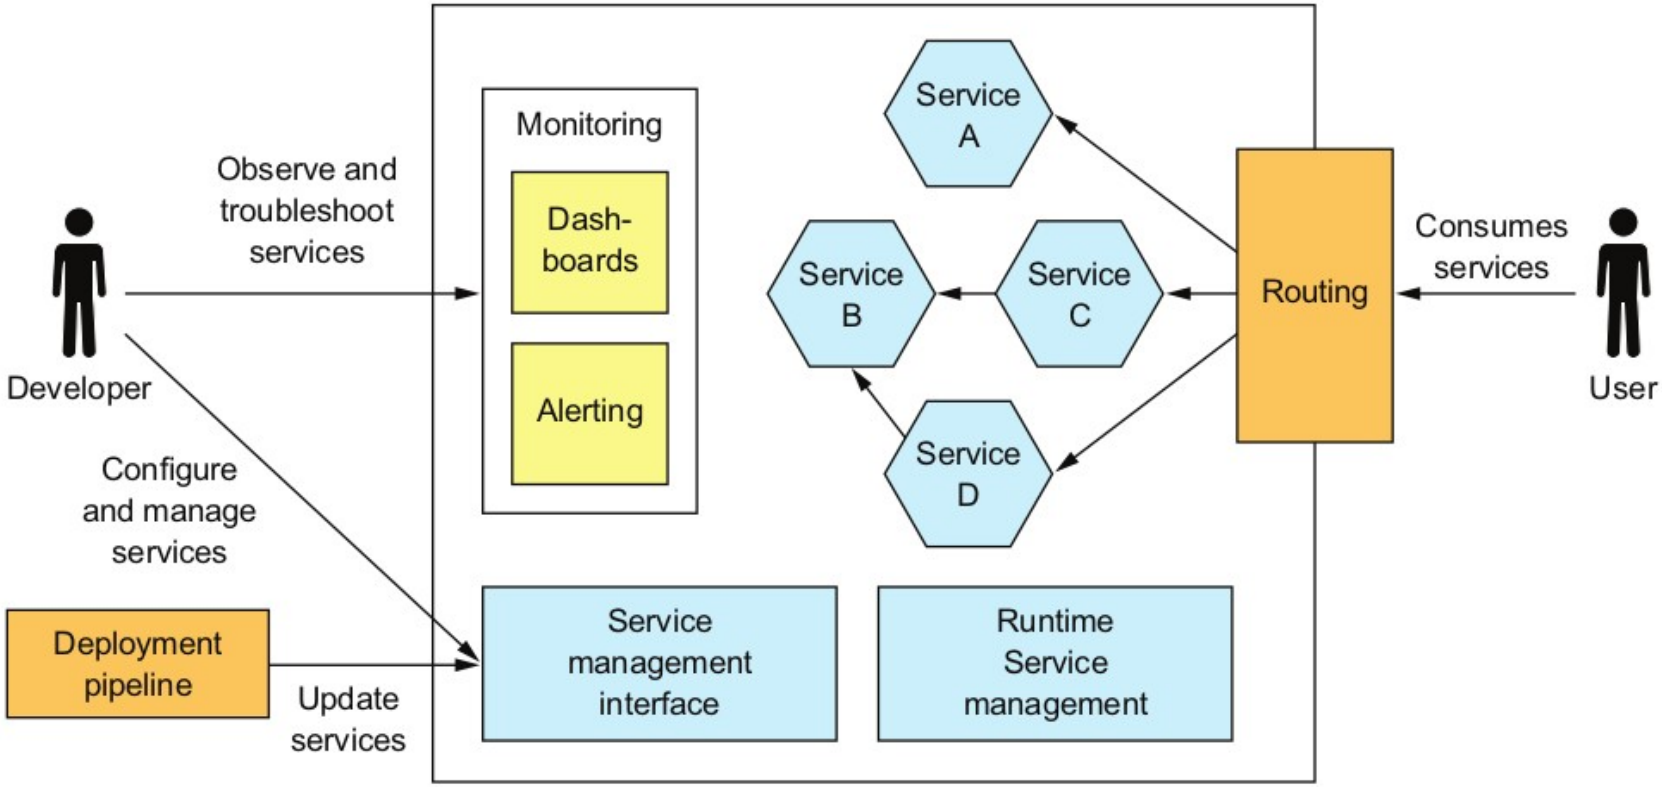

Alternatives de déploiement

Différentes options de packaging pour le déploiement existent :

- Packages spécifiques à un langage : Un jar, war, zip Javascript, ...
- Machines virtuelles qui incluent la pile technologique (OS, JVM, ...)
- Containers
- Serverless Deployment

Inconvénients des packages spécifique à un langage

Manque d'encapsulation de la pile technologique.
=> l’équipe Ops doit connaître précisément les besoins de provisionnement des machines

Aucune possibilité de limiter les ressources consommées par une instance de service.
=> Une instance de service peut consommer toutes les ressources CPU, Mémoire de la machine

Manque d'isolation lors de l'exécution de plusieurs instances de service sur la même machine.

Pas de support pour le placement des instances sur les ressources disponibles

Inconvénients des VMs

Utilisation peu efficace des ressources
=> Chaque service a la surcharge d'une machine entière, souvent surdimensionnée par rapport au service lui-même

Déploiements relativement lents
=> Construction longue car taille d'image très volumineuse, démarrage de service long

Surcharge d'administration système
=> Patch systèmes à appliquer

Déploiement

Alternatives

Support pour docker

Spring Cloud Kubernetes

Dockerfile basique

Il est facile de construire un jar exécutable d'une application Spring Boot via les plugins Maven/Gradle

Un Dockerfile basique est alors :

```
FROM openjdk:8-jdk-alpine
VOLUME /tmp
ARG JAR_FILE
COPY ${JAR_FILE} app.jar
ENTRYPOINT ["java","-jar","/app.jar"]
```

Pour le construire :

```
docker build --build-arg JAR_FILE=target/*.jar -t myorg/myapp .
```

Pour l'exécuter :

```
docker run -p 8080:8080 myorg/myapp
```

Dockerfile + sophistiqué

Pour pouvoir passer des variables d'environnement et des propriétés SpringBoot au démarrage

```
FROM openjdk:8-jdk-alpine
VOLUME /tmp
ARG JAR_FILE=target/*.jar
COPY ${JAR_FILE} app.jar
ENTRYPOINT ["sh", "-c", "java ${JAVA_OPTS} -jar /app.jar ${0} $
  {@}"]
```

On peut alors démarrer l'image via :

```
docker run -p 9000:9000 -e "JAVA_OPTS=-Ddebug -Xmx128m"
  myorg/myapp --server.port=9000
```

Taille des images

- Les images alpine sont plus petites que les images standard openjdk de Dockerhub.
- 20 mB sont éconimisés en utilisant une jre plutôt qu’une jdk
- On peut également essayer d’utiliser jlink (à partir de Java11) pour se créer une image sur mesure en ne sélectionnant que les modules Java utilisés
  - Attention pas de cache, si tous les services Java utilisent des JRE personnalisés

Couches Docker

Un jar Spring Boot a naturellement des "couches" Docker en raison de son packaging.

On peut isoler dans une couche Docker les dépendances externes ainsi tous les services utilisant les mêmes dépendances pourront se construire et se lancer plus vite.
(Cache des container runtime)

Dockerfile à couche

```
$ mkdir target/dependency
$ (cd target/dependency; jar -xf ../*.jar)
$ docker build -t myorg/myapp .

_

FROM openjdk:8-jdk-alpine
VOLUME /tmp
ARG DEPENDENCY=target/dependency
COPY ${DEPENDENCY}/BOOT-INF/lib /app/lib
COPY ${DEPENDENCY}/META-INF /app/META-INF
COPY ${DEPENDENCY}/BOOT-INF/classes /app
ENTRYPOINT ["java","-cp","app:app/lib/*","hello.Application"]
```

Accélérateur de démarrage

Quelques astuces pour accélérer le démarrage du service :

- Améliorer le scan du classpath avec *spring-context-indexer*[1]
- Limiter *actuator* à ce qui est vraiment nécessaire
- SB 2.1+ et S 5.1+
- Spécifier le chemin vers le fichier de config : *spring.config.location*
- Désactiver JMX spring.jmx.enabled=false
- Exécuter la JVM avec -noverify
- Pour Java8, également -XX:+UnlockExperimentalVMOptions -XX:+UseCGroupMemoryLimitForHeap

1. https://docs.spring.io/spring/docs/current/spring-framework-reference/core.html#beans-scanning-index

Utilisateur dédié

Les services doivent s’exécuter avec un utilisateur non root

```
FROM openjdk:8-jdk-alpine

RUN addgroup -S demo && adduser -S demo -G demo
USER demo
```

Spring-Boot Plugin

Depuis la 2.3, Spring boot fournit des plugins Maven/Gradle capables de construire les images

```
$ ./mvnw spring-boot:build-image
$ ./gradlew bootBuildImage
```

- Plus besoin de Dockerfile
- Nécessite que le démon Docker s'exécute
- Par défaut le nom de l'image est :
  `docker.io/<group>/<artifact>:latest`
- Utilise les *Cloud Native Buildpacks*

Autres plugins

Spotify Maven Plugin nécessite un Dockerfile et ajoute des objectifs permettant d'automatiser la construction de l'image dans le build Maven

Palantir Gradle est capable de générer un Dockerfile ou d'utiliser celui que l'on fournit

Jib est également un projet Google qui permet de construire des images optimisées (Docker ou OCI) sans Docker installé

BuildPacks

Cloud Foundry utilise les ***buildbacks*** qui transforment automatiquement le code source en conteneur[1]

- Les développeurs n'ont pas besoin de se soucier des détails sur la construction du conteneur.
- Les buildpacks ont de nombreuses fonctionnalités pour la mise en cache des résultats de construction et des dépendances => Souvent un buildpack s'exécute beaucoup plus rapidement qu'un docker natif

1. Idée originale de Heroku

Sortie standard d’un buildpack

```
$ pack build myorg/myapp --builder=cloudfoundry/cnb:bionic --path=.
2018/11/07 09:54:48 Pulling builder image 'cloudfoundry/cnb:bionic' (use --no-pull flag to skip this step)
2018/11/07 09:54:49 Selected run image 'packs/run' from stack 'io.buildpacks.stacks.bionic'
2018/11/07 09:54:49 Pulling run image 'packs/run' (use --no-pull flag to skip this step)
*** DETECTING:
2018/11/07 09:54:52 Group: Cloud Foundry OpenJDK Buildpack: pass | Cloud Foundry Build System Buildpack: pass | Cloud
  Foundry JVM Application Buildpack: pass
*** ANALYZING: Reading information from previous image for possible re-use
*** BUILDING:
-----> Cloud Foundry OpenJDK Buildpack 1.0.0-BUILD-SNAPSHOT
-----> OpenJDK JDK 1.8.192: Reusing cached dependency
-----> OpenJDK JRE 1.8.192: Reusing cached launch layer

-----> Cloud Foundry Build System Buildpack 1.0.0-BUILD-SNAPSHOT
-----> Using Maven wrapper
       Linking Maven Cache to /home/pack/.m2
-----> Building application
       Running /workspace/app/mvnw -Dmaven.test.skip=true package
...
---> Running in e6c4a94240c2
---> 4f3a96a4f38c
---> 4f3a96a4f38c
Successfully built 4f3a96a4f38c
Successfully tagged myorg/myapp:latest
.
```

KNative

KNative est un projet initié par Google qui a pour put de fournir une infrastructure *ServerLess* au dessus d'un cluster Kubernetes

Comme les *buildpacks*, il est capable de construire les conteneurs à partir du code source.

Déploiement

Alternatives
Support pour docker
Spring Cloud Kubernetes

Alternatives

Différentes alternatives pour déployer sur un cluster Kubernetes :

- Utiliser les descripteurs natifs et le client ***kubectl***
- Utiliser les packages ***Helm***
  https://helm.sh/
- S'équiper d'un outil de IAAS tel que ***Terraform***
  https://www.terraform.io/

Toutes ces alternatives nécessitent d'avoir publier les images des conteneurs dans un dépôt.
Ex : *DockerHub*

Exemple descripteur natif

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: delivery-service
  namespace: default
spec:
  replicas: 2
  selector:
    matchLabels:
      name: delivery-service
  template:
    metadata:
      labels:
        name: delivery-service
    spec:
      containers:
      - name: delivery-service
        image: dthibau/delivery-service:1.0.9
        imagePullPolicy: Always

-----------------------------------------
kubectl apply -f delivery-service.yml
```

Adaptation à l’environnement

Pour adapter la configuration à l’environnement de production, on peut s’appuyer :

- Sur des variables d’environnement
- Sur des arguments de démarrage du conteneur
- Sur le service de *ConfigMag* offerte par Kubernetes

Exemple

```yaml
apiVersion: apps/v1
kind: Deployment
metadata:
  name: delivery-service
  namespace: default
spec:
  replicas: 2
  selector:
    matchLabels:
      name: delivery-service
  template:
    metadata:
      labels:
        name: delivery-service
    spec:
      containers:
      - name: delivery-service
        env:
          - name: SPRING_PROFILES_ACTIVE
            value: prod,swagger
          - name: SPRING_DATASOURCE_URL
            valueFrom:
              configMapKeyRef:
                name: postgres-config
                key: POSTGRES_URL
        image: dthibau/delivery-service:1.0.9
        imagePullPolicy: Always
```

Spring Cloud Kubernetes

Spring Cloud Kubernetes est un projet dont l'objectif est de faciliter le déploiement de micro-services SpringBoot vers Kubernetes

Il fournit des implémentations des interfaces de *Spring Cloud Commons* qui utilisent les services natifs de Kubernetes :

- *@EnableDiscoveryClient*
- Les objets *PropertySource* configurés via ***ConfigMaps***
- Équilibrage de charge côté client via Netflix Ribbon (En cours de dépréciation)

Annexes

Alternative Consul

Alternative *Consul*

Un autre alternative aux outils Netflix est possible : ***Consul***

Le produit *Consul* permet les 2 services de discovery et de configuration

Il est facilement intégrable dans SpringCloud

http://www.consul.io

Consul vs Eureka (1)

Eureka est uniquement un service de discovery. L’architecture client/server, est en général constituée :

- d’un ensemble de serveurs Eureka (1 par datacenter).
- De clients avec un SDK embarqué pour s’enregistrer et découvrir les services

Consul vs Eureka (2)

Consul propose plus de fonctionnalités :

- Vérification de la santé plus riche (TCP, HTTP, Nagios/Sensu ou TTL comme Eureka)
- Stockage de paires clé/valeurs (config) et réplication d'état via le protocole Raft
- Prise en compte de plusieurs datacenter

Consul nécessite un serveur dans chaque datacenter et un agent sur chaque client.

L'agent permet aux applications d'être indépendantes de Consul. L'enregistrement s'effectue par des fichiers de configuration et la découverte via DNS ou par des load balancer.

Mise en place - discovery

Installation de Consul : Serveurs + agent pour chaque micro-services

Ajout de starter :
spring-cloud-starter-consul-discovery

Configuration :

```
spring:
  cloud:
    consul:
      host: localhost
      port: 8500
      discovery:
        healthCheckPath: ${management.server.servlet.context-path}/health
        healthCheckInterval: 15s
```

Mise en place - configuration

Installation de Consul : Serveurs + agent pour chaque micro-services

Ajout de starter :
spring-cloud-starter-consul-config

Configuration :

```
spring:
  cloud:
    consul:
      config:
        enabled: true
        prefix: configuration # Surveillance et rafraîchissement automatique
        defaultContext: apps
        profileSeparator: '::'
```

Répartition de charge avec Ribbon

Introduction Ribbon

Ribbon (Netflix) est un répartiteur de charge côté client décentralisé intégré dans SpringCloud LoadBalancer.

Il permet de contrôler facilement les clients HTTP ou TCP.

Configuration Client Ribbon

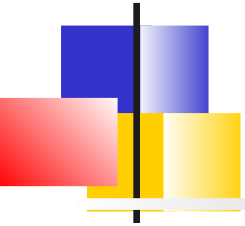

Chaque répartiteur de charge est un **ensemble de beans** Spring collaborant pour contacter un serveur distant

L'ensemble a un **nom** fourni par le développeur (par exemple en utilisant l'annotation *@FeignClient*).

Spring Cloud crée les beans en utilisant une configuration (*RibbonClientConfiguration)*.

Usage de Ribbon

```
spring-cloud-starter-ribbon
```

Ensuite, la configuration d'un client peut s'effectuer en utilisant des propriétés externes

```
<client>.ribbon.*
```

Ou programmatiquement

```
@Configuration
@RibbonClient(name = "foo", configuration =
  FooConfiguration.class)
public class TestConfiguration {
}
```

Exemple configuration

```
say-hello:
  ribbon:
    eureka:
      enabled: false
    listOfServers:
  localhost:8090,localhost:9092,localhost:9999
    ServerListRefreshInterval: 15000
```

Beans

La configuration crée un *ApplicationContext* pour chaque client nommé comprenant les beans suivants :

- ***IClientConfig***, stocke la configuration
- ***ILoadBalancer*** : Le répartiteur
- ***ServerList*** : définit comment obtenir la liste des serveurs
- ***IRule*** décrivant la stratégie de répartition
- ***IPing*** : Donne la période des ping vers un serveur.

Répartition de charge et *RestTemplate*

```
@RibbonClient(name = "ribbonApp")
….
public class RibbonApp {
  @Bean
  @LoadBalanced
  RestTemplate restTemplate () {
    new RestTemplate()
  }


  public void callMicroService() {
     // ribbonApp est le nom du client Ribbon
     Store store =
  restTemplate.getForObject("http://ribbonApp/store", Store.class) ;
  }
}
```

Utilisation avec Eureka

Quand *Eureka* est utilisé en conjonction avec *Ribbon*

- *ribbonServerList* est surchargé avec une extension de ***DiscoveryEnabledNIWSServerList*** qui renseigne la liste de serveurs à partir d'Eureka
- Il remplace également l'interface *IPing* avec ***NIWSDiscoveryPing*** qui délègue à Eureka de déterminer si un serveur est UP

Pattern disjoncteur avec Hystrix

Introduction

Netflix a créé la librairie Hystrix qui implémente le pattern « ***circuit breaker*** »

- Une erreur dans un service bas niveau peut provoquer en cascade des erreurs jusqu'à l'utilisateur final.
- Lorsque des appels vers un service particulier atteint un seuil d'erreur (Par défaut, 20 erreurs en 5 secondes), le circuit s'ouvre et les appels ne sont plus effectués
- Un ***fallback*** peut être fourni par le développeur

Exemple de *Hystrix*

```
Starter : hystrix

--

@SpringBootApplication
@EnableCircuitBreaker
public class Application {

    public static void main(String[] args) {
        new SpringApplicationBuilder(Application.class).web(true).run(args);
    }

}

@Component
public class StoreIntegration {

    @HystrixCommand(fallbackMethod = "defaultStores")
    public Object getStores(Map<String, Object> parameters) {
        //do stuff that might fail
    }

    public Object defaultStores(Map<String, Object> parameters) {
        return /* something useful */;
    }
}
```

Voir plus loin : https://github.com/Netflix/Hystrix/tree/master/hystrix-contrib/hystrix-javanica

Résilience avec *Hystrix*

Hystrix permet la résilience

- Les appels sont effectués via un autre pool de threads
- Cela ne bloque pas la thread de service
- Peut implémenter des timeouts

=> Mécanisme de disjonction si un service ne répond pas ou répond mal

Spring Boot permet une approche par annotation

Thread pools Hystrix

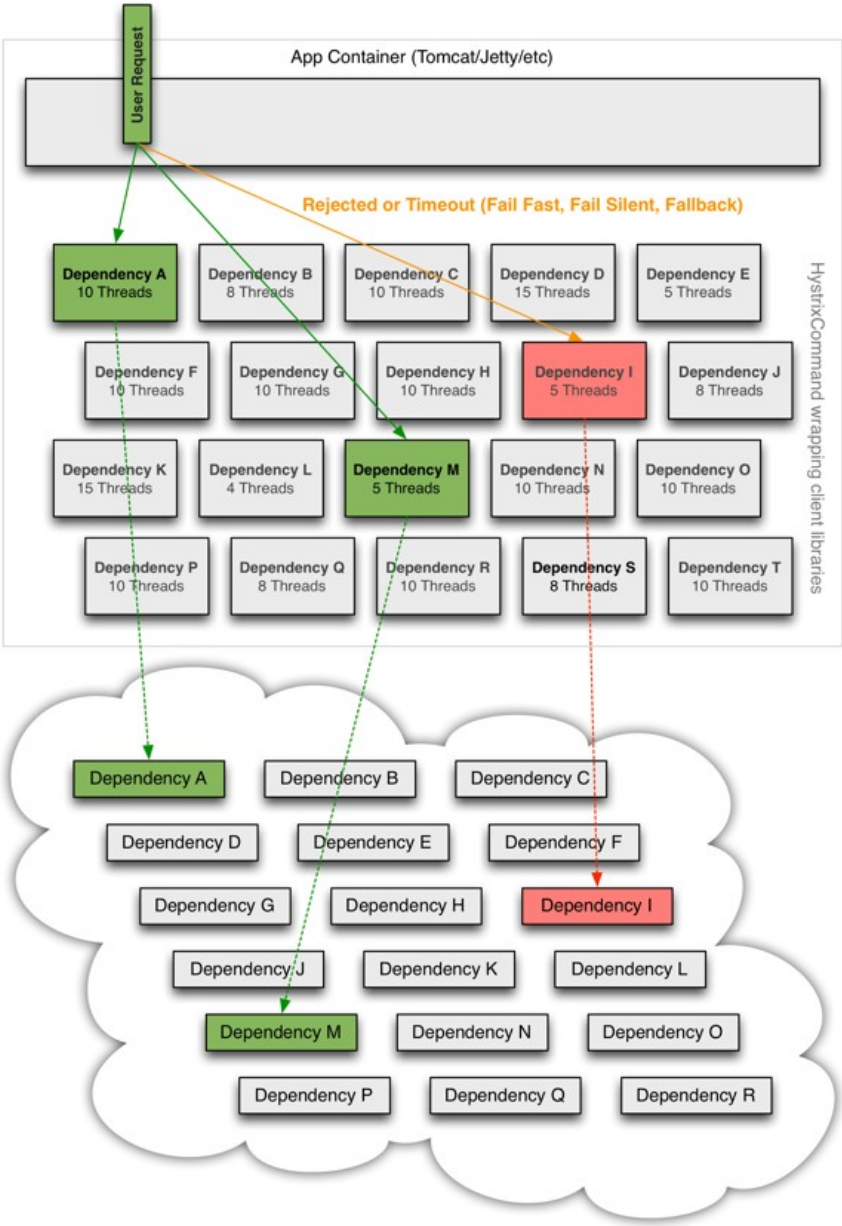

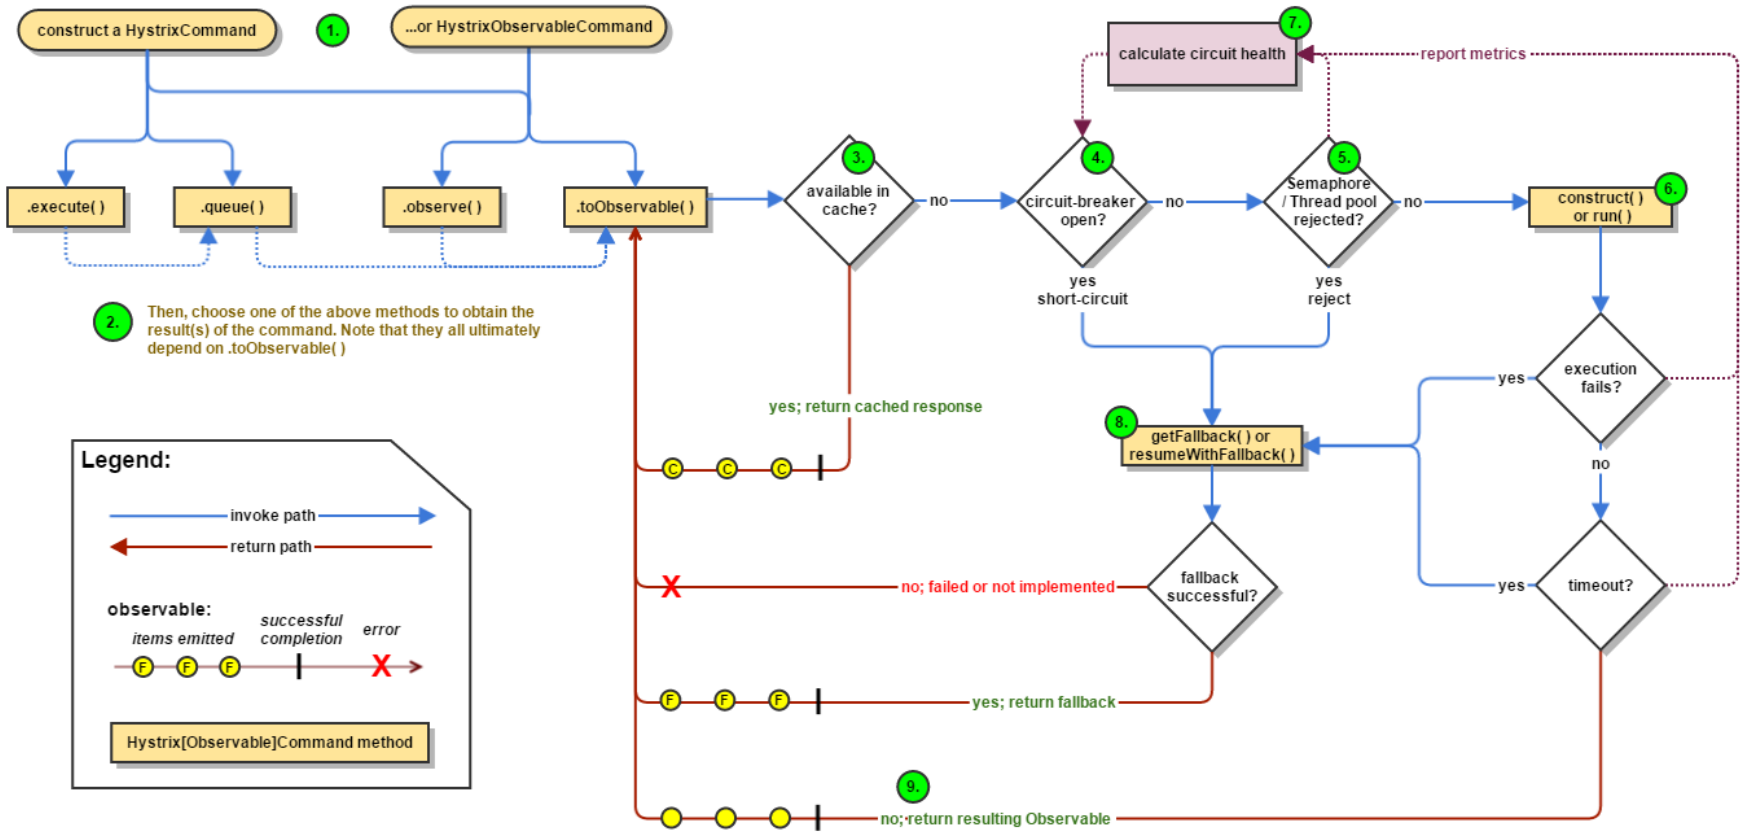
construct a HystrixCommand
1.
...or HystrixObservableCommand
.execute( )
.queue( )
.observe( )
.toObservable( )
2.
Then, choose one of the above methods to obtain the result(s) of the command. Note that they all ultimately depend on .toObservable( )
3.
available in cache?
no
4.
circuit-breaker open?
yes
short-circuit
no
5.
Semaphore / Thread pool rejected?
yes
reject
no
6.
construct( ) or run( )
7.
calculate circuit health
report metrics
yes; return cached response
execution fails?
yes
no
timeout?
yes
8.
getFallback( ) or resumeWithFallback( )
fallback successful?
no; failed or not implemented
yes; return fallback
9.
no; return resulting Observable
Legend:
invoke path
return path
observable:
items emitted
successful completion
error
Hystrix[Observable]Command method

Ouverture/fermeture de circuit

La décision d'ouvrir le circuit (condition anormale) s'appuie

- Sur un nombre d'erreurs dans une fenêtre de temps

La décision de fermer le circuit (retour aux conditions normales de fonctionnement) s'effectue ainsi :

- Après un certain temps ou le circuit est resté ouvert (*circuitBreakerSleepWindowInMilliseconds*)
- Une (seule) requête est tentée :
  - Si elle échoue le circuit reste ouvert
  - Si elle réussit le circuit redevient fermé.

Intégration SpringBoot

L’annotation ***@HystrixCommand*** est fourni par la librairie "*javanica*" de Netflix.

Spring Cloud encapsule automatiquement les beans Spring annotés avec *@HystrixCommand* dans un proxy connecté au disjoncteur Hystrix.

Le disjoncteur calcule quand ouvrir ou fermer le circuit et quoi faire en cas d’erreur.

Spring Cloud Bus

Introduction

Spring Cloud Bus utilise un message broker pour faire communiquer les micro-services.

L'usage principal est de diffuser les changements de configuration.
Il joue alors le rôle d'un Actuator distribué.

Spring Cloud Bus supporte *Apache Kafka*, *Redis*, *RabbitMQ*

Objectifs

Sans Cloud Bus, la mise à jour de configuration d'un micro-service nécessite :

- Un redémarrage
- Ou si l'application contient Actuator, un appel individuel à l'URL */refresh*

Spring Cloud Bus permet de propager les changements de configuration à tous les microservices via une seul opération

Config Server et WebHook

- Au niveau du serveur de configuration, il est possible de rajouter une dépendance sur *spring-cloud-config-monitor* ainsi un endpoint */monitor* est disponible
- Ce endpoint est capable de traiter les webhooks fourni par Github, Gitlab, ...
- Lors de la réception d'un webhook, le serveur de config envoie un évènement sur le bus aux micro-services qui ont changé.
- L'événement provoque le rafraîchissement de la configuration

Rappels Docker

Rappels docker architecture

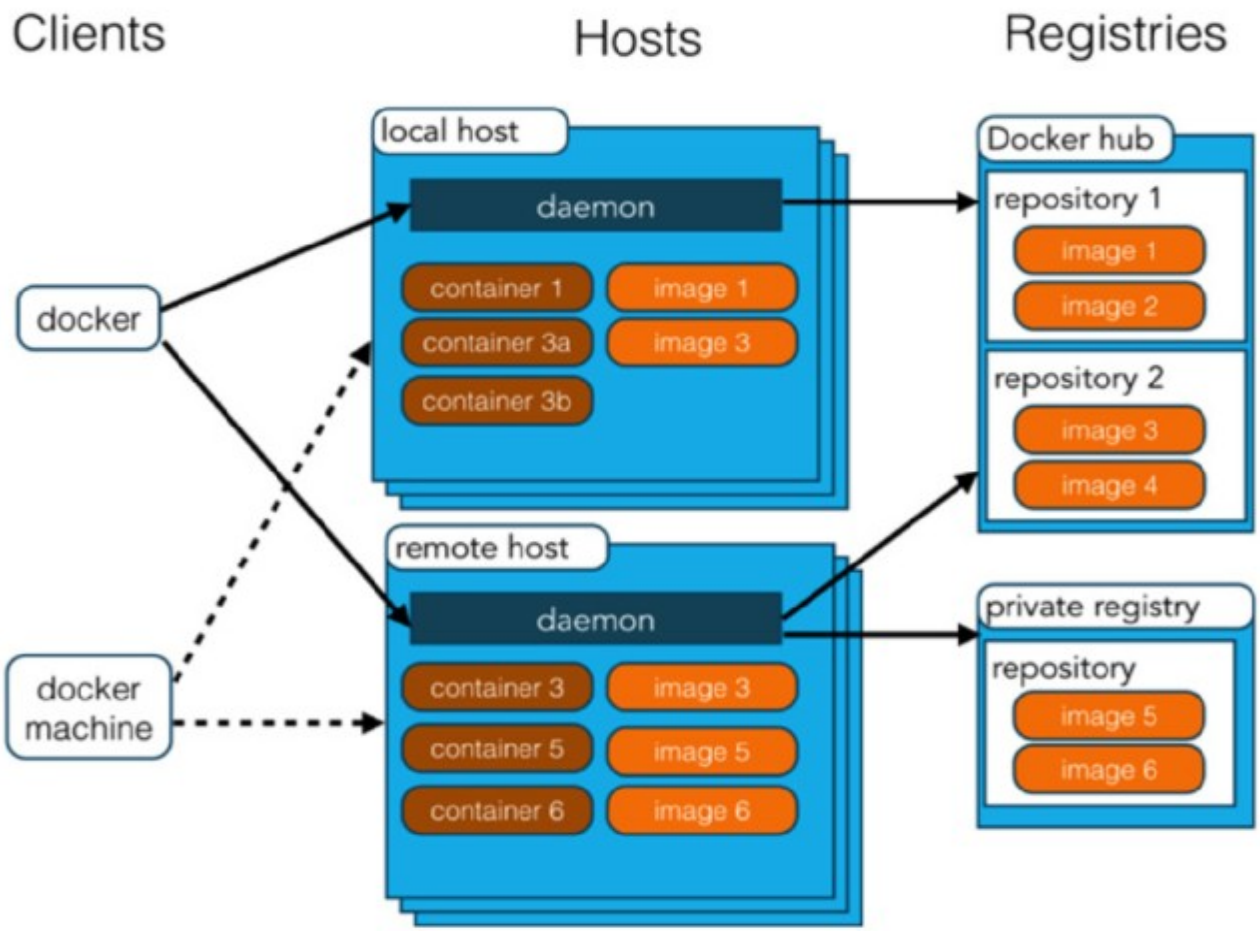

Commandes Docker

```
#Récupération d'une image
docker pull ubuntu
#Récupération et instanciation
docker run hello-world
#Mode interactif
docker run -i -t
#Visualiser les sortie standard d'un conteneur
docker  logs  <container_id>
#Conteneurs en cours
docker ps
#Toutes les exécutions de conteneurs (même arrêt)
docker ps -a
#Lister les images
docker images
#Identifier les différences entre l'image et le conteneur
docker diff <container_id>
#Committer les différences
docker commit <container_id> <image_name>
#Tagger une image d'un repository
docker tag <image_name>[:tag] <name>[:tag]
#Pousser vers un dépôt distant
docker  push <image_name>[:tag]
```

Exemple DockerFile

```
FROM ubuntu
MAINTAINER Kimbro Staken

RUN apt-get install -y software-properties-common python
RUN add-apt-repository ppa:chris-lea/node.js
RUN echo "deb http://us.archive.ubuntu.com/ubuntu/ precise universe" >>
 /etc/apt/sources.list
RUN apt-get update
RUN apt-get install -y nodejs
RUN mkdir /var/www

ADD app.js /var/www/app.js
EXPOSE 8080
CMD ["/usr/bin/node", "/var/www/app.js"]
```

–

```
docker build -t dthibau/myappli:latest
```

Communication entre machines

- Chaque conteneur s'exécutant a sa propre interface réseau (gérée par Docker)
- Par défaut, ll est isolé
  - De la machine hôtes
  - Des autres containers

Communication avec la machine hôte

Au démarrage d'un conteneur on peut :

- Associer un port exposé par le conteneur à un port local
  Option ***-p***
- Monté un répertoire du conteneur sur le système de fichier local.
  Option ***-v***

```
docker run -p 80:8080
           -v /home/jenkins:/var/lib/jenkins
            myImage
```

docker-compose

docker-compose est un outil pour définir et exécuter des applications Docker utilisant plusieurs conteneurs

- Avec un simple fichier, on spécifie les différents conteneurs, les ports exposés, les liens entre conteneurs.
- Ensuite avec une commande unique, on peut démarrer, arrêter, redémarrer l'ensemble des services.

Docker s'installe séparément sur Linux et est inclus dans Docker pour les distributions Mac ou Windows

Orienté au départ pour faciliter le développement et l'intégration ; il intègre de plus en plus des fonctionnalités pour la production

Exemple configuration

```
# Le fichier de configuration définit des services, des networks et des volumes.
version: '2'
services:
  annuaire:
    build: ./annuaire/  # context de build, présence d'un Dockerfile
    networks:
     - back
     - front
    ports:
     - "1111:1111" # Exposition de port
  documentservice:
    build: ./documentService/
    networks:
     - back
  proxy:
    build: ./proxy/
    networks:
      - front
    ports:
      - 8080:8080

# Analogue à 'docker network create'
networks:
  back:
  front:
```

Commandes

build : Construire ou reconstruire les images

config : Valide le fichier de configuration

down : Stoppe et supprime les conteneurs

exec : Exécute une commande dans un container up

logs : Visualise la sortie standard

port : Affiche le port public d'une association de port

pull / ***push*** : Pull/push les images des services

restart : Redémarrage des services

scale : Fixe le nombre de container pour un service

start / ***stop*** : Démarrage/arrêt des services

up : Création et démarrage de conteneurs

@EnableAuthorizationServer

Introduction

Avec ***spring-security-oauth2*** dans le classpath, l'auto-configuration permet de facilement mettre en place le serveur d'autorisation et/ou ressources

L'architecture micro-services étend le modèle de *oAuth2* appliqué aux services comme Google/Facbook/Github

Attention : Spring Security 5 reprend certains des fonctionnalités de *spring-security-oAuth2*

Voir : https://github.com/spring-projects/spring-security/wiki/OAuth-2.0-Migration-Guide

Implémentation oAuth2

Avec *Spring Security oAuth2* :

- Les demandes pour les jetons sont traitées par des contrôleurs de SpringMVC
- L'accès aux ressources protégées est vérifié par des filtres *http*

Mécanismes

Du côté du serveur d'autorisation, 2 endpoints sont fournies :

- ***AuthorizationEndpoint*** (par défaut */oauth/autorize*) traite les requêtes d'autorisation (Autoriser le client à demander des jetons)
- ***TokenEndpoint*** (*/oauth/token*) pour demander des jetons

Pour le serveur de ressource, le filtre ***OAuth2AuthenticationProcessingFilter*** permet d'extraire le jeton d'une requête

Configuration de l’autorisation

L’annotation ***@EnableAuthorizationServer*** fournit une configuration par défaut d’un serveur d’autorisation (***AuthorizationServerConfigurer)*** .

Généralement, 3 aspects reste à être configurés :

- ***ClientDetailsServiceConfigurer*** : Comment récupérer les informations sur le client
- ***AuthorizationServerSecurityConfigurer*** : Les contraintes de sécurité sur les endpoints « jeton » (*/oauth/**)
- ***AuthorizationServerEndpointsConfigurer*** : Le token store, le gestionnaire d’authentification permettant de déterminer les rôles de l’utilisateur final et de vérifier son mot de passe

Attributs d’un client

Un client a différents attributs :

- ***clientId***: id.
- ***secret***: (pour les clients ne nécessitant pas de login/mot de passe)
- ***scope***: Le *scope* permettant de limiter les accès du client (~rôle)
- ***autorizedGrantTypes*** : Les moyens supportés pour le consentement du user (mot de passe, secret, implicit, ..)
- ***authorities***: Permissions accordées aux clients (Permissions standard de Spring Security).

Exemple configuration *clientDetails*

```
@Override
public void configure(ClientDetailsServiceConfigurer clients) throws Exception {

// @formatter:off
clients.inMemory()
  .withClient("browser")
  .authorizedGrantTypes("refresh_token", "password")
  .scopes("ui")
  .and()
  .withClient("account-service")
  .secret(env.getProperty("ACCOUNT_SERVICE_PASSWORD"))
  .authorizedGrantTypes("client_credentials", "refresh_token")
  .scopes("server")
  .and()
  .withClient("statistics-service")
  .secret(env.getProperty("STATISTICS_SERVICE_PASSWORD"))
  .authorizedGrantTypes("client_credentials", "refresh_token")
  .scopes("server");
}
```

Choix du *TokenStore*

Les jetons fournis au client sont générés et stockés dans des ***TokenStore***

3 implémentations :

- ***InMemoryStore*** : Une fois le jeton obtenu, les serveurs de ressources doivent refaire des requêtes vers le serveur d'autorisation pour vérifier que le jeton est valide
- ***JdbStore*** : Les jetons sont stockés dans une base, le serveur de ressources doit pouvoir y accéder
- ***JwtTokenStore*** : Les jetons sont cryptés et le(s) serveurs de ressource détiennent le moyen de décrypter le jeton et d'en déduire les permissions accordées

Exemple configuration *TokenStore et gestionnaire d'authentification utilisateur*

```
@Bean
  public TokenStore tokenStore() {
        return new JwtTokenStore(accessTokenConverter());
    }

// Sécurisation des endpoints
@Override
public void configure(AuthorizationServerEndpointsConfigurer
  endpoints) throws Exception {
endpoints
  .tokenStore(tokenStore)
  .authenticationManager(authenticationManager)
  .userDetailsService(userDetailsService);
}
```

Configuration des ACLs sur les endpoints jeton

```
@Override
public void configure(AuthorizationServerSecurityConfigurer
   oauthServer) throws Exception {
oauthServer
  .tokenKeyAccess("permitAll()")
  .checkTokenAccess("isAuthenticated()");
}
```

Obtention de jeton

Avec la configuration par défaut, le endpoint ***/oauth/token*** permet d'obtenir le jeton typiquement en :

- Utilisant le crédentiel client pour s'authentifier en http sur le endpoint */oauth/token*
- Utilisant le grant type : *password*
- En fournissant les crédentiels de l'utilisateur final

Exemple :

```
curl client:secret@localhost:8080/oauth/token
   -d grant_type=password -d username=user -d password=pwd
```

Serveur de ressources

La création d'un serveur de ressources consiste à annoter ***@EnableResourceServer*** et

- De configurer la sécurité (ACLs)
- Si le serveur de ressources est différent du serveur d'autorisation. Configurer le moyen pour décoder les jetons.

ACLs

Le jeton contient des informations sur :

- Le client et ses scopes
- L’utilisateur et ses rôles

Des droits d’accès sur les scopes peuvent alors être définis de cette façon :

```
http.authorizeRequests().anyRequest()
                        .access("#oauth2.hasScope('write')")
```